图灵程序设计丛书

[PACKT] PUBLISHING

Linux Shell Scripting Cookbook Second Edition

细致剖析实际应用中的110多个案例，让看似复杂的Linux shell脚本任务迎刃而解。

Linux Shell 脚本攻略（第2版）

[印] Shantanu Tushar
Sarath Lakshman 著

门佳 译

人民邮电出版社
POSTS & TELECOM PRESS

数字版权声明

图灵社区的电子书没有采用专有客户端，您可以在任意设备上，用自己喜欢的浏览器和PDF阅读器进行阅读。

但您购买的电子书仅供您个人使用，未经授权，不得进行传播。

我们愿意相信读者具有这样的良知和觉悟，与我们共同保护知识产权。

如果购买者有侵权行为，我们可能对该用户实施包括但不限于关闭该帐号等维权措施，并可能追究法律责任。

Shantanu Tushar

资深GNU/Linux用户，KDE社区著名的贡献者，维护着Calligra Active（用于Tablets的KDE办公文档查看器）、Plasma Media Center以及Gluon Player。Shantanu坚信终有一天编程会变得无比轻松，每个人都会热衷于为计算机编写程序。

Sarath Lakshman

年轻的Linux天才程序员、开源软件及GNU/Linux活跃分子。他作为SLYNUX(2005)的开发者而广为人知，这是一款面向Linux新手的操作友好的GNU/Linux发布版。另外，他还为Linux For You月刊撰写文章，并且还在Fedora、Pardus Linux、PiTiVi、Ubuntu 以及Google编程夏令营等项目中，他都作出了显著的贡献。

门佳

Unix / Linux shell、Perl、正则表达式爱好者。在2001年接触Linux后很快喜欢上该系统。对Unix / Linux系统管理、Linux内核、Web技术研究颇多。工作之余，还喜欢探讨心理学，热衷出没于豆瓣和知乎。除此书外，他还译有《TCP Sockets编程》和《理解Unix进程》。

TURING 图灵程序设计丛书

Linux Shell 脚本攻略（第2版）

[印] Shantanu Tushar
Sarath Lakshman 著

门佳 译

人民邮电出版社
北 京

图书在版编目（CIP）数据

Linux Shell脚本攻略 : 第2版 / (印) 图沙尔(Tushar,S.), (印) 拉克什曼 (Lakshman,S.) 著 ; 门佳译. -- 北京 : 人民邮电出版社, 2014.1
（图灵程序设计丛书）
书名原文: Linux Shell scripting cookbook, Second Edition
ISBN 978-7-115-33921-8

Ⅰ. ①L… Ⅱ. ①图… ②拉… ③门… Ⅲ. ①Linux操作系统－程序设计 Ⅳ. ①TP316.89

中国版本图书馆CIP数据核字(2013)第285766号

内 容 提 要

本书结合丰富的实际案例介绍了如何利用 shell 命令快速开发常规任务，如何凭借短短几个命令行从 Web 挖掘数据的 shell 脚本，如何通过 shell 脚本设置以太网和无线 LAN，以及如何利用少量命令的组合完成诸如文本处理、文件管理、备份等复杂的数据管理工作等。

本书面向初、中、高级 Linux 系统管理员和程序员，是编写 shell 脚本的绝佳参考资料。

◆ 著 [印] Shantanu Tushar Sarath Lakshman
译 门 佳
责任编辑 丁晓昀
责任印制 焦志炜

◆ 人民邮电出版社出版发行 北京市丰台区成寿寺路11号
邮编 100164 电子邮件 315@ptpress.com.cn
网址 http://www.ptpress.com.cn
北京 印刷

◆ 开本：800×1000 1/16
印张：19.5
字数：460千字 2014年 1 月第 1 版
印数：1－5 000册 2014年 1 月北京第 1 次印刷
著作权合同登记号 图字：01-2013-5214号

定价：59.00元

读者服务热线：(010)51095186转600 印装质量热线：(010)81055316
反盗版热线：(010)81055315
广告经营许可证：京崇工商广字第 0021 号

版 权 声 明

献给我至爱的双亲！感谢你们教会我思考和推理的方法，让我乐观地面对生活。

——Shantanu Tushar

前　言

GNU/Linux是世界上最强大、最灵活的操作系统之一。在现代计算领域中，它可谓无处不在，从服务器、便携式计算机、移动电话、平板电脑到超级计算机，概莫能外。尽管配备了优美、时髦的图形用户界面，但shell依然是同Linux进行交互的最灵活的方式。

除了执行单独的命令，shell还可以执行命令脚本，所以非常易于实现各种任务的自动化操作，如生成报表、发送电子邮件、进行系统维护等。本书包含各式各样的攻略，演示了命令及shell脚本的实战用法。你可以将其作为参考，或是自己编写脚本时的灵感源泉。书中涉及的任务包括文本处理、网络运维、系统管理，不一而足。

和学习其他手艺一样，熟能生巧。待你成为shell脚本行家之日，方能完全发挥并驾驭shell的真力。本书会告诉你如何达成这一目标！

本书内容

第1章：小试牛刀。作为用于理解Bash的基本概念及特性的入门章节，这一章讨论了终端打印、数学运算以及其他一些简单的Bash功能。

第2章：命令之乐。这一章展示了GNU/Linux中的常用命令，历数了用户可能会遇到或是可以善加利用的各种实践用例。除了基础命令之外，在这一版中还讨论了加密散列命令（cryptographic hashing command）和尽可能并行执行命令的方法。

第3章：以文件之名。这一章包含了与文件及文件系统相关的多条攻略，讲解了如何生成大体积文件、将文件系统写入文件、挂载文件、创建ISO镜像。我们还探讨了查找并删除重复文件、统计文件行数、收集文件详细信息等操作。

第4章：让文本飞。这一章结合任务实例讲解了GNU/Linux下大部分命令行文本处理工具。此外还包含了一些补充内容，详细介绍了正则表达式以及`sed`/`awk`命令。本章对多数常见的文本处理任务逐一给出了解决方案。这些都是实战中不可不知的技巧。

第5章：一团乱麻？没这回事。这一章包含了多个同互联网服务相关的shell脚本，旨在帮助读者理解如何使用shell脚本与Web进行交互，以实现诸如Web页面数据采集、解析等任务的自动

化操作。讲解了以POST和GET方式发送网页，提交客户数据到服务器的方法。在这一版中，就Twitter这类服务，采用了一种全新的授权机制——OAuth。

第6章：B计划。这一章演示了用于数据备份、归档、压缩等若干命令。除了更快的压缩技术，这一版还讨论了如何创建全盘镜像。

第7章：无网不利。这一章涵盖了Linux环境下的联网实践以及若干有助于编写网络shell脚本的命令。首先介绍了一些网络基础知识，随后讲解了`ssh`的用法，这可算得上是现代GNU/Linux系统中最强大的命令之一。除此之外，我们还讨论了高级端口转发、设置原始通信信道（raw communication channel）、防火墙配置等内容。

第8章：当个好管家。这一章介绍了Linux系统活动监视相关的攻略以及日志记录和报表生成，讲解了计算磁盘使用情况、监视用户访问、CPU占用等任务。在这一版中，我们还会讲述优化电源使用、检查磁盘和文件系统错误的方法。

第9章：管理重任。这一章涉及一系列系统管理方面的实战攻略，讲解了各种用于收集系统详细信息的命令以及使用脚本进行用户管理的方法，还讨论了大图片缩放、通过shell访问MySQL数据库。在这一版中，我们还会学习在不借助窗口管理器的情况下，如何使用GNU Screen来管理多个终端。

阅读本书要求

只要具备任何一种GNU/Linux平台的一般性使用经验，都能很轻松地阅读本书。我们已竭尽所能地确保书中的所有例子清晰明了、简单易懂。在Linux平台下学习的好奇心是你阅读本书所需的唯一条件。我们为你提供了循序渐进的辅导，助你解决书中有关脚本编写的难题。为了运行并测试书中的例子，我们推荐安装Ubuntu/Debian Linux。当然，其他的Linux发行版也足以胜任绝大多数任务。你会发现就编写shell脚本来说，本书绝对是一份通俗易懂的参考资料，同时也是一位助你编写高效脚本的良师益友。

本书读者对象

如果你是一位初中级用户，希望通过掌握快速编写脚本的技巧来完成各类事务处理，而又不愿去逐页翻阅手册，那么本书就是写给你的。你不用了解任何shell脚本或Linux的工作原理，只需要参照书中类似的例子和描述就可以动手了。对于中高级用户以及系统管理员或程序员而言，本书则是在编码过程中寻求问题解决之道的一份绝佳参考资料。

本书约定

本书用多种不同格式的文本来区分不同种类的信息。下面是各类格式的例子及其所代表的含义。

正文中的代码片段像这样显示：“我们创建了名为repeat的函数，它包含了一个无限while循环，该循环尝试运行被作为函数参数（通过$@访问）传入的命令。”

代码块以如下形式显示：

```
if  [ $var -eq 0 ]; then echo "True"; fi
```

还可以写成：

```
if  test $var -eq 0 ; then echo "True"; fi
```

如果我们希望你注意代码块的某部分，那么会使用粗体显示相关的代码行或条目：

```
while  read line;
do  something
done  < filename
```

命令行输入或输出写成如下形式：

```
# mkdir /mnt/loopback
# mount -o loop loopbackfile.img /mnt/loopback
```

新术语和**重要的词句**显示为粗体。

警告或重要的提示出现在这里。

建议和窍门则会以这种方式出现。

读者反馈

十分欢迎读者提供反馈意见。我们想知道你对本书的看法：喜欢哪些部分，不喜欢哪些部分。这些反馈对于协助我们编写出真正对读者有所裨益的书至关重要。[①]

你只需要向feedback@packtpub.com发送电子邮件，并在邮件标题中注明书名即可。如果你在某

① 读者也可以登录图灵社区，在本书的页面（ituring.com.cn/book/1170）下提交反馈意见、勘误以及下载本书示例代码。——编者注

方面有所专长并且愿意参与图书编写或出版，请参阅我们的作者指南www.packtpub. com/authors。

客户支持

现在你已经拥有了这本由Packt出版的图书，为了让此书尽可能地物有所值，我们还为你提供了其他诸多方面的服务。

下载示例代码

你可以在http://www.packtput.com下载本书及你所购买的所有Packt图书的示例代码。如果你是在其他地方购买的本书的英文版，可以访问http://www.packtput.com/support并注册，示例代码将用电子邮件发送给你。

勘误

尽管我们已经竭尽全力确保本书内容准确，但错误终难避免。如果你发现了书中的任何错误，无论是出现在正文还是代码中的，我们都非常乐于见到你将错误提交给我们。这样不仅能够减少其他读者的困惑，还能帮助我们改进本书后续版本的质量。如果需要提交勘误，请访问http://www.packtpub.com/submit-errata，选择相应的书名，单击**勘误提交表单**链接，就可以开始输入详细的勘误信息了。一旦勘误得到确认，我们将接受你的提交，同时勘误内容也将被上传到我们的网站，或者被添加到对应书目勘误区的现有勘误表中。所有图书当前的勘误都可以通过http://www.packtpub.com/support来查看。

举报盗版

各种媒体在网上一直饱受版权侵害的困扰。Packt坚持严格保护版权和授权。如果你在网上发现我社图书的任何形式的盗版，请立即为我们提供地址或网站名称，以便我们采取进一步的措施。

请将疑似侵权的网站链接发送至copyright@packtpub.com。

非常感谢你对保护作者知识产权所做的工作，我们将竭诚为读者提供有价值的内容。

疑难解答

如果你对本书的某方面抱有疑问，请通过questions@packtpub.com联系我们，我们会尽力为你解决。

目　录

第 1 章 小试牛刀

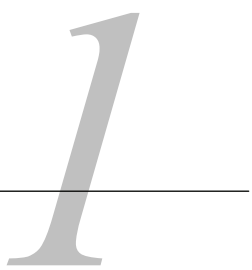

本章内容

- 终端打印
- 玩转变量与环境变量
- 使用函数填加环境变量
- 通过shell进行数学运算
- 玩转文件描述符与重定向
- 数组和关联数组
- 使用别名
- 获取终端信息
- 获取、设置日期及延时
- 调试脚本
- 函数和参数
- 将命令序列的输出读入变量
- 以不按回车键的方式获取字符"n"
- 运行命令直至执行成功
- 字段分隔符和迭代器
- 比较与测试

1.1 简介

诸多类Unix操作系统的设计令人惊叹。即便是在数十年后的今天，Unix式的操作系统架构仍是有史以来的最佳设计之一。这种架构最重要的一个特性就是命令行界面或shell。shell环境使得用户能与操作系统的核心功能进行交互。术语**脚本**更多涉及的便是这种环境。编写脚本通常使用某种基于解释器的编程语言。而shell脚本不过就是一些文件，我们能将一系列需要执行的命令写入其中，然后通过shell来执行。

本书使用的是Bash（Bourne Again Shell），它是目前大多数GNU/Linux系统默认的shell环境。鉴于GNU/Linux作为基于Unix式架构最杰出操作系统的地位，书中大部分案例和讨论都假定是在Linux系统环境下进行的。

本章的主要目的是让读者了解shell环境并熟悉shell的基本特性。命令都是在shell终端中输入并执行。打开终端后，就会出现一个提示符。其形式通常如下：

```
username@hostname$
```

或者

```
root@hostname #
```

要么就简单地以$或#表示。

$表示普通用户，#表示管理员用户root。root是Linux系统中权限最高的用户。

以root用户（管理员）的身份直接使用shell来执行任务可不是个好主意。因为如果shell具备较高的权限，命令中出现的输入错误有可能造成更严重的破坏。所以推荐使用普通用户登录系统（使用$来表明这种身份，root登录时要使用#），然后借助sudo这类工具来运行特权命令。使用sudo <command> <arguments>这种形式执行命令的效果和root一样。

shell脚本通常是一个以shebang[①]起始的文本文件，如下所示：

```
#!/bin/bash
```

shebang是一个文本行，其中#!位于解释器路径之前。/bin/bash是Bash的解释器命令路径。

有两种运行脚本的方式。一种是将脚本作为bash的命令行参数，另一种是授予脚本执行权限，将其变为可执行文件。

将脚本作为命令行参数时的运行方式如下（#号后面的文本是注释，不必输入到命令行中）：

```
$ bash script.sh #假设脚本位于当前目录下
```

或者

```
$ bash /home/path/script.sh #使用script.sh的完整路径
```

如果将脚本作为bash的命令行参数来运行，那么就用不着脚本中的shebang了。

要是有需要的话，可以利用shebang来实现脚本的独立运行。对此必须设置脚本的可执行权限，这样它就可以使用位于#!之后的解释器路径来运行了。就像这样：

```
$ chmod a+x script.sh
```

该命令赋予所有用户script.sh文件的可执行权限。这个脚本能以下列方式执行：

```
$ ./script.sh #./表示当前目录
```

或者

---

① shebang这个词其实是两个字符名称的组合。在Unix的行话里，用sharp或hash（有时候是mesh）来称呼字符“#”，用bang来称呼惊叹号“!”，因而shebang合起来就代表了这两个字符。详情请参考：http://en.wikipedia.org/wiki/Shebang_(Unix)。（注：书中脚注均为译者注。）

```
$ /home/path/script.sh #使用脚本的完整路径
```

内核会读取脚本的首行并注意到shebang为`#!/bin/bash`。它识别出/bin/bash并在内部像这样执行该脚本：

```
$ /bin/bash script.sh
```

当启动shell时，它一开始会执行一组命令来定义诸如提示文本、颜色等各类设置。这组命令来自位于用户主目录中的脚本文件~/.bashrc（对于登录shell则是~/.bash_profile）。Bash还维护了一个历史记录文件~/.bash_history，用于保存用户运行过的命令。

~表示主目录，它通常是/home/user，其中user是用户名，如果是root用户，则为/root。

登录shell是登录主机后获得的那个shell。如果登录图形界面环境（比如GNOME、KDE等）后打开了一个shell，就不是登录shell。

在Bash中，每个命令或是命令序列是通过使用分号或换行符来分隔的。比如：

```
$ cmd1 ; cmd2
```

它等同于：

```
$ cmd1
$ cmd2
```

字符#指明注释的开始。

注释部分以#为起始，一直延续到行尾。注释行通常用于为代码提供注释信息，或者停止执行某行代码。[①]

现在让我们继续讨论基本特性。

1.2 终端打印

终端是交互式工具，用户可以通过它与shell环境进行交互。在终端中打印文本是绝大多数shell脚本和工具日常需要执行的基本任务。在这则攻略中我们会看到，可以使用各种方法，采用各种格式进行打印。

① shell不执行脚本中的任何注释部分。

1.2.1　实战演练

echo是用于终端打印的基本命令。

在默认情况下，echo在每次调用后会添加一个换行符。

```
$ echo "Welcome to Bash"
Welcome to Bash
```

只需要使用带双引号的文本，结合echo命令就可以将该文本在终端中打印出来。类似地，不带双引号的文本也可以得到同样的输出结果：

```
$ echo Welcome to Bash
Welcome to Bash
```

使用单引号也可以完成同样的任务：

```
$ echo 'text in quotes'
```

这些方法看起来相似，但各有一些特殊用途和副作用。思考下面这行命令：

```
$ echo "cannot include exclamation - ! within double quotes"
```

这条命令将会返回：

```
bash: !: event not found error
```

因此，如果需要打印!，那就不要将其放入双引号中，或者你可以在其之前加上一个特殊的转义字符（\）将!转义，就像这样：

```
$ echo Hello world !
```

或者

```
$ echo 'Hello world !'
```

或者

```
$ echo "Hello world \!" #将转义字符放在前面
```

每种方法的副作用如下所述。

- 使用不带引号的echo时，没法在所要显示的文本中使用分号（;），因为分号在Bash shell中被用作命令定界符。
- 以echo hello;hello为例，echo hello被视为一个命令，第二个hello则被视为另一个命令。
- 变量替换在单引号中无效，在下一则攻略中会详细讨论。

另一个可用于终端打印的命令是printf。printf使用的参数和C语言中的printf函数一样。例如：

```
$ printf "Hello world"
```

printf使用引用文本或由空格分隔的参数。我们可以在printf中使用格式化字符串，还可以指定字符串的宽度、左右对齐方式等。在默认情况下，printf并不像echo命令一样会自动添加换行符，我们必须在需要的时候手动添加，比如在下面的脚本中：

```
#!/bin/bash
#文件名: printf.sh

printf  "%-5s %-10s %-4s\n" No Name  Mark
printf  "%-5s %-10s %-4.2f\n" 1 Sarath 80.3456
printf  "%-5s %-10s %-4.2f\n" 2 James 90.9989
printf  "%-5s %-10s %-4.2f\n" 3 Jeff 77.564
```

我们会得到如下格式化的输出：

```
No    Name       Mark
1     Sarath     80.35
2     James      91.00
3     Jeff       77.56
```

1.2.2 工作原理

%s、%c、%d和%f都是格式替换符（format substitution character），其所对应的参数可以置于带引号的格式字符串之后。

%-5s指明了一个格式为左对齐且宽度为5的字符串替换（-表示左对齐）。如果不用-指定对齐方式，字符串就采用右对齐形式。宽度指定了保留给某个变量的字符数。对Name而言，保留宽度是10。因此，任何Name字段的内容都会被显示在10字符宽的保留区域内，如果内容不足10个字符，余下的则以空格符填充。

对于浮点数，可以使用其他参数对小数部分进行舍入。

对于Mark字段，将其格式化为%-4.2f，其中.2指定保留2个小数位。注意，在每行格式字符串后都有一个换行符（\n）。

1.2.3 补充内容

使用echo和printf的命令选项时，要确保选项应该出现在命令行内所有字符串之前，否则Bash会将其视为另外一个字符串。

1. 在echo中转义换行符

在默认情况下，echo会将一个换行符追加到输出文本的尾部。可以使用选项-n来忽略结尾的换行符。echo同样接受双引号字符串内的转义序列作为参数。如果需要使用转义序列，则采用echo -e "包含转义序列的字符串"这种形式。例如：

```
echo -e "1\t2\t3"
1  2  3
```

2. 打印彩色输出

在终端中生成彩色输出相当好玩，我们可以使用转义序列来实现。

每种颜色都有对应的颜色码。比如：重置=0，黑色=30，红色=31，绿色=32，黄色=33，蓝色=34，洋红=35，青色=36，白色=37。

要打印彩色文本，可输入如下命令：

```
echo -e "\e[1;31m This is red text \e[0m"
```

\e[1;31将颜色设为红色，\e[0m将颜色重新置回。只需要将31替换成想要的颜色码就可以了。

要设置彩色背景，经常使用的颜色码是：重置=0，黑色=40，红色=41，绿色=42，黄色=43，蓝色=44，洋红=45，青色=46，白色=47。

要打印彩色文本，可输入如下命令：

```
echo -e "\e[1;42m Green Background \e[0m"
```

1.3　玩转变量和环境变量

变量是任何一种编程语言都必不可少的组成部分，用于存放各类数据。脚本语言通常不需要在使用变量之前声明其类型。只需要直接赋值就可以了。在Bash中，每一个变量的值都是字符串。无论你给变量赋值时有没有使用引号，值都会以字符串的形式存储。有一些特殊的变量会被shell环境和操作系统环境用来存储一些特别的值，这类变量就被称为**环境变量**。让我们来看一些实例。

1.3.1　预备知识

变量采用常见的命名方式进行命名。当应用程序执行时，它接收一组环境变量。可以使用env命令查看所有与终端相关的环境变量。对于进程来说，其运行时的环境变量可以使用下面的命令来查看：

```
cat /proc/$PID/environ
```

其中，将PID设置成相关进程的进程ID（PID总是一个整数）。

假设有一个叫做gedit的应用程序正在运行。我们可以使用pgrep命令获得gedit的进程ID：

```
$ pgrep gedit
12501
```

那么，你就可以通过以下命令获得与该进程相关的环境变量：

```
$ cat /proc/12501/environ
GDM_KEYBOARD_LAYOUT=usGNOME_KEYRING_PID=1560USER=slynuxHOME=/home/slynux
```

环境变量远不止这些，只是由于对页面篇幅的限制，在这里删除了其他很多环境变量。

上面的命令返回一个包含环境变量以及对应变量值的列表。每一个变量以name=value的形式来描述，彼此之间由null字符（\0）分隔。如果你将\0替换成\n，那么就可以将输出重新格式化，使得每一行显示一组“变量=值”。替换可以使用tr命令来实现：

```
$ cat /proc/12501/environ  | tr '\0' '\n'
```

现在，让我们看看怎样对变量和环境变量进行赋值及处理。

1.3.2 实战演练

变量可以通过以下方式进行赋值：

```
var=value
```

var是变量名，value是赋给变量的值。如果value不包含任何空白字符（例如空格），那么它就不需要使用引号进行引用，否则必须使用单引号或双引号。

注意，var = value不同于var=value。把var=value写成var = value是一个常见的错误，但前者是赋值操作，后者则是相等操作。

在变量名之前加上$前缀就可以打印出变量的内容：

```
var="value" #给变量var赋值

echo $var
```

或者

```
echo ${var}
```

输出如下：

```
value
```

我们可以在printf或echo命令的双引号中引用变量值。

```
#!/bin/bash
#文件名:variables.sh
fruit=apple
count=5
echo "We have $count ${fruit}(s)"
```

输出如下：

```
We have 5 apple(s)
```

环境变量是未在当前进程中定义，而从父进程中继承而来的变量。例如环境变量HTTP_PROXY，它定义了互联网连接应该使用哪个代理服务器。

该环境变量通常被设置成：

```
HTTP_PROXY=192.168.1.23:3128
export HTTP_PROXY
```

export命令用来设置环境变量。至此之后，从当前shell脚本执行的任何应用程序都会继承这个变量。我们可以按照自己的需要，在执行的应用程序或者shell脚本中导出特定的变量。在默认情况下，有很多标准环境变量可供shell使用。

PATH就是其中之一。通常，变量PATH包含：

```
$ echo $PATH
/home/slynux/bin:/usr/local/sbin:/usr/local/bin:/usr/sbin:/usr/bin:/sbin:/bin:/usr
/games
```

在给出所要执行的命令后，shell会自动在PATH环境变量所包含的目录列表中（各目录路径之间以冒号分隔）查找对应的可执行文件。PATH通常定义在/etc/environment或/etc/profile或~/.bashrc中。如果需要在PATH中添加一条新路径，可以使用：

```
export PATH="$PATH:/home/user/bin"
```

也可以使用

```
$ PATH="$PATH:/home/user/bin"
$ export PATH

$ echo $PATH
/home/slynux/bin:/usr/local/sbin:/usr/local/bin:/usr/sbin:/usr/bin:/sbin:/bin:/usr
/games:/home/user/bin
```

这样，我们就将/home/user/bin添加到了PATH中。

还有一些众所周知的环境变量：HOME、PWD、USER、UID、SHELL等。

使用单引号时，变量不会被扩展（expand），将依照原样显示。这意味着：

```
$ echo '$var' will print $var
```

但如果变量var已经定义过，那么$ echo "$var"会打印出该变量的值；如果没有定义过，则什么都不打印。

1.3.3 补充内容

让我们再多看些有关标准变量和环境变量的技巧。

1. 获得字符串长度

可以用下面的方法获得变量值的长度：

```
length=${#var}
```

例如：

```
$ var=123456789012345678905
echo ${#var}
20
```

length就是字符串所包含的字符数。

2. 识别当前所使用的shell

可以用下面的方法获知当前使用的是哪种shell：

```
echo $SHELL
```

也可以用

```
echo $0
```

例如：

```
$ echo $SHELL
/bin/bash

$ echo $0
/bin/bash
```

3. 检查是否为超级用户

UID是一个重要的环境变量，可以用于检查当前脚本是以超级用户还是以普通用户的身份运行的。例如：

```
If [ $UID -ne 0 ]; then
    echo Non root user. Please run as root.
else
    echo Root user
fi
```

root用户的UID是0。

4. 修改Bash提示字符串（**username@hostname:~$**）

当我们打开终端或是运行shell时，会看到类似于user@hostname:/home/$的提示字符串。不同GNU/Linux发布版中的提示及颜色略有不同。我们可以利用PS1环境变量来定制提示文本。默认的shell提示文本是在文件~/.bashrc中的某一行设置的。

- 可以使用如下命令列出设置变量PS1的那一行：

```
$ cat ~/.bashrc | grep PS1
PS1='${debian_chroot:+($debian_chroot)}\u@\h:\w\$ '
```

- 如果要设置一个定制的提示字符串，可以输入：

```
slynux@localhost: ~$ PS1="PROMPT>"
PROMPT> Type commands here #提示字符串已经改变
```

- 我们可以利用类似\e[1;31的特定转义序列来设置彩色的提示字符串（参考1.2节的内容）。

还有一些特殊的字符可以扩展成系统参数。例如：\u可以扩展为用户名，\h可以扩展为主机名，而\w可以扩展为当前工作目录。

1.4　使用函数添加环境变量

环境变量通常用于存储路径列表，这些路径用于搜索可执行文件、库文件等。例如$PATH、$LD_LIBRARY_PATH，它们通常看起来像这样：

```
PATH=/usr/bin;/bin
LD_LIBRARY_PATH=/usr/lib;/lib
```

这意味着只要shell需要运行二进制可执行文件时，它会首先查找/usr/bin，然后是/bin。

当你必须使用源代码编译生成程序并将其安装到某个特定路径中时，有项极其常见的任务就是将该程序的bin目录加入PATH环境变量。假设我们要将myapp安装到/opt/myapp，它的二进制文件在bin目录中，库文件在lib目录中。

1.4.1 实战演练

实现方法如下：

```
export PATH=/opt/myapp/bin:$PATH
export LD_LIBRARY_PATH=/opt/myapp/lib;$LD_LIBRARY_PATH
```

PATH和LD_LIBRARY_PATH现在看起来应该像这样：

```
PATH=/opt/myapp/bin:/usr/bin:/bin
LD_LIBRARY_PATH=/opt/myapp/lib:/usr/lib;/lib
```

不过我们可以把下面的函数加入.bashrc-，让一切变得更轻松些：

```
prepend() { [ -d "$2" ] && eval $1=\"$2':'\$$1\" && export $1; }
```

像下面这样来使用该函数：

```
prepend PATH /opt/myapp/bin
prepend LD_LIBRARY_PATH /opt/myapp/lib
```

1.4.2 工作原理

我们定义了名为prepend()的函数，它首先检查该函数第二个参数所指定的目录是否存在。如果存在，eval表达式将第一个参数所指定的变量值设置成第二个参数的值加上“:”（路径分隔符），随后再跟上首个参数的原始值。

不过，有一点需要留意。在进行添加时，如果变量为空，则会在末尾留下一个“:”。要解决这个问题，可以将该函数再进行一些修改：

```
prepend() { [ -d "$2" ] && eval $1=\"$2\$\{$1:+':'\$$1\}\" && export $1 ; }
```

在这个函数中，我们引入了一种shell参数扩展的形式：

```
${parameter:+expression}
```

如果parameter有值且不为空，则使用expression的值。

通过这次修改，在追加环境变量时，当且仅当旧值存在，才会增加。

1.5 使用 shell 进行数学运算

无论哪种编程语言都少不了算术操作，在这则攻略中，我们将会研究在shell中进行算术运算的各种方法。

1.5.1　预备知识

在Bash shell环境中，可以利用let、(( ))和[]执行基本的算术操作。而在进行高级操作时，expr和bc这两个工具也会非常有用。

1.5.2　实战演练

(1) 可以用普通的变量赋值方法定义数值，这时，它会被存储为字符串。然而，我们可以用一些方法使它能像数字一样进行运算。

```
#!/bin/bash
no1=4;
no2=5;
```

(2) let命令可以直接执行基本的算术操作。当使用let时，变量名之前不需要再添加$，例如：

```
let result=no1+no2
echo $result
```

- 自加操作

```
$ let no1++
```

- 自减操作

```
$ let no1--
```

- 简写形式

```
let no+=6
let no-=6
```

它们分别等同于let no=no+6和let no=no-6。

- 其他方法

操作符[]的使用方法和let命令类似：

```
result=$[ no1 + no2 ]
```

在[]中也可以使用$前缀，例如：

```
result=$[ $no1 + 5 ]
```

也可以使用(())，但使用(())时，变量名之前需要加上$：

```
result=$(( no1 + 50 ))
```

expr同样可以用于基本算术操作：

```
result=`expr 3 + 4`
result=$(expr $no1 + 5)
```

以上这些方法只能用于整数运算，而不支持浮点数。

(3) bc是一个用于数学运算的高级工具，这个精密计算器包含了大量的选项。我们可以借助它执行浮点数运算并应用一些高级函数：

```
echo "4 * 0.56" | bc
2.24

no=54;
result=`echo "$no * 1.5" | bc`
echo $result
81.0
```

其他参数可以置于要执行的具体操作之前，同时以分号作为定界符，通过stdin传递给bc。

- **设定小数精度**。在下面的例子中，参数scale=2将小数位个数设置为2。因此，bc将会输出包含两个小数位的数值。

```
echo "scale=2;3/8" | bc
0.37
```

- **进制转换**。用bc可以将一种进制系统转换为另一种。来看看如何将十进制转换成二进制，然后再将二进制转换回十进制：

```
#!/bin/bash
用途：数字转换

no=100
echo "obase=2;$no" | bc
1100100
no=1100100
echo "obase=10;ibase=2;$no" | bc
100
```

- **计算平方以及平方根**。

```
echo "sqrt(100)" | bc #Square root
echo "10^10" | bc #Square
```

1.6　玩转文件描述符及重定向

文件描述符是与文件输入、输出相关联的整数。它们用来跟踪已打开的文件。最常见的文件描述符是stdin、stdout和stderr。我们甚至可以将某个文件描述符的内容重定向到另一个文件描述符中。下面给出一些对文件描述符进行操作和重定向的例子。

1.6.1　预备知识

在编写脚本的时候会频繁使用标准输入（stdin）、标准输出（stdout）和标准错误（stderr）。通过内容过滤将输出重定向到文件是我们平日里的基本任务之一。当命令输出文本时，这些输出文本有可能是错误信息，也可能是正常的（非错误的）输出信息。单靠查看输出的文本本身，我们没法区分哪些是正常，哪些是错误。不过可以通过文件描述符来解决这个问题，将那些与特定描述符关联的文本提取出来。

文件描述符是与某个打开的文件或数据流相关联的整数。文件描述符0、1以及2是系统预留的。

- **0** —— stdin（标准输入）。
- **1** —— stdout（标准输出）。
- **2** —— stderr（标准错误）。

1.6.2　实战演练

(1) 用下面的方法可以将输出文本重定向或保存到一个文件中：

```
$ echo "This is a sample text 1" > temp.txt
```

这种方法通过截断文件的方式，将输出文本存储到文件temp.txt中，也就是说在把echo命令的输出写入文件之前，temp.txt中的内容首先会被清空。

(2) 将文本追加到目标文件中，看下面的例子：

```
$ echo "This is sample text 2" >> temp.txt
```

(3) 查看文件内容：

```
$ cat temp.txt
This is sample text 1
This is sample text 2
```

(4) 来看看什么是标准错误以及如何对它重定向。当命令输出错误信息时，stderr信息就会被打印出来。考虑下面的例子：

```
$ ls +
ls: cannot access +: No such file or directory
```

这里，+是一个非法参数，因此将返回错误信息。

成功和不成功的命令

当一个命令发生错误并退回时，它会返回一个非0的退出状态；而当命令成功完成后，它会返回数字0。退出状态可以从特殊变量$?中获得（在命令执行之后立刻运行echo $?，就可以打印出退出状态）。

下面的命令会将stderr文本打印到屏幕上，而不是文件中（而且因为并没有stdout的输出，所以out.txt没有内容）：

```
$ ls + > out.txt
ls: cannot access +: No such file or directory
```

下面的命令中，我们将stderr重定向到out.txt：

```
$ ls + 2> out.txt #正常运行
```

你可以将stderr单独重定向到一个文件，将stdout重定向到另一个文件：

```
$ cmd 2>stderr.txt 1>stdout.txt
```

还可以利用下面这个更好的方法将stderr转换成stdout，使得stderr和stdout都被重定向到同一个文件中：

```
$ cmd 2>&1 output.txt
```

或者这样：

```
$ cmd &> output.txt
```

(5) 有时候，在输出中可能包含一些不必要的信息（比如调试信息）。如果你不想让终端中充斥着有关stderr的繁枝末节，那么你可以将stderr的输出重定向到 /dev/null，保证一切都会被清除得干干净净。假设我们有3个文件，分别是a1、a2、a3。但是普通用户对文件a1没有“读–写–执行”权限。如果需要打印文件名以a起始的所有文件的内容，可以使用cat命令。设置一些测试文件：

```
$ echo a1 > a1
$ cp a1 a2 ; cp a2 a3;
$ chmod 000 a1  #清除所有权限
```

尽管可以使用通配符（a*）显示所有的文件内容，但是系统会显示一个出错信息，因为对文件a1没有可读权限。

```
$ cat a*
cat: a1: Permission denied
a1
a1
```

其中，cat: a1: Permission denied属于stderr。我们可以将stderr信息重定向到一个文件中，而stdout仍然保持不变。考虑如下代码：

```
$ cat a* 2> err.txt # stderr被重定向到err.txt
a1
a1

$ cat err.txt
cat: a1: Permission denied
```

观察下面的代码：

```
$ cmd 2>/dev/null
```

当对如果对stderr或stdout进行重定向，被重定向的文本会传入文件。因为文本已经被重定向到文件中，也就没剩下什么东西可以通过管道(|)传给接下来的命令，而这些命令是通过stdin进行接收的。

(6) 但是有一个方法既可以将数据重定向到文件，还可以提供一份重定向数据的副本作为后续命令的stdin。这一切都可以使用tee来实现。举个例子：要在终端中打印stdout，同时将它重定向到一个文件中，那么可以这样使用tee:

```
command | tee FILE1 FILE2
```

在下面的代码中，tee命令接收到来自stdin的数据。它将stdout的一份副本写入文件out.txt，同时将另一份副本作为后续命令的stdin。命令cat -n将从stdin中接收到的每一行数据前加上行号并写入stdout:

```
$ cat a* | tee out.txt | cat -n
cat: a1: Permission denied
     1a1
     2a1
```

查看out.txt的内容：

```
$ cat out.txt
a1
a1
```

注意，cat: a1: Permission denied 并没有在文件内容中出现。这是因为这些信息属于stderr，而tee只能从stdin中读取。

默认情况下，tee命令会将文件覆盖，但它提供了一个-a选项，用于追加内容。例如：$ cat a* | tee -a out.txt | cat -n。

带有参数的命令可以写成：command FILE1 FILE2…或者就简单的使用command FILE。

(7) 我们可以使用stdin作为命令参数。只需要将-作为命令的文件名参数即可：

```
$ cmd1 | cmd2 | cmd -
```

例如：

```
$ echo who is this | tee -
who is this
who is this
```

也可以将 /dev/stdin作为输出文件名来代替stdin。

类似地，使用 /dev/stderr代表标准错误，/dev/stdout代表标准输出。这些特殊的设备文件分别对应stdin、stderr和stdout。

1.6.3 工作原理

就输出重定向而言，>和>>并不相同。尽管两者可以将文本重定向到文件，但是前者会先清空文件，然后再写入内容，而后者会将内容追加到现有文件的尾部。

当使用重定向操作符时，输出内容不会在终端打印，而是被导向文件。重定向操作符默认使用标准输出。如果想使用特定的文件描述符，你必须将描述符编号置于操作符之前。

>等同于1>；对于>>来说，情况也类似（即>>等同于1>>）。

处理错误时，来自stderr的输出被丢弃到文件/dev/null中。/dev/null是一个特殊的设备文件，它接收到的任何数据都会被丢弃。null设备通常也被称为**黑洞**，因为凡是到这儿的数据都将一去不返。

1.6.4 补充内容

从stdin读取输入的命令能以多种方式接收数据。也可以用cat和管道来指定我们自己的文件描述符，例如：

```
$ cat file | cmd
$ cmd1 | cmd
```

1. 将文件重定向到命令

借助重定向，我们可以像使用stdin那样从文件中读取数据：

```
$ cmd < file
```

2. 将脚本内部的文本块进行重定向

有时候，我们需要对文本块（多行文本）进行重定向，就像对标准输入做的那样。考虑一个特殊情况：源文本就位于shell脚本中。一个实用的例子是向log文件中写入头部数据，可以按照下面的方法完成：

```
#!/bin/bash
cat<<EOF>log.txt
LOG FILE HEADER
This is a test log file
Function: System statistics
EOF
```

在cat <<EOF>log.txt与下一个EOF行之间的所有文本行都会被当做stdin数据。log.txt文件的内容打印如下：

```
$ cat log.txt
LOG FILE HEADER
This is a test log file
Function: System statistics
```

3. 自定义文件描述符

文件描述符是一种用于访问文件的抽象指示器（abstract indicator）。存取文件离不开被称为“文件描述符”的特殊数字。0、1和2分别是stdin、stdout和stderr的预留描述符编号。

我们可以使用exec命令创建自己的文件描述符。如果你对用其他编程语言进行文件编程非常熟悉，你可能已经注意到了文件打开模式。通常会用到3种模式。

- ❑ 只读模式。
- ❑ 截断写入模式。
- ❑ 追加写入模式。

< 操作符用于从文件中读取至stdin。> 操作符用于截断模式的文件写入（数据在目标文件内容被截断之后写入）。>>操作符用于追加模式的文件写入。（数据被添加到文件的现有内容中，而且该目标文件中原有的内容不会丢失。）文件描述符可以用以上三种模式中的任意一种来创建。

创建一个文件描述符进行文件读取：

```
$ exec 3<input.txt #使用文件描述符3打开并读取文件
```

我们可以这样使用它：

```
$ echo this is a test line > input.txt
$ exec 3<input.txt
```

现在你就可以在命令中使用文件描述符3了。例如：

```
$ cat<&3
this is a test line
```

如果要再次读取，我们就不能继续使用文件描述符3了，而是需要用exec重新分配文件描述符3来进行二次读取。

创建一个文件描述符用于写入（截断模式）：

```
$ exec 4>output.txt #打开文件进行写入
```

例如：

```
$ exec 4>output.txt
$ echo newline >&4
$ cat output.txt
newline
```

创建一个文件描述符用于写入（追加模式）：

```
$ exec 5>>input.txt
```

例如：

```
$ exec 5>>input.txt
$ echo appended line >&5
$ cat input.txt
newline
appended line
```

1.7 数组和关联数组

数组是shell脚本非常重要的组成部分，它借助索引将多个独立的数据存储为一个集合。普通数组只能使用整数作为数组索引。Bash也支持关联数组，它可以使用字符串作为数组索引。在很多情况下，采用字符串式索引更容易理解，这时候关联数组就派上用场了。在这里，我们会看到普通数组和关联数组的用法。

1.7.1 预备知识

Bash从4.0版本之后才开始支持关联数组。

1.7.2　实战演练

(1) 定义数组的方法有很多种。可以在单行中使用一列值来定义一个数组：

```
array_var=(1 2 3 4 5 6)
#这些值将会存储在以0为起始索引的连续位置上
```

另外，还可以将数组定义成一组“索引-值”：

```
array_var[0]="test1"
array_var[1]="test2"
array_var[2]="test3"
array_var[3]="test4"
array_var[4]="test5"
array_var[5]="test6"
```

(2) 打印出特定索引的数组元素内容：

```
echo ${array_var[0]}
test1
index=5
echo ${array_var[$index]}
test6
```

(3) 以清单形式打印出数组中的所有值：

```
$ echo ${array_var[*]}
test1 test2 test3 test4 test5 test6
```

也可以这样使用：

```
$ echo ${array_var[@]}
test1 test2 test3 test4 test5 test6
```

(4) 打印数组长度（即数组中元素的个数）：

```
$ echo ${#array_var[*]}
6
```

1.7.3　补充内容

关联数组从Bash 4.0版本开始被引入。借助散列技术，关联数组成为解决很多问题的有力工具。接下来就让我们一探究竟。

1. 定义关联数组

在关联数组中，我们可以用任意的文本作为数组索引。首先，需要使用声明语句将一个变量名声明为关联数组。像下面这样：

```
$ declare -A ass_array
```

声明之后，可以用两种方法将元素添加到关联数组中。

- 利用内嵌“索引-值”列表的方法，提供一个“索引-值”列表：

```
$ ass_array=([index1]=val1 [index2]=val2)
```

- 使用独立的“索引-值”进行赋值：

```
$ ass_array[index1]=val1
$ ass_array'index2]=val2
```

举个例子，试想如何用关联数组为水果制定价格：

```
$ declare -A fruits_value
$ fruits_value=([apple]='100dollars' [orange]='150 dollars')
```

用下面的方法显示数组内容：

```
$ echo "Apple costs ${fruits_value[apple]}"
Apple costs 100 dollars
```

2. 列出数组索引

每一个数组元素都有一个索引用于查找。普通数组和关联数组具有不同的索引类型。我们可以用下面的方法获取数组的索引列表：

```
$ echo ${!array_var[*]}
```

也可以使用：

```
$ echo ${!array_var[@]
```

以先前提到的`fruits_value`数组为例，运行如下命令：

```
$ echo ${!fruits_value[*]}
orange apple
```

对于普通数组，这个方法同样可行。

1.8 使用别名

别名就是一种便捷方式，以省去用户输入一长串命令序列的麻烦。下面我们会看到如何使用`alias`命令创建别名。

1.8.1 实战演练

你可以利用别名进行多种操作，如下所示。

(1) 可以按照下面的方式创建一个别名：

```
$ alias new_command='command sequence'
```

为安装命令apt-get install创建别名：

```
$ alias install='sudo apt-get install'
```

这样一来，我们就可以用install pidgin代替sudo apt-get install pidgin了。

(2) alias命令的作用只是暂时的。一旦关闭当前终端，所有设置过的别名就失效了。为了使别名设置一直保持作用，可以将它放入~/.bashrc文件中。因为每当一个新的shell进程生成时，都会执行 ~/.bashrc中的命令。

```
$ echo 'alias cmd="command seq"' >> ~/.bashrc
```

(3) 如果需要删除别名，只用将其对应的语句（如果有的话）从 ~/.bashrc中删除，或者使用unalias命令。或者使用alias example=，这会取消名为example的别名。

(4) 我们可以创建一个别名rm，它能够删除原始文件，同时在backup目录中保留副本：

```
alias rm='cp $@ ~/backup && rm $@'
```

创建别名时，如果已经有同名的别名存在，那么原有的别名设置将被新的设置取代。

1.8.2　补充内容

有时别名也会造成安全问题。下面来看看应该如何识别这些隐患。

对别名进行转义

alias命令能够为任何重要的命令创建别名，不过你未必总是希望用别名来执行这个命令。我们可以将希望使用的命令进行转义，从而忽略当前定义的别名。例如：

```
$ \command
```

字符\对命令实施转义，使我们可以执行原本的命令，而不是这些命令的别名替身。在不可信环境下执行特权命令，通过在命令前加上 \ 来忽略可能存在的别名设置总是一个不错的安全实践。因为攻击者可能已经将一些别有用心的命令利用别名伪装成了特权命令，借此来盗取用户输入的重要信息。

1.9 获取终端信息

编写命令行shell脚本时，总是免不了大量处理当前终端的相关信息，比如行数、列数、光标位置、密码字段等。这则攻略将帮助你学习如何采集和处理终端设置。

1.9.1 预备知识

tput和stty是两款终端处理工具。下面来看看如何用它们完成各种不同的任务。

1.9.2 实战演练

- 获取终端的行数和列数：

```
tput cols
tput lines
```

- 打印出当前终端名：

```
tput longname
```

- 将光标移动到坐标(100,100)处：

```
tput cup 100 100
```

- 设置终端背景色：

```
tputsetb n
```

其中，n可以在0到7之间取值。

- 设置文本前景色：

```
tputsetf n
```

其中，n可以在0到7之间取值。

- 设置文本样式为粗体：

```
tput bold
```

- 设置下划线的起止：

```
tput smul
tput rmul
```

- 删除从当前光标位置到行尾的所有内容：

```
tputed
```

- 在输入密码时，不应该显示输入内容。在下面的例子中，我们将看到如何使用stty来实现这一要求：

```
#!/bin/sh
#Filename: password.sh
echo -e "Enter password: "
stty -echo
read password
stty echo
echo
echo Password read.
```

选项-echo禁止将输出发送到终端，而选项echo则允许发送输出。

1.10　获取、设置日期和延时

很多应用程序需要以不同的格式打印日期、设置日期和时间、根据日期和时间执行操作。延时通常用于在程序执行过程中提供一段等待时间（比如1秒）。例如需要在脚本中对某项任务每隔5秒监视一次，就需要知道如何在程序中加入延时。这则攻略会告诉你怎么处理日期以及延时。

1.10.1　预备知识

我们能够以多种格式打印日期，也可以在命令行中设置日期。在类Unix系统中，日期被存储成一个整数，其大小为自**世界标准时间**（UTC）[①]1970年1月1日0时0分0秒[②]起所流逝的秒数。这种计时方式称为**纪元时**或**Unix时间**。来看看对其进行读取和设置的方式。

1.10.2　实战演练

可以使用不同的格式来读取、设置日期。实现步骤如下所示。

(1) 读取日期：

```
$ date
Thu May 20 23:09:04 IST 2010
```

(2) 打印纪元时：

```
$ date +%s
1290047248
```

① UTC（Coordinated Universal Time），又称世界标准时间或世界协调时间。UTC是以原子时秒长为基础，在时刻上尽量接近于世界时的一种时间计量系统。

② Unix认为UTC 1970年1月1日0点是纪元时间。POSIX标准推出后，这个时间也被称为POSIX时间。

我们可以从给定格式的日期串中得出对应的纪年时。在输入时有多种日期格式可供选择。如果要从系统日志中或者其他标准应用程序生成的输出中获取日期，那就完全不用烦心日期串格式的问题。要将日期串转换成纪元时，只需要这样即可实现：

```
$ date --date "Thu Nov 18 08:07:21 IST 2010" +%s
1290047841
```

选项--date用于提供日期串作为输入。但我们可以使用任意的日期格式化选项来打印输出。将日期串作为输入能够用来获知给定的日期是星期几。

例如：

```
$ date --date "Jan 20 2001" +%A
Saturday
```

表1-1是一份日期格式字符串列表。

(3) 用格式串结合 + 作为date命令的参数，可以按照你的选择打印出对应格式的日期。例如：

```
$ date "+%d %B %Y"
20 May 2010
```

(4) 设置日期和时间：

```
# date -s "格式化的日期字符串"
```

例如：

```
# date -s "21 June 2009 11:01:22"
```

(5) 有时候，我们需要检查一组命令所花费的时间，可以使用以下代码：

```
#!/bin/bash
#文件名: time_take.sh
start=$(date +%s)
commands;
statements;

end=$(date +%s)
difference=$(( end - start))
echo Time taken to execute commands is $difference seconds.
```

另一种方法则是使用time<scriptpath>来得到执行脚本所花费的时间。

1.10.3　工作原理

纪元时被定义为从**世界标准时间**1970年1月1日0时0分0秒起至当前时刻的总秒数，不包括闰秒[①]。当计算两个日期或两段时间的差值时，纪元时很有用处。你可以得出两个特定时间戳的纪元时间，并计算出两者之间的差值，由此就能知道两个日期之间相隔了多少秒。

利用日期格式来获得所需要的输出，可以参考表1-1。

表　1-1

日期内容	格　　式
星期	%a（例如：Sat） %A（例如：Saturday）
月	%b（例如：Nov） %B（例如：November）
日	%d（例如：31）
固定格式日期（mm/dd/yy）	%D（例如：10/18/10）
年	%y（例如：10） %Y（例如：2010）
小时	%I或%H（例如：08）
分钟	%M（例如：33）
秒	%S（例如：10）
纳秒	%N（例如：695208515）
Unix纪元时（以秒为单位）	%s（例如：1290049486）

1.10.4　补充内容

编写以循环方式运行的监视脚本时,设置时间间隔是必不可少的。让我们来看看如何生成延时。

在脚本中生成延时

为了在脚本中推迟执行一段时间，可以使用sleep：$ sleep no_of_seconds.例如，下面的脚本就使用tput和sleep从0开始计数到40：

```
#!/bin/bash
#文件名: sleep.sh
echo -n Count:
tput sc

count=0;
while true;
```

```
do
    if [ $count -lt 40 ];
    then
        let count++;
        sleep 1;
        tput rc
        tput ed
        echo -n $count;
    else exit 0;
    fi
done
```

在上面的例子中，变量count初始化为0，随后每循环一次便增加1。echo语句打印出count的值。我们用tput sc存储光标位置。在每次循环中，通过恢复之前存储的光标位置，在终端中打印出新的count值。恢复光标位置的命令是tput rc。tput ed清除从当前光标位置到行尾之间的所有内容，使得旧的count值可以被清除并写入新值。循环内的1秒钟延时是通过sleep命令来实现的。

1.11 调试脚本

调试功能是每一种编程语言都应该实现的重要特性之一，当出现一些始料未及的情况时，用它来生成脚本运行信息。调试信息可以帮你弄清楚是什么原因使得程序发生崩溃或行为异常。每位系统程序员都应该了解Bash提供的调试选项。

1.11.1 实战演练

我们可以利用Bash内建的调试工具，或者按照易于调试的方式编写脚本，方法如下所示。

(1) 使用选项-x，启用shell脚本的跟踪调试功能：

```
$ bash -x script.sh
```

运行带有-x标志的脚本可以打印出所执行的每一行命令以及当前状态。注意，你也可以使用sh -x script。

(2) 使用set -x和set +x对脚本进行部分调试。例如：

```
#!/bin/bash
#文件名: debug.sh
for i in {1..6};
do
    set -x
    echo $i
    set +x
```

```
done
echo "Script executed"
```

在上面的脚本中，只会打印出echo $i的调试信息，因为使用了-x和+x对调试区域进行了限制。

(3) 前面介绍的调试手段是Bash内建的。它们通常以固定的格式生成调试信息。但是在很多情况下，我们需要以自定义格式显示调试信息。这可以通过传递 _DEBUG环境变量来建立这类调试风格。

请看下面的代码：

```
#!/bin/bash
function DEBUG()
{
    [ "$_DEBUG" == "on" ] && $@ || :
}
for i in {1..10}
do
    DEBUG echo $i
done
```

可以将调试功能置为"on"来运行上面的脚本：

```
$ _DEBUG=on ./script.sh
```

我们在每一个需要打印调试信息的语句前加上DEBUG。如果没有把 _DEBUG=on传递给脚本，那么调试信息就不会打印出来。在Bash中，命令“:”告诉shell不要进行任何操作。

1.11.2　工作原理

-x标识将脚本中执行过的每一行都输出到stdout。不过，我们也可能只关注脚本某些部分的命令及参数的打印输出。针对这种情况，可以在脚本中使用set builtin来启用或禁止调试打印。

- set -x：在执行时显示参数和命令。
- set +x：禁止调试。
- set -v：当命令进行读取时显示输入。
- set +v：禁止打印输入。

1.11.3　补充内容

还有其他脚本调试的便捷方法，我们甚至可以巧妙地利用shebang来进行调试。

shebang的妙用

把shebang从#!/bin/bash改成 #!/bin/bash -xv，这样一来，不用任何其他选项就可以启用调试功能了。

1.12 函数和参数

和其他脚本语言一样，Bash同样支持函数。让我们看看它是如何定义和使用函数的。

1.12.1 实战演练

我们可以创建执行特定任务的函数，也可以创建能够接受参数的函数。方法如下所示。

(1) 定义函数：

```
function fname()
{
    statements;
}
```

或者：

```
fname()
{
    statements;
}
```

(2) 只需要使用函数名就可以调用某个函数：

```
$ fname ; #执行函数
```

(3) 参数可以传递给函数，并由脚本进行访问：

```
fname arg1 arg2 ; #传递参数
```

以下是函数fname的定义。在函数fname中，包含了各种访问函数参数的方法。

```
fname()
{
  echo $1, $2; #访问参数1和参数2
  echo "$@";#以列表的方式一次性打印所有参数
  echo "$*"; #类似于$@, 但是参数被作为单个实体
  return 0; #返回值
}
```

类似地，参数可以传递给脚本并通过script:$0（脚本名）访问。

- $1是第一个参数。
- $2是第二个参数。
- $n是第*n*个参数。
- "$@" 被扩展成 "$1" "$2" "$3"等。
- "$*" 被扩展成 "$1c$2c$3"，其中c是IFS的第一个字符。
- "$@" 要比"$*"用得多。由于 "$*"将所有的参数当做单个字符串，因此它很少被使用。

1.12.2　补充内容

让我们再研究一些Bash函数的技巧。

1. 递归函数

在Bash中，函数同样支持递归（可以调用自身的函数）。例如，`F() { echo $1; F hello; sleep 1; }`。

> **Fork炸弹**
>
> ```
> :(){ :|:& };:
> ```
>
> 
>
> 这个递归函数能够调用自身，不断地生成新的进程，最终造成拒绝服务攻击。函数调用前的 & 将子进程放入后台。这段危险的代码会分支出大量的进程，因而称为Fork炸弹。
>
> 上面这段代码要理解起来可不容易。请参阅维基百科http://en.wikipedia.org/wiki/Fork_bomb，那里列出了有关Fork炸弹的细节以及更详细的解释。
>
> 可以通过修改配置文件/etc/security/limits.conf来限制可生成的最大进程数来避开这枚炸弹。

2. 导出函数

函数也能像环境变量一样用export导出，如此一来，函数的作用域就可以扩展到子进程中，例如：

```
export -f fname
```

3. 读取命令返回值（状态）

我们可以按照下面的方式获取命令或函数的返回值：

```
cmd;
echo $?;
```

$? 会给出命令cmd的返回值。

返回值被称为**退出状态**。它可用于分析命令执行成功与否。如果命令成功退出，那么退出状态为0，否则为非0。

我们可以按照下面的方法检测某个命令是否成功结束：

```
#!/bin/bash
#文件名: success_test.sh
CMD="command" #command指代你要检测退出状态的目标命令
$CMD
if [ $? -eq 0 ];
then
    echo "$CMD executed successfully"
else
    echo "$CMD terminated unsuccessfully"
fi
```

4. 向命令传递参数

命令的参数能够以不同的格式进行传递。假设-p、-v是可用选项，-k N是另一个可以接受数字的选项，同时该命令还接受一个文件名作为参数，那么，它有如下几种执行方式：

- $ command -p -v -k 1 file
- $ command -pv -k 1 file
- $ command -vpk 1 file
- $ command file -pvk 1

1.13 将命令序列的输出读入变量

shell脚本最棒的特性之一就是可以轻松地将多个命令或工具组合起来生成输出。一个命令的输出可以作为另一个命令的输入，而这个命令的输出又会传递至另一个命令，依次类推。这种命令组合的输出可以被存储在一个变量中。这则攻略将演示如何组合多个命令以及如何读取其输出。

1.13.1 预备知识

输入通常是通过stdin或参数传递给命令。输出要么出现在stderr，要么出现在stdout。当我们组合多个命令时，通常将stdin用于输入，stdout用于输出。

此时，这些命令被称为**过滤器**（filter）。我们使用管道（pipe）连接每个过滤器。管道操作符是|。例如：

```
$ cmd1 | cmd2 | cmd3
```

这里我们组合了3个命令。cmd1的输出传递给cmd2，而cmd2的输出传递给cmd3，最终的输出（来自cmd3）将会被打印或导入某个文件。

1.13.2　实战演练

我们通常使用管道并利用子shell的方式将多个文件的输出组合起来。方法如下所示。

(1) 先从组合两个命令开始：

```
$ ls | cat -n > out.txt
```

ls的输出（当前目录内容的列表）被传给cat -n，后者将通过stdin所接收到输入内容加上行号，然后将输出重定向到文件out.txt。

(2) 我们可以用下面的方法读取由管道相连的命令序列的输出：

```
cmd_output=$(COMMANDS)
```

这种方法被称为**子shell**。例如：

```
cmd_output=$(ls | cat -n)
echo $cmd_output
```

另一种被称为**反引用**（有些人们也称它为**反标记**）的方法也可以用于存储命令输出：

```
cmd_output=`COMMANDS`
```

例如：

```
cmd_output=`ls | cat -n`
echo $cmd_output
```

反引用与单引号可不是一回事，它位于键盘的~键上。

1.13.3　补充内容

有很多种方法可以给命令分组。来看看其中的几种。

1. 利用子shell生成一个独立的进程

子shell本身就是独立的进程。可以使用()操作符来定义一个子shell：

```
pwd;
(cd /bin; ls);
pwd;
```

当命令在子shell中执行时，不会对当前shell有任何影响；所有的改变仅限于子shell内。例如，当用cd命令改变子shell的当前目录时，这种变化不会反映到主shell环境中。

pwd命令打印出工作目录的路径。

cd命令将当前目录更改为给定的目录路径。

2. 通过引用子shell的方式保留空格和换行符

假设我们使用子shell或反引用的方法将命令的输出读入一个变量中，可以将它放入双引号中，以保留空格和换行符（\n）。例如：

```
$ cat text.txt
1
2
3

$ out=$(cat text.txt)
$ echo $out
1 2 3 # Lost \n spacing in 1,2,3

$ out="$(cat tex.txt)"
$ echo$out
1
2
3
```

1.14 不使用回车键来读取 *n* 个字符

read是一个重要的Bash命令，它用于从键盘或标准输入中读取文本。我们可以使用read以交互的形式读取来自用户的输入，不过read能做的可远不止这些。任何编程语言的输入库大多都是从键盘读取输入；但只有当回车键按下的时候，才标志着输入完毕。在有些重要情形下是没法按回车键的，输入结束与否是基于字符数或某个特定字符来决定的。例如，在一个游戏中，当按下 + 键时，小球就会向上移动。那么若每次都要按下 + 键，然后再按回车键来确认已经按过 + 键，这就显然太低效了。read命令提供了一种不需要按回车键就能够搞定这个任务的方法。

实战演练

你可以借助read命令的各种选项来实现不同的效果。方法如下所示。

(1) 下面的语句从输入中读取*n*个字符并存入变量variable_name：

```
read -n number_of_chars variable_name
```

例如：

```
$ read -n 2 var
$ echo $var
```

(2) 用无回显的方式读取密码：

```
read -s var
```

(3) 显示提示信息：

```
read -p "Enter input:"  var
```

(4) 在特定时限内读取输入：

```
read -t timeout var
```

例如：

```
$ read -t 2 var
#在2秒内将键入的字符串读入变量var
```

(5) 用特定的定界符作为输入行的结束：

```
read -d delim_char var
```

例如：

```
$ read -d ":" var
hello:#var 被设置为 hello
```

1.15　运行命令直至执行成功

在日常工作中使用shell时，有时候命令只有满足某些条件或是某种外部事件（例如文件可以被下载）操作才能够成功执行。这种情况下，你可能希望重复执行命令，直到成功为止。

1.15.1　实战演练

按照以下方式定义函数：

```
repeat()
{
  while true
  do
    $@ && return
  done
}
```

或者把它放入shell的rc文件，更便于使用：

```
repeat() { while true; do $@ && return; done }
```

1.15.2 工作原理

我们创建了函数repeat，它包含了一个无限while循环，该循环执行以参数形式（通过$@访问）传入函数的命令。如果命令执行成功，则返回，进而退出循环。

1.15.3 补充内容

我们已经看过了用于重复执行命令，直到其执行成功的基本做法。接着来看看更高效的方式。

1. 一种更快的做法

在大多数现代系统中，true是作为/bin中的一个二进制文件来实现的。这就意味着每执行一次while循环，shell就不得不生成一个进程。如果不想这样，可以使用shell内建的“:”命令，它总是会返回为0的退出码：

```
repeat() { while :; do $@ && return; done }
```

尽管可读性不高，但是肯定比第一种方法快。

2. 增加延时

假设你要用repeat()从Internet上下载一个暂时不可用的文件，不过这个文件只需要等一会就能下载。方法如下：

```
repeat wget -c http://www.example.com/software-0.1.tar.gz
```

如果采用这种形式，需要向www.example.com发送很多数据，有可能会对服务器产生影响。（甚至也会给你造成麻烦，如果服务器认为你是在发送垃圾信息，就可能把你列入黑名单。）要解决这个问题，我们可以修改函数，加入一段短暂的延时：

```
repeat() { while :; do $@ && return; sleep 30; done }
```

这使得命令每30秒运行一次。

1.16 字段分隔符和迭代器

内部字段分隔符（Internal Field Separator，IFS）是shell脚本编程中的一个重要概念。在处理文本数据时，它的用途可不小。我们将会讨论把单个数据流划分成不同数据元素的定界符（delimiter）。内部字段分隔符是用于特定用途的定界符。IFS是存储定界符的环境变量。它是当前shell环境使用的默认定界字符串。

考虑一种情形：我们需要迭代一个字符串或**逗号分隔型数值**（Comma Separated Value，CSV）中的单词。如果是前一种，则使用IFS="."；如果是后一种，则使用IFS=","。接下来看看具体的做法。

1.16.1　预备知识

考虑CSV数据的情况：

```
data="name,sex,rollno,location"
```

我们可以使用IFS读取变量中的每一个条目。

```
oldIFS=$IFS
IFS=, now,
for item in $data;
do
    echo Item: $item
done

IFS=$oldIFS
```

输出如下：

```
Item: name
Item: sex
Item: rollno
Item: location
```

IFS的默认值为空白字符（换行符、制表符或者空格）。

当IFS被设置为逗号时，shell将逗号视为一个定界符，因此变量`$item`在每次迭代中读取由逗号分隔的子串作为变量值。

如果没有把IFS设置成逗号，那么上面的脚本会将全部数据作为单个字符串打印出来。

1.16.2　实战演练

让我们以/etc/passwd为例，看看IFS的另一种用法。在文件/etc/passwd中，每一行包含了由冒号分隔的多个条目。文件中的每行都对应一位用户的相关属性。

考虑这样的输入：`root:x:0:0:root:/root:/bin/bash`。每行的最后一项指定了用户的默认shell。可以按照下面的方法巧妙地利用IFS打印出用户以及他们默认的shell：

```
#!/bin/bash
#用途: 演示IFS的用法
line="root:x:0:0:root:/root:/bin/bash"
oldIFS=$IFS;
IFS=":"
count=0
for item in $line;
do
```

```
    [ $count -eq 0 ]  && user=$item;
    [ $count -eq 6 ]  && shell=$item;
   let count++
done;
IFS=$oldIFS
echo $user\'s shell is $shell;
```

输出为：

```
root's shell is /bin/bash
```

对一系列值进行迭代时，循环非常有用。Bash提供了多种类型的循环。下面就来看看怎么样使用它们。

- for循环

```
for var in list;
do
    commands; #使用变量$var
done
```

list可以是一个字符串，也可以是一个序列。

我们可以轻松地生成不同的序列。

echo {1..50}能够生成一个从1~50的数字列表。echo {a..z}或{A..Z}或{a..h}可以生成字母列表。同样，我们可以将这些方法结合起来对数据进行拼接（concatenate）。下面的代码中，变量i在每次迭代的过程里都会保存一个字符，范围从a~z：

```
for i in {a..z}; do actions; done;
```

for循环也可以采用C语言中for循环的格式。例如：

```
for((i=0;i<10;i++))
{
    commands; #使用变量$i
}
```

- while循环

```
while condition
do
    commands;
done
```

用true作为循环条件能够产生无限循环。

- until循环

在Bash中还可以使用一个特殊的循环until。它会一直执行循环，直到给定的条件为真。

例如：

```
x=0;
until [ $x -eq 9 ]; #条件是[$x -eq 9 ]
do
    let x++; echo $x;
done
```

1.17　比较与测试

程序中的流程控制是由比较语句和测试语句处理的。Bash同样具备多种与Unix系统级特性相兼容的执行测试的方法。我们可以用if、if else以及逻辑运算符进行测试，用比较运算符来比较数据项。除此之外，还有一个test命令也可以用于测试。这些命令的用法如下。

实战演练

来看看用于比较和测试的各种方法：

- if条件

```
if condition;
then
    commands;
fi
```

- else if和else

```
if condition;
then
    commands;
else if condition; then
    commands;
else
    commands;
fi
```

if和else语句可以进行嵌套。if的条件判断部分可能会变得很长，但可以用逻辑运算符将它变得简洁一些：

- [condition] && action; # 如果condition为真，则执行action；
- [condition] || action; # 如果condition为假，则执行action。

&&是逻辑与运算符，||是逻辑或运算符。编写Bash脚本时，这是一个很有用的技巧。现在来了解一下条件和比较操作。

❑ 算术比较

条件通常被放置在封闭的中括号内。一定要注意在[或]与操作数之间有一个空格。如果忘记了这个空格，脚本就会报错。例如：

```
[$var -eq 0 ] or [ $var -eq 0]
```

对变量或值进行算术条件判断：

```
[ $var -eq 0 ]  #当 $var 等于 0 时，返回真
[ $var -ne 0 ] #当 $var 为非 0 时，返回真
```

其他重要的操作符如下所示。

- -gt：大于。
- -lt：小于。
- -ge：大于或等于。
- -le：小于或等于。

可以按照下面的方法结合多个条件进行测试：

```
[ $var1 -ne 0 -a $var2 -gt 2 ]  #使用逻辑与-a
[ $var1 -ne 0 -o var2 -gt 2 ] #逻辑或 -o
```

❑ 文件系统相关测试

我们可以使用不同的条件标志测试不同的文件系统相关的属性。

- [-f $file_var]：如果给定的变量包含正常的文件路径或文件名，则返回真。
- [-x $var]：如果给定的变量包含的文件可执行，则返回真。
- [-d $var]：如果给定的变量包含的是目录，则返回真。
- [-e $var]：如果给定的变量包含的文件存在，则返回真。
- [-c $var]：如果给定的变量包含的是一个字符设备文件的路径，则返回真。
- [-b $var]：如果给定的变量包含的是一个块设备文件的路径，则返回真。
- [-w $var]：如果给定的变量包含的文件可写，则返回真。
- [-r $var]：如果给定的变量包含的文件可读，则返回真。
- [-L $var]：如果给定的变量包含的是一个符号链接，则返回真。

使用方法如下：

```
fpath="/etc/passwd"
if [ -e $fpath ]; then
    echo File exists;
else
    echo Does not exist;
fi
```

❑ 字符串比较

使用字符串比较时，最好用双中括号，因为有时候采用单个中括号会产生错误，所以最好避开它们。

可以用下面的方法检查两个字符串，看看它们是否相同。

- `[[ $str1 = $str2 ]]`：当str1等于str2时，返回真。也就是说，str1和str2包含的文本是一模一样的。
- `[[ $str1 == $str2 ]]`：这是检查字符串是否相等的另一种写法。

也可以检查两个字符串是否不同。

- `[[ $str1 != $str2 ]]`：如果str1和str2不相同，则返回真。

我们还可以检查字符串的字母序情况，具体如下所示。

- `[[ $str1 > $str2 ]]`：如果str1的字母序比str2大，则返回真。
- `[[ $str1 < $str2 ]]`：如果str1的字母序比str2小，则返回真。
- `[[ -z $str1 ]]`：如果str1包含的是空字符串，则返回真。
- `[[ -n $str1 ]]`：如果str1包含的是非空字符串，则返回真。

注意在= 前后各有一个空格。如果忘记加空格，那就不是比较关系了，而变成了赋值语句。

使用逻辑运算符 && 和 || 能够很容易地将多个条件组合起来：

```
if [[ -n $str1 ]] && [[ -z $str2 ]] ;
then
    commands;
fi
```

例如：

```
str1="Not empty "
str2=""
if [[ -n $str1 ]] && [[ -z $str2 ]];
then
    echo str1 is nonempty and str2 is empty string.
fi
```

输出如下：

```
str1 is nonempty and str2 is empty string.
```

test命令可以用来执行条件检测。用test可以避免使用过多的括号。之前讲过的[]中的测试条件同样可以用于test命令。

例如：

```
if  [ $var -eq 0 ]; then echo "True"; fi
```

也可以写成：

```
if  test $var -eq 0 ; then echo "True"; fi
```

第 2 章

命令之乐

2

本章内容

- 用cat进行拼接
- 录制与回放终端会话
- 文件查找与文件列表
- 玩转xargs
- 用tr进行转换
- 校验和与核实
- 加密工具与散列
- 排序、单一与重复
- 临时文件命名与随机数
- 分割文件和数据
- 根据扩展名切分文件名
- 用rename和mv批量重命名文件
- 拼写检查与词典操作
- 交互输入自动化
- 利用并行进程加速命令执行

2.1 简介

类Unix系统享有最棒的命令行工具。它们帮助我们完成各类任务，使我们的工作变得更轻松。尽管这些命令各有侧重，在实践中你可以通过结合多个命令来解决复杂的问题。一些经常用到的命令是grep、awk、sed和find。

掌握Unix/Linux命令行可谓是一门艺术。实践得越多，收益就越大。本章将为你介绍一些最有趣同时也是最实用的命令。

2.2 用 cat 进行拼接

cat是命令行玩家首先必须学习的命令之一。它通常用于读取、显示或拼接文件内容，不过cat的能力远不止如此。用一行命令将来自标准输入以及文件的数据给组合起来，这可是个让人挠头的难题。通常的做法是将stdin重定向到一个文件，然后再将两个文件组合到一起。不过我们可以使用cat命令一次性搞定。接下来你会看到cat的基本用法和高级用法。

2.2.1 实战演练

cat命令是一个平日里经常会使用到的简单命令。它本身表示concatenate（拼接）。

用cat读取文件内容的一般写法是：

```
$ cat file1 file2 file3 ...
```

这个命令将作为命令行参数的文件内容拼接在一起。

- 打印单个文件的内容：

```
$ cat file.txt
This is a line inside file.txt
This is the second line inside file.txt
```

- 打印多个文件的内容：

```
$ cat one.txt two.txt
This is line from one.txt
This is line from two.txt
```

2.2.2 工作原理

cat的用法多种多样。让我们来看看其中的一些。

cat命令不仅可以读取文件、拼接数据，还能够从标准输入中进行读取。

从标准输入中读取需要使用管道操作符：

```
OUTPUT_FROM_SOME COMMANDS | cat
```

类似地，我们可以用cat将来自输入文件的内容与标准输入拼接在一起，将stdin和另一个文件中的数据结合起来。方法如下：

```
$ echo 'Text through stdin' | cat - file.txt
```

在上面的代码中，-被作为stdin文本的文件名。

2.2.3 补充内容

cat命令还有一些用于文件查看的选项。来看看它们的用法。

1. 摆脱多余的空白行

有时候文本文件中可能包含多处连续的空白行。如果你需要删除这些额外的空白行，使用下面的方法：

```
$ cat -s file
```

例如:

```
$ cat multi_blanks.txt
line 1



line2

line3


line4

$ cat -s multi_blanks.txt #压缩相邻的空白行
line 1

line2

line3

line4
```

另外，也可以用tr删除所有的z空白行，我们会在2.6节详细讨论。

2. 将制表符显示为^|

单从视觉上很难将制表符同连续的空格区分开。而在用Python编写程序时，用于代码缩进的制表符以及空格是具有特殊含义的。因此，若在应该使用空格的地方误用了制表符的话，就会产生缩进错误。仅仅在文本编辑器中进行观察是很难发现这种错误的。cat有一个特性，可以将制表符着重标记出来。该特性对排除缩进错误非常有用。用cat命令的 -T选项能够将制表符标记成 ^|。例如:

```
$ cat file.py
def function():
    var = 5
        next = 6
    third = 7

$ cat -T file.py
def function():
^Ivar = 5
        next = 6
^Ithird = 7^I
```

3. 行号

使用cat命令的-n选项会在输出的每一行内容之前加上行号。别担心，cat命令绝不会修改你的文件，它只是根据用户提供的选项在stdout中生成一个修改过的输出而已。例如：

```
$ cat lines.txt
line
line
line

$ cat -n lines.txt
     1 line
     2 line
     3 line
```

-n甚至会为空白行加上行号。如果你想跳过空白行，那么可以使用选项-b。

2.3 录制并回放终端会话

当你需要为别人在终端上演示某些操作或是需要准备一个命令行教程时，通常得一边手动输入命令一边演示，或者也可以录制一段屏幕演示视频，然后再回放出来。其实也有其他的实现方法。利用script和scriptreplay命令，我们可以录制命令的次序以及时序，将相关数据记录在文本文件中。利用这些文件，其他人可以在终端上回放并查看命令的输出。

2.3.1 预备知识

script和scirptreplay命令在绝大多数GNU/Linux发行版上都可以找到。把终端会话记录到一个文件中挺好玩的。你可以通过录制终端会话来制作命令行教学视频教程，也可以与他人分享会话记录文件，共同研究如何使用命令行完成某项任务。

2.3.2 实战演练

开始录制终端会话：

```
$ script -t 2> timing.log -a output.session
type commands;
…
..
exit
```

注意，对于不支持单独将stderr重定向到文件的shell（比如csh shell），这则攻略是没法使用的。

两个配置文件被当做script命令的参数。其中一个文件（timing.log）用于存储时序信息，描述每一个命令在何时运行；另一个文件（output.session）用于存储命令输出。-t选项用于将时序数据导入stderr。2>则用于将stderr重定向到timing.log。

利用这两个文件：timing.log（存储时序信息）和output.session（存储命令输出信息），我们可以按照下面的方法回放命令执行过程：

```
$ scriptreplay timing.log output.session
# 按播放命令序列输出
```

2.3.3　工作原理

通常，我们会录制桌面环境视频来作为教程使用。但是视频需要大量的存储空间，而终端脚本文件仅仅是一个文本文件，其文件大小不过是KB级别。

你可以把timing.log和output.session文件分享给任何想在自己的终端上回放这段终端会话的人。

2.4　文件查找与文件列表

find是Unix/Linux命令行工具箱中最棒的工具之一。该命令对于编写shell脚本所起到的功用不可小视，但是多数人却无法最大程度发挥它的功效。这则攻略讨论了find的大多数常见用法。

2.4.1　预备知识

find命令的工作方式如下：沿着文件层次结构向下遍历，匹配符合条件的文件，执行相应的操作。下面来看看find命令的各种应用场景和基本用法。

2.4.2　实战演练

要列出当前目录及子目录下所有的文件和文件夹，可以采用下面的写法：

```
$ find base_path
```

bash_path可以放在任意位置（例如 /home/slynux），find会从该位置开始向下查找。

例如：

```
$ find . -print
# 打印文件和目录的列表
```

. 指定当前目录，.. 指定父目录。这是Unix文件系统中的约定用法。

-print指明打印出匹配文件的文件名（路径）。当使用 -print时，'\n'作为用于对输出的文件名进行分隔。就算你忽略-print，find命令仍会打印出文件名。

-print0指明使用'\0'作为匹配的文件名之间的定界符。当文件名中包含换行符时，这个方法就有用武之地了。

2.4.3 补充内容

至此，我们已经学习了find命令最常见的用法。作为一款强大的命令行工具，find命令包含了诸多值得一提的选项。接下来看看find命令的其他功能。

1. 根据文件名或正则表达式进行搜索

选项-name的参数指定了文件名所必须匹配的字符串。我们可以将通配符作为参数使用。*.txt能够匹配所有以.txt结尾的文件名。选项 -print在终端中打印出符合条件（例如 -name）的文件名或文件路径，这些匹配条件通过find命令的选项给出。

```
$ find /home/slynux -name "*.txt" -print
```

find命令有一个选项 -iname（忽略字母大小写），该选项的作用和 -name类似，只不过在匹配名字时会忽略大小写。

例如：

```
$ ls
example.txt  EXAMPLE.txt  file.txt
$ find . -iname "example*" -print
./example.txt
./EXAMPLE.txt
```

如果想匹配多个条件中的一个，可以采用OR条件操作：

```
$ ls
new.txt  some.jpg  text.pdf
$ find . \( -name "*.txt" -o -name "*.pdf" \) -print
./text.pdf
./new.txt
```

上面的代码会打印出所有的.txt和.pdf文件，是因为这个find命令能够匹配所有这两类文件。\(以及\)用于将 -name "*.txt" -o -name "*.pdf"视为一个整体。

选项-path的参数可以使用通配符来匹配文件路径。-name总是用给定的文件名进行匹配。-path则将文件路径作为一个整体进行匹配。例如：

```
$ find /home/users -path "*/slynux/*" -print
```

这会匹配以下路径：

```
/home/users/list/slynux.txt
/home/users/slynux/eg.css
```

选项-regex的参数和-path的类似，只不过-regex是基于正则表达式来匹配文件路径的。

正则表达式是通配符匹配的高级形式，它可以指定文本模式。我们借助这种模式来匹配文本及进行打印。使用正则表达式进行文本匹配的一个典型例子就是从一堆文本中解析出所有的E-mail地址。E-mail地址通常采用name@host.root这种形式，所以可以将其一般化为[a-z0-9]+@[a-z0-9]+.[a-z0-9]+。符号+ 指明在它之前的字符类中的字符可以出现一次或多次。

下面的命令匹配.py或.sh文件：

```
$ ls
new.PY  next.jpg  test.py
$ find . -regex ".*\(\.py\|\.sh\)$"
./test.py
```

类似地，-iregex可以让正则表达式忽略大小写。例如：

```
$ find . -iregex ".*\(\.py\|\.sh\)$"
./test.py
./new.PY
```

我们会在第4章学习到更多有关正则表达式的内容。

2. 否定参数

find也可以用“!”否定参数的含义。例如：

```
$ find . ! -name "*.txt" -print
```

上面的find命令能够匹配所有不以.txt结尾的文件名。下面就是这个命令的运行结果：

```
$ ls
list.txt  new.PY  new.txt  next.jpg  test.py

$ find . ! -name "*.txt" -print
.
./next.jpg
```

```
./test.py
./new.PY
```

3. 基于目录深度的搜索

find命令在使用时会遍历所有的子目录。我们可以采用深度选项-maxdepth和 -mindepth来限制find命令遍历的目录深度。

大多数情况下，我们只需要在当前目录中进行搜索，无须再继续向下查找。对于这种情况，我们使用深度选项来限制find命令向下查找的深度。如果只允许find在当前目录中查找，深度可以设置为1；当需要向下两级时，深度可以设置为2；其他情况可以依次类推。

可以用-maxzdepth指定最大深度。与此相似，我们也可以指定一个最小的深度，告诉find应该从此处开始向下查找。如果我们想从第二级目录开始搜索，那么就使用 -mindepth设置最小深度。使用下列命令将find命令向下的最大深度限制为1：

```
$ find . -maxdepth 1 -name "f*" -print
```

该命令列出当前目录下的所有文件名以f打头的文件。即使有子目录，也不会被打印或遍历。与之类似，-maxdepth 2最多向下遍历两级子目录。

-mindepth类似于 -maxdepth，不过它设置的是find开始遍历的最小深度。这个选项可以用来查找并打印那些距离起始路径一定深度的所有文件。例如，打印出深度距离当前目录至少两个子目录的所有文件：

```
$ find . -mindepth 2 -name "f*" -print
./dir1/dir2/file1
./dir3/dir4/f2
```

即使当前目录或dir1和dir3中包含有文件，它们也不会被打印出来。

-maxdepth和-mindepth应该作为find的第三个参数出现。如果作为第4个或之后的参数，就可能会影响到find的效率，因为它不得不进行一些不必要的检查。例如，如果-maxdepth作为第四个参数，-type作为第三个参数，find首先会找出符合-type的所有文件，然后在所有匹配的文件中再找出符合指定深度的那些。但是如果反过来，目录深度作为第三个参数，-type作为第四个参数，那么find就能够在找到所有符合指定深度的文件后，再检查这些文件的类型，这才是最有效的搜索之道。

4. 根据文件类型搜索

Unix类系统将一切都视为文件。文件具有不同的类型，例如普通文件、目录、字符设备、块设备、符号链接、硬链接、套接字以及FIFO等。

-type可以对文件搜索进行过滤。借助这个选项，我们可以为find命令指明特定的文件匹配类型。

只列出所有的目录：

```
$ find . -type d -print
```

将文件和目录分别列出可不是个容易事。不过有了find就好办了。例如，只列出普通文件：

```
$ find . -type f -print
```

只列出符号链接：

```
$ find . -type l -print
```

你可以按照表2-1列出的内容用type参数来匹配所需要的文件类型。

表　2-1

文件类型	类型参数
普通文件	f
符号链接	l
目录	d
字符设备	c
块设备	b
套接字	s
FIFO	p

5. 根据文件时间进行搜索

Unix/Linux文件系统中的每一个文件都有三种时间戳，如下所示。

- **访问时间**（-atime）：用户最近一次访问文件的时间。
- **修改时间**（-mtime）：文件内容最后一次被修改的时间。
- **变化时间**（-ctime）：文件元数据（例如权限或所有权）最后一次改变的时间。

在Unix中并没有所谓“创建时间”的概念。

-atime、-mtime、-ctime可作为find的时间选项。它们可以用整数值指定，单位是天。这些整数值通常还带有 - 或 + ：- 表示小于，+ 表示大于。

- 打印出在最近7天内被访问过的所有文件：

```
$ find . -type f -atime -7 -print
```

- 打印出恰好在7天前被访问过的所有文件：

```
$ find . -type f -atime 7 -print
```

- 打印出访问时间超过7天的所有文件：

```
$ find . -type f -atime +7 -print
```


类似地，我们可以根据修改时间，用-mtime进行搜索，也可以根据变化时间，用-ctime进行搜索。

-atime、-mtime以及-ctime都是基于时间的参数，其计量单位是“天”。还有其他一些基于时间的参数是以分钟作为计量单位的。这些参数包括：

- -amin（访问时间）；
- -mmin（修改时间）；
- -cmin（变化时间）。

举例如下。

打印出访问时间超过7分钟的所有文件：

```
$ find . -type f -amin +7 -print
```

find另一个漂亮的特性是 -newer参数。使用 -newer，我们可以指定一个用于比较时间戳的参考文件，然后找出比参考文件更新的（更近的修改时间）所有文件。

例如，找出比file.txt修改时间更近的所有文件：

```
$ find . -type f -newer file.txt -print
```

find命令的时间戳处理选项对编写系统备份和维护脚本很有帮助。

6. 基于文件大小的搜索

根据文件的大小，可以这样搜索：

```
$ find . -type f -size +2k
# 大于2KB的文件

$ find . -type f -size -2k
# 小于2KB的文件

$ find . -type f -size 2k
# 大小等于2KB的文件
```

除了k之外，还可以用其他文件大小单元。

- b —— 块（512字节）。
- c —— 字节。
- w —— 字（2字节）。
- k —— 1024字节。
- M —— 1024K字节。
- G —— 1024M字节。

7. 删除匹配的文件

-delete可以用来删除find查找到的匹配文件。

删除当前目录下所有的 .swp文件：

```
$ find . -type f -name "*.swp" -delete
```

8. 基于文件权限和所有权的匹配

也可以根据文件权限进行文件匹配。列出具有特定权限的所有文件：

```
$ find . -type f -perm 644 -print
# 打印出权限为644的文件
```

-perm指明find应该只匹配具有特定权限值的文件。文件权限会在3.5节进行讲解。

以Apache Web服务器为例。Web服务器上的PHP文件需要具有合适的执行权限。我们可以用下面的方法找出那些没有设置好执行权限的PHP文件：

```
$ find . -type f -name "*.php" ! -perm 644 -print
```

也可以根据文件的所有权进行搜索。用选项 -user USER就能够找出由某个特定用户所拥有的文件。

参数USER可以是用户名或UID。

例如，打印出用户slynux拥有的所有文件：

```
$ find . -type f -user slynux -print
```

9. 利用find执行命令或动作

find命令可以借助选项-exec与其他命名进行结合。-exec算得上是find最强大的特性之一。

在前一节中，我们用 -perm找出了所有权限不当的PHP文件。这次的任务也差不多，我们需要将某位用户（比如root）全部文件的所有权更改成另一位用户（比如Web服务器默认的Apache用户www-data），那么就可以用 -user找出root拥有的所有文件，然后用-exec更改所有权。

你必须以root用户的身份执行find命令才能够进行所有权的更改。

示例如下：

```
# find . -type f -user root -exec chown slynux {} \;
```

在这个命令中，{}是一个与 -exec选项搭配使用的特殊字符串。对于每一个匹配的文件，{}会被替换成相应的文件名。例如，find命令找到两个文件test1.txt和test2.txt，其所有者均为slynux，那么find就会执行：

```
chown slynux {}
```

它会被解析为chown slynux test1.txt和chown slynux test2.txt。

有时候我们并不希望对每个文件都执行一次命令。我们更希望使用文件列表作为命令参数，这样就可以少运行几次命令了。如果是这样，可以在exec中使用+来代替；。

另一个例子是将给定目录中的所有C程序文件拼接起来写入单个文件all_c_files.txt。我们可以用find找到所有的C文件，然后结合 -exec使用cat命令：

```
$ find . -type f -name "*.c" -exec cat {} \;>all_c_files.txt
```

-exec之后可以接任何命令。{}表示一个匹配。对于任何匹配的文件名，{}均会被该文件名所替换。

我们使用 > 操作符将来自find的数据重定向到all_c_files.txt文件，没有使用>>（追加）的原因是因为find命令的全部输出就只有一个数据流（stdin），而只有当多个数据流被追加到单个文件中时才有必要使用>>。

例如，用下列命令将10天前的 .txt文件复制到OLD目录中：

```
$ find . -type f -mtime +10 -name "*.txt" -exec cp {} OLD  \;
```

find命令同样可以采用类似的方法与其他命令结合起来。

-exec结合多个命令

我们无法在-exec参数中直接使用多个命令。它只能够接受单个命令，不过我们可以耍一个小花招。把多个命令写到一个shell脚本中（例如command.sh），然后在-exec中使用这个脚本：

```
-exec ./commands.sh {} \;
```

-exec能够同printf结合来生成有用的输出信息。例如：

```
$ find . -type f -name "*.txt" -exec printf "Text file: %s\n" {} \;
```

10. 让**find**跳过特定的目录

在搜索目录并执行某些操作时，有时为了提高性能，需要跳过一些子目录。例如，程序员会在版本控制系统（如Git）管理的开发源码树中查找特定的文件，源代码层级结构中的每个子目录里都会包含一个.git目录。（.git存储每个目录相关的版本控制信息。）因为与版本控制相关的目录对我们而言并没有什么用处，所以没必要去搜索这些目录。将某些文件或目录从搜索过程中排除在外的技巧被称为**修剪**，其操作方法如下：

```
$ find devel/source_path  \( -name ".git" -prune \) -o \( -type f -print \)

# Instead of \( -type -print \),而是选择需要的过滤器
```

以上命令打印出不包括在.git目录中的所有文件的名称（路径）。

\(-name ".git" -prune \)的作用是用于进行排除，它指明了 .git目录应该被排除在外，而\(-type f -print \)指明了需要执行的动作。这些动作需要被放置在第二个语句块中（打印出所有文件的名称和路径）。

2.5　玩转 **xargs**

我们可以用管道将一个命令的stdout（标准输出）重定向到另一个命令的stdin（标准输入）。例如：

```
cat foo.txt | grep "test"
```

但是，有些命令只能以命令行参数的形式接受数据，而无法通过stdin接受数据流。在这种情况下，我们没法用管道来提供那些只有通过命令行参数才能提供的数据。

那就只能另辟蹊径了。该xargs命令出场了，它擅长将标准输入数据转换成命令行参数。xargs能够处理stdin并将其转换为特定命令的命令行参数。xargs也可以将单行或多行文本输入转换成其他格式，例如单行变多行或是多行变单行。

Bash用户都爱单行命令。单行命令是一个命令序列，各命令之间不使用分号，而是使用管道操作符进行连接。精心编写的单行命令可以更高效、更简捷地完成任务。就文本处理而言，需要具备扎实的理论知识和实践经验才能够写出适合的单行命令解决方案。xargs就是构建单行命令的重要组件之一。

2.5.1　预备知识

xargs命令应该紧跟在管道操作符之后，以标准输入作为主要的源数据流。它使用stdin并通过提供命令行参数来执行其他命令。例如：

```
command | xargs
```

2.5.2 实战演练

xargs命令把从stdin接收到的数据重新格式化，再将其作为参数提供给其他命令。

xargs可以作为一种替代，其作用类似于find命令中的 -exec。下面是各种xargs命令的使用技巧。

- 将多行输入转换成单行输出。

  只需要将换行符移除，再用" "（空格）进行代替，就可以实现多行输入的转换。'\n' 被解释成一个换行符，换行符其实就是多行文本之间的定界符。利用xargs，我们可以用空格替换掉换行符，这样就能够将多行文本转换成单行文本：

```
$ cat example.txt # 样例文件
1 2 3 4 5 6
7 8 9 10
11 12

$ cat example.txt | xargs
1 2 3 4 5 6 7 8 9 10 11 12
```

- 将单行输入转换成多行输出。

  指定每行最大的参数数量*n*，我们可以将任何来自stdin的文本划分成多行，每行*n*个参数。每一个参数都是由" "（空格）隔开的字符串。空格是默认的定界符。下面的方法可以将单行划分成多行：

```
$ cat example.txt | xargs -n 3
1 2 3
4 5 6
7 8 9
10 11 12
```

2.5.3 工作原理

xargs命令数量众多的选项使其能够适用于多种问题场景。让我们来看看如何能够巧妙地运用这些选项来解决问题。

可以用自己的定界符来分隔参数。用-d选项为输入指定一个定制的定界符：

```
$ echo "splitXsplitXsplitXsplit" | xargs -d X
split split split split
```

在上面的代码中，stdin是一个包含了多个X字符的字符串。我们可以用 -d将X作为输入定界符。在这里，我们明确指定X作为输入定界符，而在默认情况下，xargs采用**内部字段分隔符**（空格）作为输入定界符。

结合-n选项，我们可以将输入划分成多行，而每行包含两个参数：

```
$ echo "splitXsplitXsplitXsplit" | xargs -d X -n 2
split split
split split
```

2.5.4　补充内容

我们已经从上面的例子中学到了如何将stdin格式化成不同的输出形式以作为参数。现在让我们来学习如何将这些参数传递给命令。

1. 读取stdin，将格式化参数传递给命令

编写一个小型的定制版echo来更好地理解用xargs提供命令行参数的方法：

```
#!/bin/bash
#文件名: cecho.sh

echo $*'#'
```

当参数被传递给文件cecho.sh后，它会将这些参数打印出来，并以 # 字符作为结尾。例如：

```
$ ./cecho.sh arg1 arg2
arg1 arg2 #
```

让我们来看下面这个问题。

- 有一个包含着参数列表的文件（每行一个参数）。我需要用两种方法将这些参数传递给一个命令（比如cecho.sh）。第一种方法，需要每次提供一个参数：

  ```
  ./cecho.sh arg1
  ./cecho.sh arg2
  ./cecho.sh arg3
  ```

  或者，每次需要提供两个或三个参数。提供两个参数时，它看起来像这样：

  ```
  ./cecho.sh arg1 arg2
  ./cecho.sh arg3
  ```

- 第二种方法，需要一次性提供所有的命令参数：

  ```
  ./cecho.sh arg1 arg2 arg3
  ```

先别急着往下看，试着运行一下上面的命令，然后仔细观察输出结果。

上面的问题也可以用xargs来解决。我们有一个名为args.txt的参数列表文件，这个文件的内容如下：

```
$ cat args.txt
arg1
arg2
arg3
```


就第一个问题，我们可以将这个命令执行多次，每次使用一个参数：

```
$ cat args.txt | xargs -n 1 ./cecho.sh
arg1 #
arg2 #
arg3 #
```

每次执行需要X个参数的命令时，使用：

```
INPUT | xargs -n X
```

例如：

```
$ cat args.txt | xargs -n 2 ./cecho.sh
arg1 arg2 #
arg3 #
```

就第二个问题，为了在执行命令时一次性提供所有的参数，可以使用：

```
$ cat args.txt | xargs ./cecho.sh
arg1 arg2 arg3 #
```

在上面的例子中，我们直接为特定的命令（例如cecho.sh）提供命令行参数。这些参数都源于args.txt文件。但实际上除了它们外，我们还需要一些固定不变的命令参数。思考下面这种命令格式：

```
./cecho.sh -p arg1 -l
```

在上面的命令执行过程中，arg1是唯一的可变内容，其余部分都保持不变。我们可以从文件（args.txt）中读取参数，并按照下面的方式提供给命令：

```
./cecho.sh -p arg1 -l
./cecho.sh -p arg2 -l
./cecho.sh -p arg3 -l
```

xargs有一个选项-I，可以提供上面这种形式的命令执行序列。我们可以用-I指定替换字符串，这个字符串在xargs扩展时会被替换掉。如果将-I与xargs结合使用，对于每一个参数，命令都会被执行一次。

试试下面的用法：

```
$ cat args.txt | xargs -I {} ./cecho.sh -p {} -l
-p arg1 -l #
-p arg2 -l #
-p arg3 -l #
```

-I {} 指定了替换字符串。对于每一个命令参数，字符串{}都会被从stdin读取到的参数替换掉。

使用-I的时候，命令以循环的方式执行。如果有3个参数，那么命令就会连同{}一起被执行3次。在每一次执行中{}都会被替换为相应的参数。

2. 结合find使用xargs

xargs和find算是一对死党。两者结合使用可以让任务变得更轻松。不过人们通常却是以一种错误的组合方式使用它们。例如：

```
$ find . -type f -name "*.txt"  -print | xargs rm -f
```

这样做很危险。有时可能会删除不必要删除的文件。我们没法预测分隔find命令输出结果的定界符究竟是什么（'\n'或者' '）。很多文件名中都可能会包含空格符（' '），因此xargs很可能会误认为它们是定界符（例如，hell text.txt会被xargs误解为hell和text.txt）。

只要我们把find的输出作为xargs的输入，就必须将 -print0与find结合使用，以字符null（'\0'）来分隔输出。

用find匹配并列出所有的 .txt文件，然后用xargs将这些文件删除：

```
$ find . -type f -name "*.txt" -print0 | xargs -0 rm -f
```

这样就可以删除所有的.txt文件。xargs -0将\0作为输入定界符。

3. 统计源代码目录中所有C程序文件的行数

统计所有C程序文件的**行数**（Lines of Code，LOC）是大多数程序员都会遇到的任务。完成这项任务的代码如下：

```
$ find source_code_dir_path -type f -name "*.c" -print0 | xargs -0 wc -l
```

如果你想获得有关个人源代码更多的统计信息，有个叫做SLOCCount的工具可以派上用场。现代GNU/Linux发行版一般都包含这个软件包，或者你也可以从http://www.dwheeler.com/sloccount/处下载。

4. 结合stdin，巧妙运用while语句和子shell

xargs只能以有限的几种方式来提供参数，而且它也不能为多组命令提供参数。要执行包含来自标准输入的多个参数的命令，有一种非常灵活的方法。包含while循环的子shell可以用来读取参数，然后通过一种巧妙的方式执行命令：

```
$ cat files.txt  | ( while read arg; do cat $arg; done )
# 等同于cat files.txt | xargs -I {} cat {}
```

在while循环中，可以将cat $arg替换成任意数量的命令，这样我们就可以对同一个参数执行多条命令。也可以不借助管道，将输出传递给其他命令。这个技巧能够适用于各种问题场景。子shell操作符内部的多个命令可作为一个整体来运行。

```
$ cmd0 | ( cmd1;cmd2;cmd3) | cmd4
```

如果cmd1是cd /，那么就会改变子shell工作目录，然而这种改变仅局限于子shell内部。cmd4则完全不知道工作目录发生了变化。

2.6 用 tr 进行转换

tr是Unix命令行专家工具箱中一件简约却不失精美的工具。它经常用来编写优美的单行命令，作用不容小视。tr可以对来自标准输入的内容进行字符替换、字符删除以及重复字符压缩。它可以将一组字符变成另一组字符，因而通常也被称为**转换**（translate）命令。在这则攻略中，我们会看到如何使用tr进行基本的集合转换。

2.6.1 预备知识

tr只能通过stdin（标准输入），而无法通过命令行参数来接受输入。它的调用格式如下：

```
tr [options] set1 set2
```

将来自stdin的输入字符从set1映射到set2，然后将输出写入stdout（标准输出）。set1和set2是字符类或字符集。如果两个字符集的长度不相等，那么set2会不断重复其最后一个字符，直到长度与set1相同。如果set2的长度大于set1，那么在set2中超出set1长度的那部分字符则全部被忽略。

2.6.2 实战演练

将输入字符由大写转换成小写，可以使用下面的命令：

```
$ echo "HELLO WHO IS THIS" | tr 'A-Z' 'a-z'
```

'A-Z' 和 'a-z'都是集合。我们可以按照需要追加字符或字符类来构造自己定制的集合。

'ABD-}'、'aA.,'、'a-ce-x'以及'a-c0-9'等均是合法的集合。定义集合也很简单，不需要书写一长串连续的字符序列，只需要使用“起始字符–终止字符”这种格式就行了。这种写法也可以和其他字符或字符类结合使用。如果“起始字符–终止字符”不是一个连续的字符序列，那么它就会被视为包含了3个元素的集合，也就是：起始字符，–，终止字符。你可以使用像'\t'、'\n'这种特殊字符，也可以使用其他ASCII字符。

2.6.3　工作原理

通过在tr中使用集合的概念，我们可以轻松地将字符从一个集合映射到另一个集合中。下面通过一则示例看看如何用tr进行数字加密和解密。

```
$ echo 12345 | tr '0-9' '9876543210'
87654 # 已加密

$ echo 87654 | tr '9876543210' '0-9'
12345 # 已解密
```

再来看另外一个有趣的例子。

ROT13是一个著名的加密算法。在ROT13算法中，文本加密和解密都使用同一个函数。ROT13按照字母表排列顺序执行13个字母的转换。用tr进行ROT13加密：

```
$ echo "tr came, tr saw, tr conquered." | tr 'a-zA-Z' 'n-za-mN-ZA-M'
```

得到输出：

```
ge pnzr, ge fnj, ge pbadhrerq.
```

对加密后的密文再次使用同样的ROT13函数，我们采用：

```
$ echo ge pnzr, ge fnj, ge pbadhrerq. | tr 'a-zA-Z' 'n-za-mN-ZA-M'
```

得到输出：

```
tr came, tr saw, tr conquered.
```

tr还可以用来将制表符转换成空格：

```
$ tr '\t' ' ' < file.txt
```

2.6.4　补充内容

我们已经看到了tr的一些基本转换功能，接下来看看tr还能帮我们实现的其他功能。

1. 用tr删除字符

tr有一个选项-d，可以通过指定需要被删除的字符集合，将出现在stdin中的特定字符清除掉：

```
$ cat file.txt | tr -d  '[set1]'
#只使用set1，不使用set2
```

例如：

```
$ echo "Hello 123 world 456" | tr -d '0-9'
Hello world
# 将stdin中的数字删除并打印出来
```

2. 字符集补集

我们可以利用选项-c来使用set1的补集。下面的命令中，set2是可选的：

```
tr -c [set1] [set2]
```

set1的补集意味着这个集合中包含set1中没有的所有字符。

最典型的用法是从输入文本中将不在补集中的所有字符全部删除。例如：

```
$ echo hello 1 char 2 next 4 | tr -d -c '0-9 \n'
 1  2  4
```

在这里，补集中包含了除数字、空格字符和换行符之外的所有字符。因为指定了-d，所以这些字符全部都被删除。

3. 用tr压缩字符

tr命令在很多文本处理环境中大有用武之地。多数情况下，连续的重复字符应该压缩成单个字符。经常需要从事的一项任务就是压缩空白字符。

tr的-s选项可以压缩输入中重复的字符，方法如下：

```
$ echo "GNU is       not     UNIX. Recursive   right ?" | tr -s ' '
GNU is not UNIX. Recursive right ?
# tr -s '[set]'
```

让我们用一种巧妙的方式用tr将文件中的数字列表进行相加：

```
$ cat sum.txt
1
2
3
4
```

```
5

$ cat sum.txt | echo $[ $(tr '\n' '+' ) 0 ]
15
```

这一招是如何起效的?

在上面的命令中，tr用来将'\n'替换成'+'，因此我们得到了字符串"1+2+3+…5+"，但是在字符串的尾部多了一个操作符+。为了抵消这个多出来的操作符，我们再追加一个0。

$[operation]执行算术运算，因此得到下面的字符串：

```
echo $[ 1+2+3+4+5+0 ]
```

如果我们利用循环从文件中读取数字，然后再进行相加，那肯定得用好几行代码。而如今只用一行就搞定了。

还可以像下面这样使用tr，以摈除多余的换行符：

```
$ cat multi_blanks.txt | tr -s '\n'
line1
line2
line3
line4
```

在上例中，tr将多余的'\n'字符合并为单一的'\n'（换行符）。

4. 字符类

tr可以像使用集合一样使用各种不同的字符类，这些字符类如下所示：

- ❑ alnum：字母和数字。
- ❑ alpha：字母。
- ❑ cntrl：控制（非打印）字符。
- ❑ digit：数字。
- ❑ graph：图形字符。
- ❑ lower：小写字母。
- ❑ print：可打印字符。
- ❑ punct：标点符号。
- ❑ space：空白字符。
- ❑ upper：大写字母。
- ❑ xdigit：十六进制字符。

可以按照下面的方式选择并使用所需的字符类：

```
tr [:class:] [:class:]
```

例如：

```
tr '[:lower:]' '[:upper:]'
```


2.7 校验和与核实

校验和（checksum）程序用来从文件中生成校验和密钥，然后利用这个校验和密钥核实文件的完整性。文件可以通过网络或任何存储介质分发到不同的地点。出于多种原因，数据有可能在传输过程中丢失了若干位，从而导致文件损坏。这种错误通常发生在从Internet上下载文件，通过网络传输文件，或者CD光盘损坏等。

因此，我们需要采用一些测试方法来确定接收到的文件是否存在错误。用于文件完整性测试的特定密钥就称为**校验和**。

我们对原始文件和接收到的文件都进行校验和计算。通过比对两者的校验和，就能够核实接收到的文件是否正确。如果校验和（一个来自发送地的原始文件，另一个来自目的地的接收文件）相等，就意味着我们接收到了正确的文件，否则用户就不得不重新发送文件并再次比对校验和。

校验和对于编写备份脚本或系统维护脚本来说非常重要，因为它们都会涉及通过网络传输文件。通过使用校验和核实，我们就可以识别出那些在网络传输过程中出现损坏的文件，并进行重发。

在这则攻略中，我们会学习如何计算校验和验证数据完整性。

2.7.1 预备知识

最知名且使用最为广泛的校验和技术是md5sum和SHA-1。它们对文件内容使用相应的算法来生成校验和。下面就来看看如何从文件中生成校验和并核实文件的完整性。

2.7.2 实战演练

为了计算md5sum，使用下列命令：

```
$ md5sum filename
68b329da9893e34099c7d8ad5cb9c940 filename
```

如上所示，`md5sum`是一个32个字符的十六进制串。

将输出的校验和重定向到一个文件，然后用这个MD5文件核实数据的完整性：

```
$ md5sum filename > file_sum.md5
```

2.7.3　工作原理

md5sum校验和计算的方法如下：

```
$ md5sum file1 file2 file3 ..
```

当使用多个文件时，输出中会在每行中包含单个文件的校验和：

```
[checksum1]   file1
[checksum1]   file2
[checksum1]   file3
```

可以按照下面的方法用生成的文件核实数据完整性：

```
$ md5sum -c file_sum.md5
# 这个命令会输出校验和是否匹配的消息
```

如果需要用所有的.md5信息来检查所有的文件，可以使用：

```
$ md5sum -c *.md5
```

与md5sum类似，SHA-1是另一种常用的校验和算法。它从给定的输入文件中生成一个长度为40个字符的十六进制串。用来计算SAH-1串的命令是sha1sum。其用法和md5sum的非常相似。只需要把先前讲过的那些命令中的md5sum替换成sha1sum就行了，记住将输入文件名从file_sum.md5改为file_sum.sha1。

校验和对于核实下载文件的完整性非常有帮助。我们从网上下载的ISO镜像文件一般更容易出现错误（见图2-1）。为了检查接收文件正确与否，校验和得以广泛应用。校验和程序对同样的文件数据始终生成一模一样的校验和。

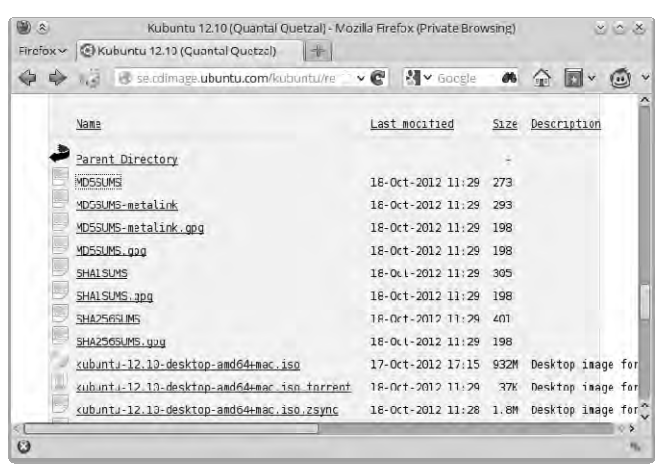

图　2-1

图2-2是md5sum生成的校验和。

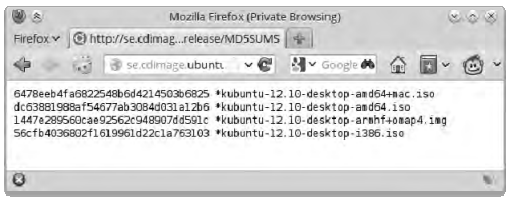

图 2-2

2.7.4 补充内容

对于多个文件，校验和同样可以发挥作用。现在就看看如何校验并核实多个文件。

对目录进行校验

校验和是从文件中计算得来的。对目录计算校验和意味着我们需要对目录中的所有文件以递归的方式进行计算。

这可以用命令`md5deep`或`sha1deep`来实现。首先，需要安装md5deep软件包以确保能找到这些命令。该命令的用法如下：

```
$ md5deep -rl directory_path > directory.md5
# -r使用递归的方式
# -l使用相对路径。默认情况下，md5deep会输出文件的绝对路径
```

或者也可以结合`find`来递归计算校验和：

```
$ find directory_path -type f -print0 | xargs -0 md5sum >> directory.md5
```

用下面的命令进行核实：

```
$ md5sum -c directory.md5
```

2.8 加密工具与散列

加密技术主要用于防止数据遭受未经授权的访问。加密算法有很多，我们会着重讲解那些常见的标准加密算法。在Linux环境下有一些工具可以用来执行加密和解密。有时我们使用加密算法散列值来验证数据的完整性。本节将介绍一些常用的加密工具以及这些工具所涉及的算法。

实战演练

让我们看看`crypt`、`gpg`、`base64`、`md5sum`、`sha1sum`以及`openssl`的用法。

- crypt是一个简单的加密工具，它从stdin接受一个文件以及口令作为输入，然后将加密数据输出到Stdout（因此要对输入、输出文件使用重定向）。

```
$ crypt <input_file >output_file
Enter passphrase:
```

它会要求输入一个口令。我们也可以通过命令行参数来提供口令。

```
$ crypt PASSPHRASE <input_file >encrypted_file
```

如果需要解密文件，可以使用：

```
$ crypt PASSPHRASE -d <encrypted_file >output_file
```

- gpg（GNU隐私保护）是一种应用广泛的工具，它使用加密技术来保护文件，以确保数据在送达目的地之前无法被读取。这里我们讨论如何加密、解密文件。

gpg签名同样广泛用于在电子邮件通信中的邮件“签名”，以证明发送方的真实性。

用gpg加密文件：

```
$ gpg -c filename
```

该命令采用交互方式读取口令，并生成filename.gpg。使用以下命令解密gpg文件：

```
$ gpg filename.gpg
```

该命令读取口令，然后对文件进行解密。

本书并没有涉及gpg的过多细节。如果你感兴趣，希望进一步了解，请访问http://en.wikipedia.org/wiki/GNU_Privacy_Guard。

- Base64是一组相似的编码方案，它将ASCII字符转换成以64为基数的形式（radix-64 representation），以可读的ASCII字符串来描述二进制数据。base64命令可以用来编码/解码Base64字符串。要将文件编码为Base64格式，可以使用：

```
$ base64 filename > outputfile
```

或者

```
$ cat file | base64 > outputfile
```

base64可以从stdin中进行读取。

解码Base64数据：

```
$ base64 -d file > outputfile
```

或者

```
$ cat base64_file | base64 -d > outputfile
```

- md5sum与sha1sum都是单向散列算法，均无法逆推出原始数据。它们通常用于验证数据完整性或为特定数据生成唯一的密钥：

```
$ md5sum file
8503063d5488c3080d4800ff50850dc9  file

$ sha1sum file
1ba02b66e2e557fede8f61b7df282cd0a27b816b  file
```

这种类型的散列算法是存储密码的理想方案。密码使用其对应的散列值来存储。如果某个用户需要进行认证，读取该用户提供的密码并转换成散列值，然后将其与之前存储的散列值进行比对。如果相同，用户就通过认证，被允许访问；否则，就会被拒绝访问。将密码以明文形式存储是件非常冒险的事，会面临安全风险。

尽管使用广泛，md5sum和SHA-1已不再安全。因为计算能力的攀升使其变得容易被破解。推荐使用bcrypt或sha512sum这类工具进行加密。详情可参看http://codahale.com/how-to-saftyly-store-a-password/。

- shadow-like散列（salt散列）

让我们看看如何为密码生成shadow-like salt散列。在Linux中，用户密码是以散列值形式存储在文件 /etc/shadow中的。该文件中的典型内容类似于下面这样：

```
test:$6$fG4eWdUi$ohTKOlEUzNk77.4S8MrYe07NTRV4M3LrJnZP9p.qc1bR5c.EcOruzPXfEu1uloB
FUa18ENRH7F70zhodas3cR.:14790:0:99999:7:::
```

该行中的 `$6$fG4eWdUi$ohTKOlEUzNk77.4S8MrYe07NTRV4M3LrJnZP9p.qc1bR5c.EcOruzPXfEu1uloBFUa18ENRH7F70zhodas3cR`是密码对应的shadow散列值。

某些情况下，我们得编写一些至关重要的管理脚本，这些脚本也许需要编辑密码，或是需要用shell脚本手动添加用户。这时我们必须生成shadow密码字符串，并向shadow文件中写入与上面类似的文本行。下面让我们看看如何用`openssl`生成shadow密码。

shadow密码通常都是salt密码。所谓SALT就是额外的一个字符串，用来起一个混淆的作用，使加密更加不易被破解。salt由一些随机位组成，被用作密钥生成函数的输入之一，以生成密码的salt散列值。

关于salt的更多细节信息，请参考维基百科页面http://en.wikipedia.org/wiki/Salt_(cryptography)。

```
$ opensslpasswd -1 -salt SALT_STRING PASSWORD
$1$SALT_STRING$323VkWkSLHuhbt1zkSsUG.
```

将SALT_STRING替换为随机字符串，并将PASSWORD替换成你想要使用的密码。

2.9　排序、唯一与重复

同文本文件打交道时，少不了要用到排序。sort命令能够帮助我们对文本文件和stdin进行排序操作。它通常会配合其他命令来生成所需要的输出。uniq是一个经常与sort一同使用的命令。它的作用是从文本或stdin中提取唯一（或重复）的行。这则攻略将演示sort和uniq命令的常见用法。

2.9.1　预备知识

sort命令既可以从特定的文件，也可以从stdin中获取输入，并将输出写入stdout。uniq的工作方式和sort一样。

2.9.2　实战演练

(1) 我们可以按照下面的方式轻松地对一组文件（例如file1.txt和file2.txt）进行排序：

```
$ sort file1.txt file2.txt > sorted.txt
```

或是

```
$ sort file1.txt file2.txt -o sorted.txt
```

(2) 按照数字顺序进行排序：

```
$ sort -n file.txt
```

(3) 按照逆序进行排序：

```
$ sort -r file.txt
```

(4) 按照月份进行排序（依照一月，二月，三月……）：

```
$ sort -M months.txt
```

(5) 合并两个已排序过的文件：

```
$ sort -m sorted1 sorted2
```

(6) 找出已排序文件中不重复的行：

```
$ sort file1.txt file2.txt | uniq
```

(7) 检查文件是否已经排序过：

```
#!/bin/bash
#功能描述：排序
sort -C filename ;
if [ $? -eq 0 ]; then
   echo Sorted;
else
   echo Unsorted;
fi
```

将filename替换成你需要进行检查的文件名，然后运行该脚本。

2.9.3 工作原理

sort命令包含大量的选项，能够对文件数据进行各种排序。如果使用uniq命令，那sort更是必不可少，因为前者要求输入数据必须经过排序。

sort和uniq可以应用于多种场景。让我们来看一下这些命令的各种选项及用法。

要检查文件是否排序过，可以采用以下方法：如果文件已经排序，sort会返回为0的退出码（$?），否则返回非0。

2.9.4 补充内容

我们已经介绍了sort命令的基本用法。下面来看看如何利用sort来完成一些复杂的任务。

1. 依据键或列进行排序

我们可以按列将下面的文本排序：

```
$ cat data.txt
1  mac    2000
2  winxp    4000
3  bsd    1000
4  linux    1000
```

有很多方法可以对这段文本排序。目前它是按照序号（第一列）来排序的。我们也可以依据第二列和第三列来排序。

-k指定了排序应该按照哪一个键（key）来进行。键指的是列号，而列号就是执行排序时的依据。-r告诉sort命令按照逆序进行排序。例如：

```
# 依据第1列，以逆序形式排序
$ sort -nrk 1  data.txt
4  linux    1000
3  bsd    1000
2  winxp    4000
1  mac    2000
# -nr表明按照数字，采用逆序形式排序

# 依据第2列进行排序
$ sort -k 2  data.txt
3  bsd    1000
4  linux    1000
1  mac    2000
2  winxp    4000
```

一定要留意用于按数字顺序进行排序的选项-n。sort命令对于字母表排序和数字排序有不同的处理方式。因此，如果要采用数字顺序排序，就应该明确地给出-n选项。

通常在默认情况下，键就是文本文件中的列。列与列之间用空格分隔。但有时候，我们需要将特定范围内的一组字符（例如，key1=character4-character8）作为键。在这种情况下，必须明确地将键指定为某个范围内的字符，这个范围可以用键起止的字符位置来表明。例如：

```
$ cat data.txt
1010hellothis
2189ababbba
7464dfddfdfd
$ sort -nk 2,3 data.txt
```

把醒目的字符作为数值键。为了提取这个键，用字符在行内的起止位置作为键的书写格式（在上面的例子中，起止位置是2和3）。

用第一个字符作为键：

```
$ sort -nk 1,1 data.txt
```

为了使sort的输出与以\0作为终止符的xargs命令相兼容，采用下面的命令：

```
$ sort -z data.txt | xargs -0
# 终止符\0用来保证xargs命令的使用安全
```

有时文本中可能会包含一些像空格之类的不必要的多余字符。如果需要忽略这些字符，并以字典序进行排序，可以使用：

```
$ sort -bd unsorted.txt
```

其中，选项-b用于忽略文件中的前导空白行，选项-d用于指明以字典序进行排序。

2. uniq

uniq命令通过消除重复内容，从给定输入中（stdin或命令行参数文件）找出唯一的行。它也可以用来找出输入中出现的重复行。

uniq只能作用于排过序的数据输入，因此，uniq要么使用管道，要么将排过序的文件作为输入，与sort命令结合使用。

你可以按照下面的方式从给定的输入数据中生成唯一的行（所谓“唯一的行”是指来自输入的所有行都会被打印出来，但是其中重复的行只会被打印一次）：

```
$ cat sorted.txt
bash
foss
hack
hack

$ uniq sorted.txt
bash
foss
hack
```

或是

```
$ sort unsorted.txt | uniq
```

只显示唯一的行（在输入文件中没有重复出现的行）：

```
$ uniq -u sorted.txt
bash
foss
```

或是

```
$ sort unsorted.txt | uniq -u
```

要统计各行在文件中出现的次数，使用下面的命令：

```
$ sort unsorted.txt | uniq -c
      1 bash
      1 foss
      2 hack
```

找出文件中重复的行：

```
$ sort unsorted.txt  | uniq -d
hack
```

我们可以结合-s和-w来指定键：

- -s 指定可以跳过前*n*个字符；
- -w 指定用于比较的最大字符数。

这个对比键被用作uniq操作的索引：

```
$ cat data.txt
u:01:gnu
d:04:linux
u:01:bash
u:01:hack
```

我们需要使用醒目的字符作为唯一的键。可以通过忽略前2个字符（-s 2），使用 -w选项（-w 2）指定用于比较的最大字符数。

```
$ sort data.txt | uniq -s 2 -w 2
d:04:linux
u:01:bash
```

我们将命令输出作为xargs命令的输入时，最好为输出的各行添加一个0值字节（zero-byte）终止符。在将uniq命令的输入作为xargs的数据源时，同样应当如此。如果没有使用0值字节终止符，那么在默认情况下，xargs命令会用空格作为定界符分割参数。例如，来自stdin的文本行“this is a line”会被xargs当做包含4个不同的参数，但实际上它只是一个单行而已。如果使用0值字节终止符，那么\0就被作为定界符，此时，包含空格的单行就能够被正确地解析成单个参数。

用uniq命令生成包含0值字节终止符的输出：

```
$ uniq -z file.txt
```

下面的命令将删除所有指定的文件，这些文件的名字是从files.txt中读取的：

```
$ uniq -z file.txt | xargs -0 rm
```

如果某个文件名在文件中出现多次，uniq命令只会将这个文件名写入stdout一次。

2.10　临时文件命名与随机数

编写shell脚本时，我们经常需要存储临时数据。最适合存储临时数据的位置是 /tmp（该目录中的内容在系统重启后会被清空）。有两种方法可以为临时数据生成标准的文件名。

2.10.1　实战演练

执行下列步骤来创建临时文件并进行不同的命名操作。

(1) 创建临时文件：

```
$ filename=`mktemp`
$ echo $filename
/tmp/tmp.8xvhkjF5fH
```

上面的代码创建了一个临时文件，并打印出存储在$filename中的文件名。

(2) 创建临时目录：

```
$ dirname=`mktemp -d`
$ echo $dirname
tmp.NI8xzW7VRX
```

上面的代码创建了一个临时目录，并打印出存储在$dirname中的目录名。

(3) 如果仅仅是想生成文件名，又不希望创建实际的文件或目录，方法如下：

```
$ tmpfile=`mktemp -u`
$ echo $tmpfile
/tmp/tmp.RsGmilRpcT
```

文件名被存储在$tmpfile中，但并没有创建对应的文件。

(4) 根据模板创建临时文件名：

```
$mktemp test.XXX
test.2tc
```

2.10.2 工作原理

mktemp命令的用法非常简单。它生成一个临时文件并返回其文件名（如果创建的是目录，则返回目录名）。

如果提供了定制模板，X会被随机的字符（字母或数字）替换。注意，mktemp正常工作的前提是保证模板中只少要有3个X。

2.11 分割文件和数据

在某些情况下，必须把文件分割成多个更小的片段。早期像软盘之类的设备容量都很有限，将文件分割得更小些，以便能够存储到多张磁盘中就显得至关重要了。不过如今我们分割文件就是出于其他目的了，比如为提高可读性、生成日志、通过E-mail发送文件等。在这则攻略中我们会看到将文件分割成不同大小的多种方法。

2.11.1　工作原理

假设有一个叫做data.file的测试文件，其大小为100KB。你可以将该文件分割成多个大小为10KB的文件，方法如下：

```
$ split -b 10k data.file
$ ls
data.file  xaa  xab  xac  xad  xae  xaf  xag  xah  xai  xaj
```

上面的命令将data.file分割成多个文件，每一个文件大小为10KB。这些文件以xab、xac、xad的形式命名。这表明它们都有一个字母后缀。如果想以数字为后缀，可以另外使用-d参数。此外，使用 -a length可以指定后缀长度：

```
$ split -b 10k data.file -d -a 4
```

除了k（KB）后缀，我们还可以使用M（MB）、G（GB）、c（byte）、w（word）等后缀。

```
$ ls
data.file x0009  x0019  x0029  x0039  x0049  x0059  x0069  x0079
```

2.11.2　补充内容

来看看split命令的其他选项。

为分割后的文件指定文件名前缀

之前那些分割后的文件都有一个文件名前缀x。我们也可以通过提供一个前缀名来使用自己的文件名前缀。split命令最后一个参数是PREFIX，其格式如下：

```
$ split [COMMAND_ARGS] PREFIX
```

我们加上文件名前缀再运行先前那个命令来分割文件：

```
$ split -b 10k data.file -d -a 4 split_file
$ ls
data.file       split_file0002  split_file0005  split_file0008  strtok.c
split_file0000  split_file0003  split_file0006  split_file0009
split_file0001  split_file0004  split_file0007
```

如果不想按照数据块大小，而是需要根据行数来分割文件的话，可以使用 -l no_of_lines：

```
$ split -l 10 data.file
# 分割成多个文件，每个文件包含10行
```

另一个有趣的的工具是csplit。它能够依据指定的条件和字符串匹配选项对日志文件进行分割。来看看这个工具是如何运作的。

csplit是split工具的一个变体。split只能够根据数据大小或行数分割文件，而csplit可以根据文本自身的特点进行分割。是否存在某个单词或文本内容都可作为分割文件的条件。

看一个日志文件示例：

```
$ cat server.log
SERVER-1
[connection] 192.168.0.1 success
[connection] 192.168.0.2 failed
[disconnect] 192.168.0.3 pending
[connection] 192.168.0.4 success
SERVER-2
[connection] 192.168.0.1 failed
[connection] 192.168.0.2 failed
[disconnect] 192.168.0.3 success
[connection] 192.168.0.4 failed
SERVER-3
[connection] 192.168.0.1 pending
[connection] 192.168.0.2 pending
[disconnect] 192.168.0.3 pending
[connection] 192.168.0.4 failed
```

我们需要将这个日志文件分割成server1.log、server2.log和server3.log，这些文件的内容分别取自原文件中不同的SERVER部分。那么，可以使用下面的方法来实现：

```
$ csplit server.log /SERVER/ -n 2 -s {*}  -f server -b "%02d.log"  ; rm server00.log

$ ls
server01.log  server02.log  server03.log  server.log
```

有关这个命令的详细说明如下。

- /SERVER/ 用来匹配某一行，分割过程即从此处开始。
- /[REGEX]/ 表示文本样式。包括从当前行（第一行）直到（但不包括）包含“SERVER”的匹配行。
- {*} 表示根据匹配重复执行分割，直到文件末尾为止。可以用{整数}的形式来指定分割执行的次数。
- -s 使命令进入静默模式，不打印其他信息。
- -n 指定分割后的文件名后缀的数字个数，例如01、02、03等。
- -f 指定分割后的文件名前缀（在上面的例子中，server就是前缀）。
- -b 指定后缀格式。例如%02d.log，类似于C语言中printf的参数格式。在这里文件名=前缀+后缀=server + %02d.log。

因为分割后的第一个文件没有任何内容（匹配的单词就位于文件的第一行中），所以我们删除了server00.log。

2.12　根据扩展名切分文件名

有一些脚本是依据文件名进行各种处理的。我们可能会需要在保留扩展名的同时修改文件名、转换文件格式（保留文件名的同时修改扩展名）或提取部分文件名。shell所具有的一些内建功能可以依据不同的情况来切分文件名。

2.12.1　实战演练

借助%操作符可以轻松将名称部分从“*名称.扩展名*”这种格式中提取出来。你可以按照下面的方法从sample.jpg中提取名称。

```
file_jpg="sample.jpg"
name=${file_jpg%.*}
echo File name is: $name
```

输出结果：

```
File name is: sample
```

下一个任务是将文件名的扩展名部分提取出来，这可以借助 # 操作符实现。

提取文件名中的 .jpg并存储到变量file_jpg中：

```
extension=${file_jpg#*.}
echo Extension is: jpg
```

输出结果：

```
Extension is: jpg
```

2.12.2　工作原理

在第一个任务中，为了从“*名称.扩展名*”这种格式中提取名称，我们使用了%操作符。

${VAR%.*} 的含义如下所述：

- 从 $VAR中删除位于 % 右侧的通配符（在前例中是.*）所匹配的字符串。通配符从右向左进行匹配。
- 给VAR赋值，VAR=sample.jpg。那么，通配符从右向左就会匹配到.jpg，因此，从 $VAR 中删除匹配结果，就会得到输出sample。

%属于非贪婪（non-greedy）操作。它从右到左找出匹配通配符的最短结果。还有另一个操作符 %%，这个操作符与%相似，但行为模式却是贪婪的，这意味着它会匹配符合条件的最长的字符

串。例如，我们现在有这样一个文件：

```
VAR=hack.fun.book.txt
```

使用%操作符：

```
$ echo ${VAR%.*}
```

得到输出：hack.fun.book

操作符%使用.*从右向左执行非贪婪匹配（.txt）。

使用%%操作符：

```
$ echo ${VAR%%.*}
```

得到输出：hack

操作符%%则用.*从右向左执行贪婪匹配（.fun.book.txt）。

在第二个任务中，我们用 # 操作符从文件名中提取扩展名。这个操作符与%类似，不过求值方向是从左向右。

${VAR#*.}的含义如下所述：

从$VAR中删除位于#右侧的通配符（即在前例中使用的*.）所匹配的字符串。通配符从左向右进行匹配。

和 %% 类似，#也有一个相对应的贪婪操作符 ##。

从左向右进行贪婪匹配，并从指定变量中删除匹配结果。

来看一个例子：

```
VAR=hack.fun.book.txt
```

使用#操作符：

```
$ echo ${VAR#*.}
```

得到输出：fun.book.txt

操作符#用*.从左向右执行非贪婪匹配（hack）。

使用##操作符：

```
$ echo ${VAR##*.}
```

得到输出：txt

操作符##则用*.从左向右执行贪婪匹配（txt）。

因为文件名中可能包含多个'.'字符，所以相较于#，## 更适合于从文件名中提取扩展名。## 执行的是贪婪匹配，因而总是能够准确地提取出扩展名。

这里有个能够提取域名不同部分的实用案例。假定URL="www.google.com"：

```
$ echo ${URL%.*} # 移除.*所匹配的最右边的内容
www.google

$ echo ${URL%%.*} # 将从右边开始一直匹配到最左边的*.移除（贪婪操作符）
www


$ echo ${URL#*.} # 移除*.所匹配的最左边的内容
google.com


$ echo ${URL##*.} # 将从左边开始一直匹配到最右边的*.移除（贪婪操作符）
com
```

2.13　批量重命名和移动

重命名多个文件是我们经常会碰到的一项工作。举个简单的例子，当你把照片从数码相机传输到你的计算机之后，你可能会删除其中某些不如意的部分，这会使图像文件的编号变得不再连续。你会想使用特定的前缀和连续的数字对它们进行重命名。我们当然可以借助第三方软件执行这类重命名操作，但是也可以使用Bash命令在短短几秒钟之内完成同样的活儿。

另一件经常要做的工作是，将文件名中包含某个特定部分（例如相同的前缀）或者具有特定类型的所有文件移动到指定的文件夹中。让我们看看如何用脚本来执行这些操作。

2.13.1　预备知识

rename命令利用Perl正则表达式修改文件名。综合运用find、rename和mv，我们能做到的事其实很多。

2.13.2　实战演练

用特定的格式重命名当前目录下的图像文件，最简单的方法是使用下面的脚本：

```
#!/bin/bash
#文件名：rename.sh
#用途：重命名.jpg和.png文件

count=1;
for img in `find . -iname '*.png' -o -iname '*.jpg' -type f -maxdepth 1`
do
  new=image-$count.${img##*.}

  echo "Renaming $img to $new"
  mv "$img" "$new"
  let count++

done
```

输出如下：

```
$ ./rename.sh
Renaming hack.jpg to image-1.jpg
Renaming new.jpg to image-2.jpg
Renaming next.png to image-3.png
```

该脚本将当前目录下所有的.jpg和.png文件重命名，新文件名的格式为image-1.jpg、image-2.jpg、image-3.jpg、image-4.png等，依次类推。

2.13.3 工作原理

在前面的重命名脚本中，使用了for循环对所有扩展名为.jpg或.png的文件进行迭代。我们使用find命令进行搜索，选项-o用于指定多个-iname选项，后者用于执行大小写无关的匹配。借助-maxdepth 1，确保$img中只包含来自当前目录的文件名，无视其他的子目录。

为了跟踪图像编号，我们初始化变量count=1。下一步就是用mv命令重命名文件。因此需要构造出新的文件名。${img##*.}对处于当前循环中的文件名进行解析并获得文件扩展名（请参看2.12节中对于${img##*.}的解释）。

let count++用来在每次循环中增加文件编号。

还有许多其他执行重命名操作的方法，来看其中一些例子。

- 将*.JPG更名为*.jpg：

```
$ rename *.JPG *.jpg
```

- 将文件名中的空格替换成字符“_”：

```
$ rename 's/ /_/g' *
```

's/ /_/g'用于替换文件名，而 * 是用于匹配目标文件的通配符，它也可以以 *.txt或其他样式出现。

- 转换文件名的大小写：

```
$ rename 'y/A-Z/a-z/' *
$ rename 'y/a-z/A-Z/' *
```

- 将所有的 .mp3文件移入给定的目录：

```
$ find path -type f -name "*.mp3" -exec mv {} target_dir \;
```

- 将所有文件名中的空格替换为字符“_”：

```
$ find path -type f -exec rename 's/ /_/g' {} \;
```

2.14　拼写检查与词典操作

Linux大多数发行版都含有一份词典文件。然而，我发现几乎没人在意过这个文件，更别提利用它了。还有一个叫做aspell的命令行工具，其作用是进行拼写检查。让我们通过一些脚本来看看如何使用词典文件和拼写检查工具。

2.14.1　实战演练

目录 /usr/share/dict/ 包含了一些词典文件。“词典文件”就是包含了词典单词列表的文本文件。我们可以利用这个列表来检查某个单词是否为词典中的单词。

```
$ ls /usr/share/dict/
american-english  british-english
```

为了检查给定的单词是否为词典中的单词，可以使用下面的脚本：

```
#!/bin/bash
#文件名: checkword.sh
word=$1
grep "^$1$" /usr/share/dict/british-english -q
if [ $? -eq 0 ]; then
  echo $word is a dictionary word;
else
  echo $word is not a dictionary word;
fi
```

这个脚本的用法如下：

```
$ ./checkword.sh ful
ful is not a dictionary word
```

```
$ ./checkword.sh fool
fool is a dictionary word
```

2.14.2 工作原理

在grep中，^ 标记着单词的开始，$ 标记着单词的结束。

-q 禁止产生任何输出。

另外，我们也可以用拼写检查命令aspell来核查某个单词是否在词典中：

```
#!/bin/bash
#文件名: aspellcheck.sh
word=$1

output=`echo \"$word\" | aspell list`

if [ -z $output ]; then
        echo $word is a dictionary word;
else
        echo $word is not a dictionary word;
fi
```

当给定的输入不是一个词典单词时，aspell list命令产生输出文本，反之则不产生任何输出。-z用于确认 $output是否为空。

列出文件中以特定单词起头的所有单词：

```
$ look word filepath
```

或者使用

```
$ grep "^word" filepath
```

在默认情况下，如果没有给出文件参数，look命令会使用默认词典（/usr/share/dict/words）并返回输出。

```
$look word
# 像这样使用时，look命令以默认词典作为文件参数
```

例如：

```
$ look android
android
android's
androids
```

2.15　交互输入自动化

就编写自动化工具或测试工具而言，实现命令的交互输入自动化极其重要。在很多情况下，我们要同一些以交互方式读取输入的命令打交道。下面的例子就是一个要求提供交互式输入的命令执行过程。

```
$ command
Enter a number: 1
Enter name : hello
You have entered 1,hello
```

2.15.1　预备知识

能够自动接受输入的自动化工具，对于本地命令或远程应用来说都有益处。让我们看看如何实现自动化。

2.15.2　实战演练

思考一下交互式输入的过程。参照之前的代码，我们可以将涉及的步骤描述如下：

```
1[Return]hello[Return]
```

观察实际通过键盘输入的字符，可以将上面的1、Return、hello以及Return转换为以下字符串：

```
"1\nhello\n"
```

按下回车键时会发送 \n。通过添加 \n，就可以得到发送给stdin的字符串。

因此，通过发送与用户输入等同的字符串，我们就可以实现在交互过程中自动发送输入。

2.15.3　工作原理

先写一个读取交互式输入的脚本，然后用这个脚本进行自动化的演示：

```
#!/bin/bash
#文件名: interactive.sh
read -p "Enter number:" no ;
read -p "Enter name:" name
echo You have entered $no, $name;
```

按照下面的方法向脚本自动发送输入：

```
$ echo -e "1\nhello\n" | ./interactive.sh
You have entered 1, hello
```

看来制作的输入生效了。

我们用echo -e来生成输入序列，-e表明echo会解释转义序列。如果输入内容比较多，那么可以用单独的输入文件结合重定向操作符来提供输入：

```
$ echo -e "1\nhello\n"  > input.data
$ cat input.data
1
hello
```

制作输入文件时，你也可以不用echo命令：

```
$ ./interactive.sh < input.data
```

这个方法是从文件中导入交互式输入数据。

如果你是逆向工程师，那可能同缓冲区溢出攻击打过交道。要实施攻击，我们需要将十六进制形式的shellcode（例如“\xeb\x1a\x5e\x31\xc0\x88\x46”）进行重定向。这些字符没法直接通过键盘输入，因为键盘上并没有其对应的按键。因此，我们应该使用：

```
echo -e \xeb\x1a\x5e\x31\xc0\x88\x46"
```

这条命令会将shellcode重定向到有缺陷的可执行文件中。

我们已经描述了一种方法，它通过stdin将所需的文本进行重定向，从而实现交互式输入程序自动化。但是我们并没有检查所发送的输入内容。我们期望程序以特定（固定）的次序处理我们所发送的输入。如果程序对于输入采取随机或其他处理次序，或者甚至不要求输入某些内容，那么之前的方法就要出问题了。它会发送不符合程序要求的错误输入。为了处理动态输入并通过检查程序运行时的输入需求来提供输入内容，我们要使用一个出色的工具expect。expect命令可以根据输入要求提供适合的输入。

2.15.4 补充内容

我们看看expect的用法。交互式输入自动化也可以用其他方法实现。expect脚本就是其中之一。

用expect实现自动化

在默认情况下，多数常见的Linux发行版中并不包含expect。你得用软件包管理器手动进行安装。

expect等待特定的输入提示，通过检查输入提示来发送数据。

```
#!/usr/bin/expect
#文件名: automate_expect.sh
spawn ./interactive.sh
expect "Enter number:"
send "1\n"
expect "Enter name:"
send "hello\n"
expect eof
```

运行结果如下：

```
$ ./automate_expect.sh
```

在这个脚本中：

- spawn参数指定需要自动化哪一个命令；
- expect参数提供需要等待的消息；
- send是要发送的消息；
- expect eof指明命令交互结束。

2.16　利用并行进程加速命令执行

在过去的几年中，计算能力有了大幅度的攀升。但这并不是仅仅因为处理器有了更高的时钟频率，而是因为多核的出现。对于用户而言，这意味着单个物理处理器中包含了多个逻辑处理器。

除非软件能够善加利用多核，否则它们毫无用武之地。如果你有一个需要进行大量运算的程序，仅运行在其中一个核心上，那么其他的核心都会被闲置。如果想提高速度，软件必须留意并充分利用多核。

在这则攻略中，我们会看到如何让命令运行得更快。

2.16.1　实战演练

以之前讲过的md5sum命令为例。由于涉及运算，该命令属于CPU密集型命令。如果多个文件需要生成校验和，我们可以使用下面的脚本来运行md5sum的多个实例。

```
#/bin/bash
#文件名: generate_checksums.sh
PIDARRAY=()
for file in File1.iso File2.iso
do
  md5sum $file &
```

```
  PIDARRAY+=("$!")
done
wait ${PIDARRAY[@]}
```

运行脚本后，可以得到如下输出：

```
$ ./generate_checksums.sh
330dcb53f253acdf76431cecca0fefe7  File1.iso
bd1694a6fe6df12c3b8141dcffaf06e6  File2.iso
```

输出结果和下面命令的结果一样：

```
md5sum File1.iso File2.iso
```

但是因为多个md5sum命令是同时运行的，如果你使用的是多核处理器，就会更快地获得运行结果（可以使用time命令来验证）。

2.16.2 工作原理

我们利用了Bash的操作符&，它使得shell将命令置于后台并继续执行脚本。这意味着一旦循环结束，脚本就会退出，而md5sum命令仍在后台运行。为了避免这种情况，我们使用$!来获得进程的PID，在Bash中，$!保存着最近一个后台进程的PID。我们将这些PID放入数组，然后使用wait命令等待这些进程结束。

第 3 章

以文件之名 3

本章内容

- ❑ 生成任意大小的文件
- ❑ 文本文件的交集与差集
- ❑ 查找并删除重复文件
- ❑ 文件权限、所有权和粘滞位
- ❑ 创建不可修改文件
- ❑ 批量生成空白文件
- ❑ 查找符号链接及其指向目标
- ❑ 列举文件类型统计信息
- ❑ 使用环回文件
- ❑ 生成ISO文件及混合ISO
- ❑ 查找文件差异并进行修补
- ❑ head与tail——打印文件的前10行或后10行
- ❑ 只列出目录的其他方法
- ❑ 在命令行中用pushd和popd快速定位
- ❑ 统计文件的行数、单词数和字符数
- ❑ 打印目录树

3.1 简介

Unix将操作系统中的一切都视为文件。所有操作都离不开文件，可以利用它们进行各种与系统或进程相关的处理工作。例如，我们所使用的命令终端就是和一个设备文件关联在一起的。我们可以通过写入特定终端所对应的设备文件来实现向终端写入信息。文件的形式多种多样，比如目录、普通文件、块设备、字符设备、符号链接、套接字和命名管道等。文件名、大小、文件类型、文件内容修改时间、文件访问时间、文件属性更改时间、i节点、链接以及文件所在的文件系统等都是文件的属性。本章包含的实战攻略涉及文件相关的操作及属性。

3.2 生成任意大小的文件

出于各种原因，你也许需要生成一个包含随机数据的文件。这可能是用于执行测试的测试文件，比如用一个大文件作为输入来测试应用程序的效率；也可能是测试文件分割，或是创建环回

文件系统（**环回文件**自身包含文件系统，这种文件可以像物理设备一样使用mount命令进行挂载）。专门写一个程序来创建这些文件可得花点功夫，所以我们用一些通用工具帮忙解决。

实战演练

创建特定大小的大文件最简单的方法就是利用dd命令。dd命令会克隆给定的输入内容，然后将一模一样的一份副本写入到输出。stdin、设备文件、普通文件等都可作为输入，stdout、设备文件、普通文件等也可作为输出。下面是使用dd命令的一个示例：

```
$ dd if=/dev/zero of=junk.data bs=1M count=1
1+0 records in
1+0 records out
1048576 bytes (1.0 MB) copied, 0.00767266 s, 137 MB/s
```


该命令会创建一个1MB大小的文件junk.data。来看一下命令参数：if代表输入文件（input file），of代表输出文件（output file），bs代表以字节为单位的块大小（block size），count代表需要被复制的块数。

使用dd命令时一定得留意，该命令运行在设备底层。要是你不小心出了岔子，搞不好会把磁盘清空或是损坏数据。所以一定要反复检查dd命令所用的语法是否正确，尤其是参数of=。

在上面的例子中，我们将bs指定为1MB，count指定为1，于是得到了一个大小为1MB的文件。如果把bs设为2MB，count设为2，那么总文件大小就是4MB。

块大小可以使用各种计量单位。表3-1中任意一个字符都可以置于数字之后来指定字节数。

表 3-1

单元大小	代 码
字节（1B）	c
字（2B）	w
块（512B）	b
千字节（1024B）	k
兆字节（1024KB）	M
吉字节（1024MB）	G

按照这种方法，我们就可以生成任意大小的文件。表3-1中给出的计量单位都可以使用。

/dev/zero是一个字符设备，它会不断返回0值字节（\0）。

如果不指定输入参数（if），默认情况下dd会从stdin中读取输入。与之类似，如果不指定输出参数（of），则dd会将stdout作为默认输出。

也可以用dd命令传输大量数据并观察命令输出来测量内存的操作速度（例如，在前一个例子中所示的1048576 bytes (1.0 MB) copied, 0.00767266 s, 137 MB/s）。

3.3　文本文件的交集与差集

交集（intersection）和差集（set difference）操作在数学课上的集合论中经常会被用到。不过，有时候对字符串进行类似的操作也很有用。

3.3.1　预备知识

comm命令可用于两个文件之间的比较。它有很多不错的选项可用来调整输出，以便我们执行交集、求差（difference）以及差集操作[①]。

- **交集**：打印出两个文件所共有的行。
- **求差**：打印出指定文件所包含的且互不相同的那些行。
- **差集**：打印出包含在文件A中，但不包含在其他指定文件中的那些行。

3.3.2　实战演练

需要注意的是comm必须使用排过序的文件作为输入。请看看下面的例子：

```
$ cat A.txt
apple
orange
gold
silver
steel
iron

$ cat B.txt
orange
gold
cookies
carrot
```

① 假设现在有两个文件A和B，内容分别是：A(1,2,3)，B(3,4,5)。那么，对这两个文件进行操作的结果如下。
交集：3。
求差：1,2,4,5。
差集（A）：1,2。

```
$ sort A.txt -o A.txt ; sort B.txt -o B.txt
```

(1) 首先执行不带任何选项的comm：

```
$ comm A.txt B.txt
apple
        carrot
        cookies
                gold
iron
                orange
silver
steel
```

输出的第一列包含只在A.txt中出现的行，第二列包含只在B.txt中出现的行，第三列包含A.txt和B.txt中相同的行。各列以制表符（\t）作为定界符。

(2) 为了打印两个文件的交集，我们需要删除第一列和第二列，只打印出第三列：

```
$ comm A.txt B.txt -1 -2
gold
orange
```

(3) 打印出两个文件中不相同的行：

```
$ comm A.txt B.txt  -3
apple
        carrot
        cookies
iron
silver
steel
```

在这次的输出中，那些唯一出现的行使得列中出现了空白字段。所以这两列在同一行上不会同时都出现内容。为了提高输出结果的可用性，需要删除空白字段，将两列合并成一列：

```
apple
carrot
cookies
iron
silver
steel
```

(4) 要生成规范的输出，得使用下面的命令：

```
$ comm A.txt B.txt  -3 | sed 's/^\t//'
apple
```

```
carrot
cookies
iron
silver
steel
```

(5) 通过删除不需要的列，我们就可以分别得到A.txt和B.txt的差集。

- A.txt的差集

```
$ comm A.txt B.txt -2 -3
```

-2 -3 删除第二列和第三列。

- B.txt的差集

```
$ comm A.txt B.txt -1 -3
```

-1 -3 删除第一列和第三列。

3.3.3　工作原理

comm的命令行选项可以按照需求对输出进行格式化，例如：

- -1 从输出中删除第一列；
- -2 从输出中删除第二列；
- -3 从输出中删除第三列。

在生成统一输出时，sed命令通过管道获取comm的输出。它删除行首的 \t字符。sed中的s表示替换（substitute）。/^\t/ 匹配行前的 \t（^是行首标记）。//（两个/操作符之间没有任何字符）是用来替换行首的\t的字符串。如此一来，就删除了所有行首的\t。

差集操作允许你比较两个文件，打印出只在A.txt或B.txt中出现的行。当A.txt和B.txt作为comm命令的参数时，输出中的第一列是A.txt相对于B.txt的差集，第二列是B.txt相对于A.txt的差集。

3.4　查找并删除重复文件

重复文件是同一个文件的多个副本。有时候我们需要删除重复的文件，只保留其中一份。通过查看文件内容来识别重复文件是件挺有意思的活儿。可以结合多种shell工具来完成这项任务。在这则攻略中，我们讨论如何查找重复文件并根据查找结果执行相关的操作。

3.4.1　预备知识

我们可以通过比较文件内容来识别它们。校验和是依据文件内容来计算的，内容相同的文件

自然会生成相同的校验和，因此，我们可以通过比较校验和来删除重复文件。

3.4.2 实战演练

(1) 按照下面的方法创建一些测试文件：

```
$ echo "hello" > test ; cp test test_copy1 ; cp test test_copy2;
$ echo "next" > other;
# test_copy1和test_copy2都是test文件的副本
```

(2) 删除重复文件的脚本代码如下：

```
# !/bin/bash
# 文件名：remove_duplicates.sh
# 用途：查找并删除重复文件，每一个文件只保留一份

ls -lS --time-style=long-iso | awk 'BEGIN {
  getline; getline;
  name1=$8; size=$5
}
{
  name2=$8;
  if (size==$5)
  {
    "md5sum "name1 | getline; csum1=$1;
    "md5sum "name2 | getline; csum2=$1;
    if ( csum1==csum2 )
    {
      print name1; print name2
    }
  };

  size=$5; name1=name2;
}' | sort -u > duplicate_files


cat duplicate_files | xargs -I {} md5sum {} | sort | uniq -w 32 | awk '{ print
"^"$2"$" }' | sort -u >  duplicate_sample

echo Removing..
comm duplicate_files duplicate_sample  -2 -3 | tee /dev/stderr | xargs rm
echo Removed duplicates files successfully.
```

(3) 执行方式：

```
$ ./remove_duplicates.sh
```

3.4.3　工作原理

前文中的shell脚本会找出某个目录中同一文件的所有副本，然后保留单个副本的同时删除其他副本。让我们研究一下这个脚本的工作原理。

`ls -lS`对当前目录下的所有文件按照文件大小进行排序，并列出文件的详细信息。awk读取`ls -lS`的输出，对行列进行比较，找出重复文件。

下面是代码的执行逻辑。

- 我们将文件依据大小排序并列出，这样大小接近的文件就会排列在一起。识别大小相同的文件是我们查找重复文件的第一步。接下来，计算这些文件的校验和。如果校验和相同，那么这些文件就是重复文件，将被删除。
- 在从文件中读取文本行之前，首先要执行awk的`BEGIN{}`语句块。读取文本行的工作在`{}`语句块中进行，读取并处理完所有的行之后，执行`END{}`语句块。`ls -lS`的输出如下：

```
total 16
-rw-r--r-- 1 slynux slynux 5 2010-06-29 11:50 other
-rw-r--r-- 1 slynux slynux 6 2010-06-29 11:50 test
-rw-r--r-- 1 slynux slynux 6 2010-06-29 11:50 test_copy1
-rw-r--r-- 1 slynux slynux 6 2010-06-29 11:50 test_copy2
```

- 第1行输出告诉我们文件数量，这个信息在本例中没什么用处。我们用getline读取第1行，然后丢弃。由于需要对每一行及其下一行来比对文件大小，因此用getline读取长文件列表的第一行，并存储文件名和大小（它们分别是第8列和第5列）。这样我们就先得到了一行。接下来，awk进入`{}`语句块（在这个语句块中读取余下的文本行），读取到的每一行文本都会执行该语句块。它将当前行中读取到的文件大小与之前存储在变量size中的值进行比较。如果相等，那就意味着两个文件至少在大小上是相同的，随后再用md5sum执行进一步的检查。

我们在给出的解决方法中使用了一些技巧。

在awk中，外部命令的输出可以用下面的方法读取：

```
"cmd"| getline
```

随后就可以在`$0`中获取命令的输出，在`$1,$2,…$n`中获取命令输出中的每一列。我们将文件的md5sum保存在变量csum1和csum2中。变量name1和name2保存文件列表中位置连续的文件名。如果两个文件的校验和相同，那它们肯定是重复文件，其文件名会被打印出来。

我们需要从每组重复文件中找出一个文件，这样就可以删除其他副本了。计算重复文件的md5sum，从每一组重复文件中打印出其中一个。这是通过`-w 32`比较每一行的md5sum（md5sum

输出中的前32个字符，md5sum的输出通常由32个字符的散列值和文件名组成），然后找出那些不相同的行。这样，每组重复文件中的一个采样就被写入duplicate_sample。

现在需要将duplicate_files中列出的、且未包含在duplicate_sample之内的全部文件删除。这些文件由comm命令负责打印出来。我们可以使用差集操作来实现（参考3.3节）。

comm通常只接受排序过的文件。所以，在重定向到duplicate_files和duplicate_sample之前，首先用sort -u作为一个过滤器。

tee命令在这里有一个妙用：它在将文件名传递给rm命令的同时，也起到了print的作用。tee将来自stdin的行写入文件，同时将其发送到stdout。我们也可以将文本重定向到stderr来实现终端打印功能。/dev/stderr是对应于stderr（标准错误）的设备。通过重定向到stderr设备文件，来自stdin的文本将会以标准错误的形式出现在终端中。

3.5 文件权限、所有权和粘滞位

文件权限和所有权是Unix/Linux文件系统（如**ext文件系统**）最显著的特性之一。在Unix/Linux平台工作时，经常会碰到与文件权限及所有权相关的问题。这则攻略就考查了文件权限和所有权的各种用例。

Linux系统中的每一个文件都与多种类型的权限相关联。在这些权限中，我们通常要和三类权限打交道（用户、用户组以及其他用户）。

用户（user）是文件的所有者。**用户组**（group）是多个用户的集合（由系统管理员指定），系统允许这些用户对文件进行某种形式的访问。**其他用户**（others）是除文件用户或用户组之外的任何人。

用命令ls -l可以列出文件的权限：

```
-rw-r--r-- 1 slynux slynux  2497  2010-02-28 11:22 bot.py
drwxr-xr-x 2 slynux slynux  4096  2010-05-27 14:31 a.py
-rw-r--r-- 1 slynux slynux  539   2010-02-10 09:11 cl.pl
```

第1列输出明确了后面的输出。其中第一个字母的对应关系如下所示。

- ❑ -——普通文件。
- ❑ d——目录。
- ❑ c——字符设备。
- ❑ b——块设备。
- ❑ l——符号链接。
- ❑ s——套接字。

- p——管道。

剩下的部分可以划分成三组，每组3个字符（--- --- ---）。第一组的3个字符（---）对应用户权限（所有者），第二组对应用户组权限，第三组对应其他用户权限。这9个字符（即9个权限）中的每一个字符指明是否其设置了某种权限。如果已设置，对应位置上会出现一个字符，否则出现一个'-'，表明没有设置对应的权限。

让我们来看一下每个字符组对于用户、用户组以及其他用户的含义。

- **用户**（权限序列：rwx------）：第一个字符指定用户是否拥有文件的读权限。如果为用户设置了读权限，r将出现在第一个字符的位置上。第二个字符指定了写（修改）权限（w），第三个字符指定了用户是否拥有执行权限（x，即运行该文件的权限）。可执行文件通常会设置执行权限。用户还有一个称为setuid（S）的特殊权限，它出现在执行权限（x）的位置。setuid权限允许用户以其拥有者的权限来执行可执行文件，即使这个可执行文件是由其他用户运行的。

  具有setuid权限的文件的权限序列如下：-rwS------。

  目录同样也有读、写、执行权限。不过对于目录来说，读、写、执行权限的含义有点不一样：

  - 目录的读权限（r）允许读取目录中文件和子目录的列表；
  - 目录的写权限（w）允许在目录中创建或删除文件或目录；
  - 目录的执行权限（x）指明是否可以访问目录中的文件和子目录。

- **用户组**（权限序列：---rwx---）：第二组字符指定了组权限。组权限的rwx的含义和用户权限中的一样。组权限并没有setuid，但是有一个setgid（S）位。它允许以同该目录拥有者所在组相同的有效组权限来允许可执行文件。但是这个组和实际发起命令的用户组未必相同。
  组权限的权限序列如下：----rwS---。
- **其他用户**（权限序列：------rwx）：最后三个字符是其他用户权限。和用户以及用户组一样，其他用户也有读、写、执行权限，但是并没有S权限（如setuid和setgid）。

目录有一个特殊的权限，叫做**粘滞位**（sticky bit）。如果目录设置了粘滞位，只有创建该目录的用户才能删除目录中的文件，即使用户组和其他用户也有写权限，也无能无力。粘滞位出现在其他用户权限中的执行权限（x）位置。它使用t或T来表示。如果没有设置执行权限，但设置了粘滞位，就使用t；如果同时设置了执行权限和粘滞位，就使用T。

例如：

```
------rwt , ------rwT
```

设置目录粘滞位的一个典型例子就是 /tmp。

在ls -l的每一行输出中，字符串slynux slynux分别对应所属用户和所属用户组。第一个slynux代表所属用户，第二个slynux代表用户组的所有者。

3.5.1 实战演练

可使用chmod命令设置文件权限。

假设需要设置权限：rwx rw- r--。

可以像下面这样使用chmod：

```
$ chmod u=rwx g=rw o=r filename
```

在这里：

- u——指定用户权限
- g——指定用户组权限
- o——指定其他实体权限

可以对用户、用户组和其他用户用 + 进行添加权限，用 - 删除权限。

文件已经具有权限rwx rw- r--，现在需要增加可执行权限，方法如下：

```
$ chmod o+x filename
```

给所有权限类别（即用户、用户组和其他用户）增加可执行权限：

```
$ chmod a+x filename
```

其中，a表示全部（all）。

如果需要删除权限，则使用 -，例如：

```
$ chmod a-x filename
```

也可以用八进制数来设置权限。权限由3位八进制数来表示，每一位按顺序分别对应用户、用户组和其他用户。

读、写和执行权限都有与之对应的唯一的八进制数：

- r-- = 4
- -w- = 2
- --x = 1

我们可以将权限序列的八进制值相加来获得所需的权限组合，例如：

- rw- = 4 + 2 = 6
- r-x = 4 + 1 = 5

权限序列 rwx rw- r--的数字表示形式如下：

- rwx = 4 + 2 + 1 = 7
- rw- = 4 + 2 = 6
- r-- = 4

因此，rwx rw- r-- 等于764，那么使用八进制值设置权限的命令为：

```
$ chmod 764 filename
```

3.5.2　补充内容

让我们再看一些其他有关文件和目录的操作。

1. 更改所有权

要更改文件的所有权，可以使用chown命令：

```
$ chown user.group filename
```

例如：

```
$ chown slynux.slynux test.sh
```

在这里，slynux既是用户名，也是用户组名。

2. 设置粘滞位

粘滞位是一种应用于目录的权限类型。通过设置粘滞位，使得只有目录的所有者才能够删除目录中的文件，即使用户组和其他用户拥有足够的权限也不能执行删除操作。

要设置粘滞位，利用chmod将 +t应用于目录：

```
$ chmod a+t directory_name
```

3. 以递归的方式设置权限

有时候需要以递归的方式修改当前目录下的所有文件和子目录的权限，方法如下：

```
$ chmod 777 . -R
```

选项 -R指定以递归的方式修改权限。

我们用“.”指定当前工作目录，这等同于：

```
$ chmod 777 "$(pwd)" -R.
```

4. 以递归的方式设置所有权

用chown命令结合 -R就可以以递归的方式设置所有权：

```
$ chown user.group . -R
```

5. 以不同的身份运行可执行文件

一些可执行文件需要以不同的用户身份（启动该文件的当前用户之外的用户），通过文件路径来执行（如 ./executable_name）。有一个叫做setuid的特殊文件权限，它允许其他用户以文件所有者的身份来执行文件。

首先将文件的所有权替换为需要执行该文件的用户，然后以该用户的身份登录。运行下面的命令：

```
$ chmod +s executable_file

# chown root.root executable_file
# chmod +s executable_file
$ ./executable_file
```

现在，这个文件实际上每次都是以root用户的身份来执行。

setuid的使用不是无限制的。为了确保安全，它只能应用在Linux ELF格式二进制文件上，而不能用于脚本文件。

3.6 创建不可修改的文件

在常见的Linux扩展文件系统中（如ext2、ext3、ext4等），可以借助某种文件属性将文件设置为不可修改（immutable）。一旦设置，任何用户（包括超级用户）都不能删除该文件，除非其不可修改的属性被移除。通过查看 /etc/mtab文件，我们很容易获知所有挂载分区的文件系统类型。这个文件的第一列指定了分区设备路径（如 /dev/sda5），第三列指定了文件系统类型（如ext3）。

不可修改属性是避免文件被篡改的安全手段之一。/etc/resolv.conf文件就是这样的一个例子。该文件包含了一组DNS服务器列表。DNS服务器负责将域名（例如packtpub.com）转换成IP地址。它通常被设置成你所属ISP的DNS服务器地址。但有些用户更喜欢使用第三方的DNS服务器，他们会修改/etc/resolv.conf，将其指向所选的服务器。可当下次你再连接到ISP时，/etc/resolv.conf又会恢复到之前的设置。为了避免这种情况，需要将/etc/resolv.conf 设置成不可修改。

3.6.1　预备知识

chattr能够将文件设置为不可修改。不过chattr能做的可不止这些。

3.6.2　实战演练

(1) 使用下列命令将一个文件设置为不可修改：

```
# chattr +i file
```

(2) 这样文件file就变为了不可修改状态。来试试下面的命令:

```
rm file
rm: cannot remove 'file': Operation not permitted
```

(3) 如果需要使文件恢复可写状态，移除不可修改属性即可：

```
chattr -i file
```

3.7　批量生成空白文件

有时候我们可能需要为程序生成测试样本，这些程序面对的是上千个文件。那该怎样生成这些测试样本呢?

3.7.1　预备知识

touch命令可以用来生成空白文件或是修改文件的时间戳（如果文件已存在）。让我们来看看该命令的用法。

3.7.2　实战演练

(1) 用下面的命令创建一个名为filename的空白文件：

```
$ touch filename
```

(2) 批量生成不同名字的空白文件：

```
for name in {1..100}.txt
do
  touch $name
done
```

在上面的代码中，{1..100}会扩展成一个字符串“1, 2, 3, 4, 5, 6, 7，…100”。除了{1..100}.txt，我们还可以使用其他简写样式，比如 test{1..200}.c、test{a..z}.txt等。

如果文件已经存在，那么touch命令会将与该文件相关的所有时间戳都更改为当前时间。如果我们只想更改某些时间戳，则可以使用下面的选项。

- touch -a 只更改文件访问时间。
- touch -m 只更改文件内容修改时间。

(3) 除了将时间戳更改为当前时间，我们还能够为时间戳指定特定的时间和日期：

```
$ touch -d "Fri Jun 25 20:50:14 IST 1999" filename
```

-d使用的日期串不需要是同样的格式。它可以接受任何简短的日期格式。我们可以忽略具体时间，使用“Jan 20 2010”这种方便的日期格式。

3.8 查找符号链接及其指向目标

符号链接在类Unix系统中很常见。使用它的理由有很多，要么是为了便于存取，要么是为了维护相同代码库或程序的不同版本。这则攻略中我们讨论了处理符号链接的一些基本方法。

符号链接只不过是指向其他文件的指针。它在功能上类似于Mac OS中的别名或Windows中的快捷方式。删除符号链接不会影响到原始文件。

3.8.1 实战演练

我们可以按照下面的步骤来处理符号链接。

(1) 创建符号链接：

```
$ ln -s target symbolic_link_name
```

例如：

```
$ ln -l -s /var/www/ ~/web
```

这个命令在已登录用户的home目录中创建了一个名为Web的符号链接。该链接指向/var/www。

(2) 使用下面的命令来验证是否创建链接：

```
$ ls -l web
lrwxrwxrwx 1 slynux slynux 8 2010-06-25 21:34 web -> /var/www
```

web -> /var/www表明web指向 /var/www。

(3) 打印出当前目录下的符号链接：

```
$ ls -l | grep "^l"
```

(4) 使用find打印当前目录以及子目录下的符号链接：

```
$ find . -type l -print
```

(5) 使用readlink打印出符号链接所指向的目标路径：

```
$ readlink web
/var/www
```

3.8.2　工作原理

在查找当前目录下的符号链接时，grep对ls -l的输出进行过滤，使用^显示那些以l起始的行，^是字符串的起始标记。该方法利用了这样一个事实：每个符号链接的权限标记块（lrwxrwxrwx）均以字母l起始。

在使用find时，我们将type的参数指定为l，告诉find命令只搜索符号链接文件。-print选项将符号链接列表打印到标准输出（stdout）。“·”表示从当前目录开始搜索。

3.9　列举文件类型统计信息

文件类型可谓数量繁多。如果编写一个脚本，使它能够遍历目录中所有的文件，并生成一份关于文件类型细节以及每种文件类型数量的报告，这肯定很有意思。这则攻略正是教你练习如何编写一个能够遍历大量文件并收集相关细节的脚本。

3.9.1　预备知识

find命令可以通过查看文件内容来找出特定类型的文件。在Unix/Linux系统中，文件类型并不是由文件扩展名决定的（在微软Windows平台中是这么做的）。编写这个脚本的目的是从多个文件中收集文件类型统计信息。我们用关联数组存储相同类型的文件数量，用find命令获取每一个文件的类型细节。

3.9.2　实战演练

(1) 用下面的命令打印文件类型信息：

```
$ file filename
```

```
$ file /etc/passwd
/etc/passwd: ASCII text
```

(2) 打印不包括文件名在内的文件类型信息：

```
$ file -b filename
ASCII text
```

(3) 生成文件统计信息的脚本如下：

```
# !/bin/bash
# 文件名: filestat.sh

if [ $# -ne 1 ];
then
  echo "Usage is $0 basepath";
  exit
fi
path=$1

declare -A statarray;

while read line;
do
  ftype=`file -b "$line" | cut -d, -f1`
  let statarray["$ftype"]++;

done < <(find $path -type f -print)

echo ============ File types and counts =============
for ftype in "${!statarray[@]}";
do
  echo $ftype :  ${statarray["$ftype"]}
done
```

(4) 用法如下：

```
$ ./filestat.sh /home/slynux/temp
```

输出如下：

```
$ ./filetype.sh /home/slynux/programs
============ File types and counts =============
Vim swap file : 1
ELF 32-bit LSB executable : 6
ASCII text : 2
ASCII C program text : 10
```

3.9.3 工作原理

在脚本中声明了一个关联数组statarray，这样可以用文件类型作为数组索引，将每种文件类型的数量存入数组。每次遇到一个文件类型，就用let增加计数。find命令以递归的方式获取文件路径列表。脚本中的ftype='file -b "$line"'使用file命令获得文件类型信息。选项-b告诉file命令只打印文件类型（不包括文件名）。输出的文件类型信息包含很多细节，比如图像编码以及分辨率（如果是图像文件的话）。对于这些细节我们并不感兴趣，我们只需要基本的信息就够了。各种细节信息是由逗号分隔的，例如：

```
$ file a.out -b
ELF 32-bit LSB executable, Intel 80386, version 1 (SYSV), dynamically linked (uses
shared libs), for GNU/Linux 2.6.15, not stripped
```

我们只需要从上面这些细节中提取ELF 32-bit LSB executable。因此我们使用cut -d, -f1，指明以逗号作为定界符，并且只打印第一个字段。

done<<(find $path -type f -print);是一段很重要的代码。它的执行逻辑如下：

```
while read line;
do something
done < filename
```

我们不用filename，而是用find命令的输出。

<(find $path -type f -print)等同于文件名。只不过它用子进程输出来代替文件名。注意，第一个<用于输入重定向，第二个<用于将子进程的输出装换成文件名。在两个<之间有一个空格，避免shell将其解释为<<操作符。

在Bash 3.*x*及更高的版本中，有一个新操作符<<<，可以让我们将字符串作为输入文件。利用这个新操作符，可以将loop循环的done语句改写成

```
done <<< "`find $path -type f -print`"
```

${!statarray[@]}用于返回一个数组索引列表。

3.10 使用环回文件

环回（loopback）文件系统是Linux类系统中非常有趣的部分。我们通常是在设备上（例如磁盘分区）创建文件系统。这些存储设备能够以设备文件的形式来使用，比如 /dev/device_name。为了使用存储设备上的文件系统，我们需要将其挂载到一些被称为**挂载点**（mount point）的目录上。环回文件系统是指那些在文件中而非物理设备中创建的文件系统。我们可以将这些文件作为

文件系统挂载到挂载点上。这实际上可以让我们在物理磁盘上的文件中创建逻辑磁盘。

3.10.1 实战演练

让我们来看看如何在大小为1GB的文件中创建ext4文件系统。

(1) 下面的命令可以创建一个1GB大小的文件：

```
$ dd if=/dev/zero of=loobackfile.img bs=1G count=1
1024+0 records in
1024+0 records out
1073741824 bytes (1.1 GB) copied, 37.3155 s, 28.8 MB/s
```

你会发现创建好的文件大小超过了1GB。这是因为硬盘作为块设备，其分配存储空间时是按照块大小的整数倍来进行的。

(2) 用mkfs命令将1GB的文件格式化成ext4文件系统：

```
$ mkfs.ext4 loopbackfile.img
```

(3) 使用下面的命令检查文件系统：

```
$ file loobackfile.img
loobackfile.img: Linux rev 1.0 ext4 filesystem data,
UUID=c9d56c42-f8e6-4cbd-aeab-369d5056660a (extents) (large files) (huge files)
```

(4) 现在就可以挂载环回文件了：

```
# mkdir /mnt/loopback
# mount -o loop loopbackfile.img /mnt/loopback
```

-o loop用来挂载环回文件系统。

这实际上是一种快捷的挂载方法，我们无需手动连接任何设备。但是在内部，这个环回文件连接到了一个名为/dev/loop1或loop2的设备上。

(5) 我们也可以手动来操作：

```
# losetup /dev/loop1 loopbackfile.img
# mount /dev/loop1 /mnt/loopback
```

(6) 使用下面的方法进行卸载（umount）：

```
# umount mount_point
```

例如：

```
# umount /mnt/loopback
```

(7) 也可以用设备文件的路径作为umount命令的参数：

```
# umount /dev/loop1
```

注意，因为mount和umount都是特权命令，所以必须以root用户的身份来执行。

3.10.2　工作原理

我们首先使用dd命令创建了一个文件，准备将其作为环回文件使用。dd是一个用于复制原始数据（raw data）的通用命令。它将数据从if参数所指定的文件复制到of参数所指定的文件中。另外，我们指定dd以大小为1GB的块为单位进行复制，共复制1块，这样就创建了一个1GB的文件。/dev/zero是一个特殊的文件，如果读取这个文件，读出的内容都是0。

然后使用mkfts．ext4命令在该文件中创建ext4文件系统。我们需要文件系统才能将文件存储到磁盘或环回文件中。

最后，我们使用mount命令将环回文件挂载到**挂载点**上（在这个例子中是/mnt/loopback）。挂载点使得用户可以访问文件系统中的文件。在执行mount命令之前，应该先使用mkdir命令创建挂载点。选项-o loop用于指明使用的是环回文件。

当mount知道它使用的是环回文件时，它会自动在/dev中建立一个对应该环回文件的设备并进行挂载。如果想手动操作，可以使用losetup命令建立设备，然后使用mount命令挂载。

3.10.3　补充内容

让我们再来研究一下使用环回文件和挂载的其他用法。

1. 在环回镜像中创建分区

假设我们需要创建环回文件，然后分区并挂载其中某个分区。在这种情况下，没法使用mount -o loop。我们必须手动建立设备并挂载分区。使用下面的方法对文件（内容全部填充为0）进行分区：

```
# losetup /dev/loop1 loopback.img
# fdisk /dev/loop1
```

fdisk是Linux系统中的标准分区工具，在http://www.tldp.org/HOWTO/Partition/fdisk_partitoning.html处可以找到一份有关如何使用fdisk创建分区的简明教程（记得将教程中的/dev/hdb换成/dev/loop1）。

在loopback.img中创建分区并挂载第一个分区：

```
# losetup -o 32256 /dev/loop2 loopback.img
```

/dev/loop2表示第一个分区，-o用来指定偏移量，32 256字节用于DOS分区方案[①]。第一个分区在硬盘上起始于32 256字节处。

2. 快速挂载带有分区的换回磁盘镜像

如果我们希望挂载环回磁盘镜像中的分区，可以将分区偏移量以手动的形式传递给losetup。不过，有一个更快的方法可以挂载镜像中的所有分区——kpartx。它并没有安装默认在系统中，你得使用软件包管理器进行安装：

```
# kpartx -v -a diskimage.img
add map loop0p1 (252:0): 0 114688 linear /dev/loop0 8192
add map loop0p2 (252:1): 0 15628288 linear /dev/loop0 122880
```

这条命令在磁盘镜像中的分区与/dev/mapper中的设备之间建立了映射，随后便可以挂载这些设备。下列命令可以用来挂载第一个分区：

```
# mount /dev/mapper/loop0p1 /mnt/disk1
```

当你处理完该设备上的操作后（使用umount卸载所有挂载过的分区），使用下列命令移除映射关系：

```
# kpartx -d diskimage.img
loop deleted : /dev/loop0
```

3. 将ISO文件作为环回文件挂载

ISO文件是光学存储介质的归档。我们可以采用挂载环回文件的方法，像挂载物理光盘一样挂载ISO文件。

我们甚至可以用一个非空目录作为挂载路径。那么在设备被卸载之前，这个挂载路径中包含的都是来自该设备的数据，而非目录中的原始内容。例如：

```
# mkdir /mnt/iso
# mount -o loop linux.iso /mnt/iso
```

现在就可以用/mnt/iso中的文件进行操作了。ISO是一个只读文件系统。

4. 使用sync即刻应用更改

当对挂载设备作出更改之后，这些改变并不会被立即写入物理设备。只有当缓冲区被写满之

---

① losetup 中的 -o 32256 (512*63=32256)用于设置数据偏移。由于历史原因，硬盘第一个扇区（512 字节）作为 MBR（Master Boot Record，主引导记录），其后的62个扇区作为保留扇区。

后才会进行设备回写。但是我们可以用sync命令强制将更改即刻写入：

```
$ sync
```

3.11　生成 ISO 文件及混合型 ISO

ISO镜像是一种存档格式，它存储了如CD-ROM、DVD-ROM等光盘的精确镜像。ISO镜像通常用于存储待刻录的数据。这节，我们会看到如何使用光盘来创建ISO镜像。很多人都是依赖第三方工具来创建ISO镜像。其实若使用命令行，会更简单。

我们同样需要区分可引导光盘与不可引导光盘之间的差别。可引导光盘自身具备引导能力，也可以运行操作系统或其他软件。不可引导光盘则做不到这些。很重要的一点是：将可引导光盘中的内容复制到另一张光盘上并不足以生成一张新的可引导光盘。要想保留光盘的可引导性，应该使用ISO文件将其保存为磁盘镜像。

现在，多数人会用闪存或硬盘作为光盘的代替品。当我们将一个可引导的ISO文件写入闪存后，它却再也没法引导了，除非我们使用一种专门设计用于闪存设备的混合ISO镜像。

这则攻略将带你认识ISO镜像及其处理方法。

3.11.1　预备知识

我们已经提到过多次，Unix将一切都作为文件来处理。所有的设备都是文件。那应该怎样复制设备的精确镜像呢？需要读出所有的数据，并将其写入另外一个文件，对吧？

如我们所知，cat命令可以用来读取任何数据，重定向可以用来写入文件。

3.11.2　实战演练

用下面的命令从/dev/cdrom创建一个ISO镜像：

```
# cat /dev/cdrom > image.iso
```

尽管可以奏效。但创建ISO镜像最好的方法还是使用dd工具：

```
# dd if=/dev/cdrom of=image.iso
```

mkisofs命令用于创建ISO文件系统。可以用cdrecord之类的工具将mkisofs的输出文件直接刻录到CD-ROM或DVD-ROM上。我们可以将需要的所有文件放入同一个目录中，然后用mkisofs将整个目录的内容写入一个ISO文件。方法如下：

```
$ mkisofs -V "Label" -o image.iso source_dir/
```

其中选项 -o指定了ISO文件的路径。source_dir是作为ISO文件内容来源的目录路径，选项 -V指定了ISO文件的卷标。

3.11.3 补充内容

让我们继续学习一些ISO文件相关的命令和技巧。

1. 能够启动闪存或硬盘的混合型ISO

通常无法通过将可引导的ISO文件写入USB设备来启动操作系统。但是有一种被称为“混合ISO”的特殊ISO文件可以做到这一切。

我们可以用isohybrid命令把标准ISO文件转换成混合ISO。isohybrid是一个比较新的工具，大多数的Linux发行版中还未包含这个工具。你可以从http://syslinux.zytor.com下载syslinux软件包。

来看看下面的命令：

```
# isohybrid image.iso
```

执行这个命令，我们将获得一个名为image.iso的混合ISO，它可用于写入USB存储设备。

将该ISO写入USB存储设备：

```
# dd if=image.iso of=/dev/sdb1
```

你可以用适当的设备代替/dev/sdb1，或者使用cat命令：

```
# cat image.iso >> /dev/sdb1
```

2. 用命令行刻录ISO

cdrecord命令可以用来将ISO文件刻入CD-ROM或DVD-ROM。刻录CD-ROM的方法如下：

```
# cdrecord -v dev=/dev/cdrom image.iso
```

还有一些其他的选项，如下所示:

- 我们可以用-speed选项指定刻录速度：

  ```
  -speed SPEED
  ```

  例如：

  ```
  # cdrecord -v dev=/dev/cdrom image.iso -speed 8
  ```

  参数8表明其刻录速度为8x。

- 刻录CD-ROM时也可以采用多区段（multisession）方式，这样就能在一张光盘上分多次

刻录数据。多区段刻录需要使用 -multi选项：

```
# cdrecord -v dev=/dev/cdrom image.iso -multi
```

3. 玩转CD-ROM托盘

如果你是用的是桌面电脑，不妨试试下面的命令来找点乐趣。

- **$ eject**

  这个命令可以弹出光驱托盘。

- **$ eject -t**

  这个命令可以合上光驱托盘。

  不妨试着写一个可以让托盘重复开合*n*次的循环吧。

3.12　查找文件差异并进行修补

当一个文件有多个版本时，如果能够重点标记出这些版本之间的不同而无须通过人工查看来比较，那就简直是太棒了。要是文件很大，光靠人工进行比较可是件极其费时费力的活儿。这则攻略为你演示如何用行号对文件之间的差异进行重点标记。当多名开发人员在文件繁多的环境下工作时，如果某个人对其中某个文件进行了修改，那么应该将这个修改告知其他所有开发人员。如果发送整个源代码，不仅浪费磁盘存储空间，而且单靠手动检查这些修改就很耗时间。这时，发送一个差异文件就显得很有用了。它只包含那些被修改过、添加或删除的行以及行号。这个差异文件被称为**修补文件**（patch file）。我们可以用patch命令将修补文件中包含的更改信息应用到原始文件。也可以再次进行修补来撤销改变。来看看如何才能实现这一切。

3.12.1　实战演练

diff命令可以生成差异文件。

(1) 为了生成差异信息，先创建下列文件。

- **文件 1：**version1.txt

```
this is the original text
line2
line3
line4
happy hacking !
```

❑ 文件 2：version2.txt

```
this is the original text
line2
line4
happy hacking !
GNU is not UNIX
```

(2) 非一体化（nonunified）形式的diff输出（不使用 -u选项）如下：

```
$ diff version1.txt version2.txt
3d2
<line3
6c5
> GNU is not UNIX
```

(3) 一体化形式的diff输出如下：

```
$ diff -u version1.txt version2.txt
--- version1.txt  2010-06-27 10:26:54.384884455 +0530
+++ version2.txt  2010-06-27 10:27:28.782140889 +0530
@@ -1,5 +1,5 @@
this is the original text
line2
-line3
line4
happy hacking !
-
+GNU is not UNIX
```

选项-u用于生成一体化输出。因为一体化输出的可读性更好，更易于看出两个文件之间的差异，所以人们往往更喜欢这种输出形式。

在一体化diff输出中，以 + 起始的是新加入的行，以 - 起始的是删除的行。

(4) 修补文件可以通过将diff的输出重定向到一个文件来生成：

```
$ diff -u version1.txt version2.txt > version.patch
```

现在就可以用patch命令将修改应用于任意文件。当应用于version1.txt时，我们就可以得到version2.txt；而当应用于version2.txt时，就可以得到version1.txt。

(5) 用下列命令来进行修补：

```
$ patch -p1 version1.txt < version.patch
patching file version1.txt
```

version1.txt的内容现在和verson2.txt的内容一模一样。

(6) 下面的命令可以撤销做出的修改：

```
$ patch -p1 version1.txt < version.patch
patching file version1.txt
Reversed (or previously applied) patch detected!  Assume -R? [n] y
# 修改被撤销
```

如上例所示，修补已修补的文件将撤销修改。

在撤销修改时，若使用patch命令的 -R选项，则不会提示用户y/n。

3.12.2　补充内容

让我们再看一些diff的其他特性。

生成目录的差异信息

diff命令也能够以递归的形式作用于目录。它会对目录中的所有内容生成差异输出。使用下面的命令：

```
$ diff -Naur directory1 directory2
```

上面命令中出现的选项含义如下。

- -N：将所有缺失的文件视为空文件。
- -a：将所有文件视为文本文件。
- -u：生成一体化输出。
- -r：遍历目录下的所有文件。

3.13　使用 **head** 与 **tail** 打印文件的前 10 行和后 10 行

当查看上千行的大文件时，我们可不会用cat命令把整个文件内容给打印出来。相反，我们只会查看文件的一小部分内容（例如文件的前10行或后10行）。有时候可能需要打印出文件的前*n*行或后*n*行，也有可能需要打印出除了前*n*行或后*n*行之外所有的行。

还有一种情况是打印文件的第*m*行至第*n*行。

head和tail命令可以帮助我们实现这些需求。

实战演练

head命令总是读取输入文件的头部。

(1) 打印前10行：

```
$ head file
```

(2) 从stdin读取数据：

```
$ cat text | head
```

(3) 指定打印前几行：

```
$ head -n 4 file
```

该命令会打印文件的前4行。

(4) 打印除了最后*M*行之外所有的行：

```
$ head -n -M file
```

注意，-M表示一个负数，并非选项。

例如，用下面的代码打印除了最后5行之外的所有行：

```
$ seq 11 | head -n -5
1
2
3
4
5
6
```

而下面的命令会打印出文件的第1行至第5行：

```
$ seq 100 | head -n 5
```

(5) 将最后几行排除在打印范围之外是head非常重要的一种用法。来看看如何打印文件最后的若干行。打印文件的最后10行：

```
$ tail file
```

(6) 可以用下面的代码从stdin中读取输入：

```
$ cat text | tail
```

(7) 打印最后5行：

```
$ tail -n 5 file
```

(8) 打印除了前*M*行之外所有的行：

```
$ tail -n +(M+1)
```

例如，打印除前5行之外的所有行，M+1=6，因此使用下列命令：

```
$ seq 100 | tail -n +6
```

这条命令将打印出第6行至第100行。

tail命令的一个重要用法是从一个内容不断增加的文件中读取数据。新增加的内容总是被添加到文件的尾部，因此当新内容被写入文件的时候，可以用tail将其显示出来。只是如果简单地使用tail的话，它只会读取文件的最后10行，然后退出。但那时新的内容也许又已经被其他进程追加到文件中了。为了能够不间断地监视文件的增长，tail有一个特殊的选项 -f或--follow，它们会使tail密切关注文件中新添加的内容，并随着数据的增加持续保持更新：

```
$ tail -f growing_file
```

你可能希望将其用于日志文件。监视文件内容增加的命令如下：

```
# tail -f /var/log/messages
```

或者

```
$ dmesg | tail -f
```

我们经常会运行dmeg 查看内核的环形缓冲区消息，要么是调试USB设备，要么是查看sdX（X是对应于SCSI磁盘的sd设备的次序列号）。tail -f也可以加入一个睡眠间隔 -s，这样我们就可以设置监视文件更新的时间间隔。

tail有一个很有意思的特性：当某个给定进程结束之后，tail也会随之终结。

假设我们正在读取一个不断增长的文件，进程Foo一直在向该文件追加数据，那么tail -f就会一直执行到进程Foo结束。

```
$ PID=$(pidof Foo)
$ tail -f file --pid $PID
```

当进程Foo结束之后，tail也会跟着结束。

让我们实际演练一下。

(1) 创建一个新文件file.txt，用gedit打开这个文件（你也可以使用其他文本编辑器）。
(2) 向文件添加新内容并不断地在gedit中保存。
(3) 现在运行下列命令：

```
$ PID=$(pidof gedit)
$ tail -f file.txt --pid $PID
```

当你不断对文件进行更新时，更新的内容都会被tail命令写入终端。当关闭gedit时，tail命令也会随之结束。

3.14 只列出目录的各种方法

用脚本只列出目录似乎不是件容易事。这则攻略很值得学习，因为它介绍了多种只列出目录的方法与技巧。

3.14.1 预备知识

有很多种方法可以只列出目录。当你向其他人询问这些技术的时候，你得到的第一个答案可能是dir。但dir只不过是一个类似于ls且选项更少的命令。让我们来看看如何列出目录。

3.14.2 实战演练

有好几种方法可以列出当前路径下的目录。

(1) 使用ls -d：

```
$ ls -d */
```

(2) 使用grep结合ls -F：

```
$ ls -F | grep "/$"
```

(3) 使用grep结合ls -l：

```
$ ls -l | grep "^d"
```

(4) 使用find：

```
$ find . -type d -maxdepth 1 -print
```

3.14.3 工作原理

当使用-F时，所有的输出项都会添加上一个代表文件类型的字符，如@、*、|等。目录对应的是 / 字符。我们用grep只过滤那些以 /$ 作为行尾标记的输出项。

ls -d 输出的每一行的首字符表示文件类型。目录的文件类型字符是"d"。因此我们用grep过滤以"d"起始的行。^ 是行首标记。

find命令可以指定type的参数为目录并将maxdepth设置成1，这是因为我们不需要继续向下搜索。

3.15　在命令行中使用 **pushd** 和 **popd** 进行快速定位

当在终端或shell提示符下涉及多处位置时，我们通常所做的就是复制并粘贴路径。但如果没有GUI，只能通过命令行进行访问时，这招就难有用武之地了。举例来说，假如同时涉及/var/www、/home/slynux和 /usr/src目录，当要在这些位置之间进行切换时，每次都要通过键盘输入路径，这实在是一件很麻烦的事。此时，我们就可以使用诸如pushd和popd这种基于**命令行接口**（Command-Line Interface，CLI）的定位技术。让我们来看看它们的使用方法。

3.15.1　预备知识

pushd和popd可以用于在多个目录之间进行切换而无需复制并粘贴目录路径。pushd和popd以栈的方式来运作。我们都知道栈是一个**后进先出**（Last In First Out, LIFO）的数据结构。目录路径被存储在栈中，然后用push和pop操作在目录之间进行切换。

3.15.2　实战演练

使用pushd和popd时，可以无视cd命令。

(1) 压入并切换路径：

```
~ $ pushd /var/www
```

现在，栈中包含了 /var/www ~，当前目录切换到 /var/www。

(2) 再压入下一个目录路径：

```
/var/www $ pushd /usr/src
```

现在栈中包含 /usr/src /var/www ~，当前目录为 /usr/src。

(3) 用下面的命令查看栈内容：

```
$ dirs
/usr/src /var/www ~ /usr/share /etc
0           1              2  3              4
```

(4) 当你想切换到列表中任意一个路径时，将每条路径从0到*n*进行编号，然后使用你希望切换到的路径编号，例如：

```
$ pushd +3
```

这条命令会将栈进行翻转并切换到目录 /use/share。

pushd总是将路径添加到栈。如果要从栈中删除路径，可以使用popd。

(5) 要删除最后添加的路径并把当前目录更改为上一级目录，可以使用以下命令：

```
$ popd
```

假设现在栈包含 /usr/src /var/www ~ /usr/share /etc，当前目录是 /usr/share，popd会将栈更改为 /var/www ~ /usr/share /etc，并且把目录切换到/var/www。

(6) 用popd +num可以从列表中移除特定的路径。

num是从左到右，从0到*n*开始计数的。

3.15.3 补充内容

让我们再进行一些基本的目录定位练习。

在常用的目录之间切换

当涉及3个以上的目录时，可以使用pushd和popd。但是如果只涉及两个位置的时候，还有另一个更简便的方法：cd -。

如果当前路径是 /var/www，执行下面的命令：

```
/var/www $  cd /usr/src
/usr/src $ # 做点什么
```

现在要切换回 /var/www，你不需要再输入一次，只需要执行：

```
/usr/src $ cd -
```

你还可以再切换到 /usr/src：

```
/var/www $ cd -
```

3.16 统计文件的行数、单词数和字符数

统计文件的行数、单词数和字符数在文本处理工作中发挥着重要作用。很多时候，单词或字符计数被作为一种间接的技巧来生成所需要的输出样式及结果。本书在其他章节就包含了一些这样的实例。对开发人员来说，**统计代码行数**是一件重要的工作。我们可能需要对无关文件之外的特定类型的文件进行统计。将wc结合其他命令有助于我们实现这些需求。

wc是一个用于统计的工具。它是Word Count（单词统计）的缩写。来看看如何使用wc统计文件的行数、单词数和字符数。

实战演练

我们可以使用wc的各种选项来统计行数、单词数和字符数。

(1) 统计行数：

```
$ wc -l file
```

(2) 如果需要将stdin作为输入，使用下列命令：

```
$ cat file | wc -l
```

(3) 统计单词数：

```
$ wc -w file
$ cat file | wc -w
```

(4) 统计字符数：

```
$ wc -c file
$ cat file | wc -c
```

例如，我们可以按照下面的方法统计文本中的字符数：

```
echo -n 1234 | wc -c
4
```

-n用于避免echo添加额外的换行符。

(5) 当不使用任何选项执行wc时：

```
$ wc file
   1435   15763  112200
```

它会分别打印出文件的行数、单词数和字符数。

(6) 使用-L选项打印出文件中最长一行的长度：

```
$ wc file -L
205
```

3.17　打印目录树

在准备教程和文档时，将目录和文件系统以图形化的树状层次结构描述，一定会为你增色不少。在编写一些监控脚本时，用清晰易懂的树状描述方式来查看文件系统，同样颇有益处。让我们来看看这是如何实现的。

3.17.1 预备知识

tree命令以图形化的树状结构打印文件和目录。在Linux发行版中通常并没有包含这个命令。你需要用包管理器自行安装。

3.17.2 实战演练

下面是树状Unix文件系统的一个示例：

```
$ tree ~/unixfs
unixfs/
|-- bin
|   |-- cat
|   `-- ls
|-- etc
|   `-- passwd
|-- home
|   |-- pactpub
|   |   |-- automate.sh
|   |   `-- schedule
|   `-- slynux
|-- opt
|-- tmp
`-- usr
8 directories, 5 files
```

tree命令有很多有意思的选项，让我们认识一下其中的几项。

- 重点标记出匹配某种样式的文件：

```
$ tree path -P PATTERN # 用通配符描述样式
```

例如：

```
$ tree PATH -P "*.sh" # 用一个目录路径代替PATH
|-- home
|   |-- packtpub
|   |   `-- automate.sh
```

- 重点标记出除符合某种样式之外的那些文件：

```
$ tree path -I PATTERN
```

- 使用 -h选项同时打印出文件和目录的大小：

```
$ tree -h
```

3.17.3　补充内容

请看一个有趣的tree命令选项。

以HTML形式输出目录树

tree命令可以生成HTML输出。例如，用下面的命令可以创建一个包含目录树输出的HTML文件：

```
$ tree PATH -H http://localhost -o out.html
```

将http://localhost替换为适合存放输出文件的URL。将PATH替换为主目录的真正路径。当前目录可以用 . 作为PATH。

根据目录列表生成的Web页面形式如图3-1所示。

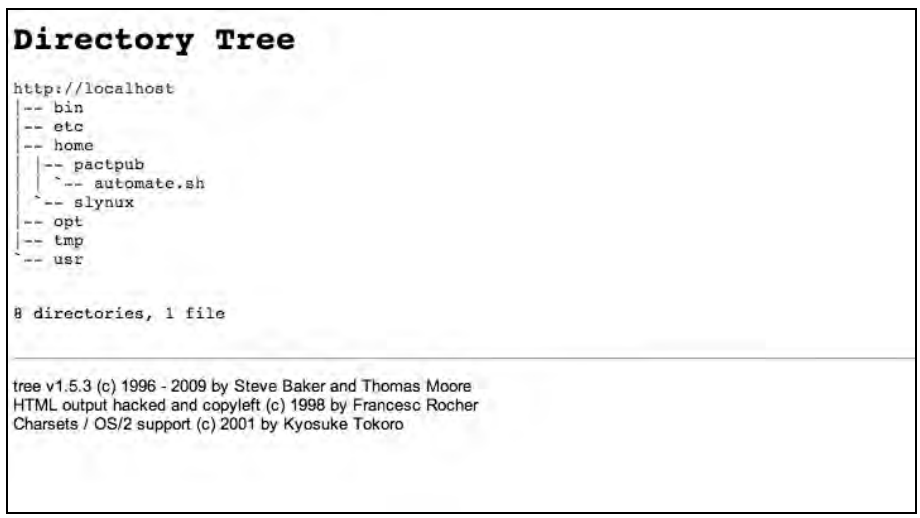

图　3-1

第 4 章

让文本飞

4

本章内容

- 使用正则表达式
- 用grep在文件中搜索文本
- 用cut按列切分文件
- 使用sed进行文本替换
- 使用awk进行高级文本处理
- 统计特定文件中的词频
- 压缩或解压缩JavaScript
- 按列合并文件
- 打印文件或行中的第*n*个单词或列
- 打印不同行或样式之间的文本
- 以逆序形式打印行
- 解析文本中的电子邮件地址和URL
- 在文件中移除包含某个单词的句子
- 对目录中的所有文件进行文本替换
- 文本切片与参数操作

4.1 简介

shell脚本语言包含了众多用于解决Unix/Linux系统问题必不可少的组件。文本处理是shell脚本擅长的重要领域之一。它可以与sed、awk、grep、cut这类优美的工具组合在一起来解决文本处理相关的问题。

有各种各样的工具能够帮助我们从不同的细节层面上处理文件，比如字符、行、单词、行列等，允许我们用多种方法来处理文本文件。正则表达式是模式匹配技术的核心。借助适合的正则表达式，可以生成我们所需的各类输出结果，例如过滤、剥离（strip）、替换、搜索等。

本章包括一系列攻略，探讨了多个与文本处理相关的问题，了解这些问题在编写用于解决实际问题的脚本时大有裨益。

4.2 使用正则表达式

正则表达式是基于模式匹配的文本处理技术的关键所在。想要在编写文本处理工具方面驾轻

就熟，你就必须对正则表达式有一个基本的理解。通配符能够匹配的文本范围相当有限。正则表达式是一种用于文本匹配的形式小巧、具有高度针对性的编程语言。`[a-z0-9_]+@[a-z0-9]+\.[a-z]+`就是一个能够匹配电子邮件地址的正则表达式。

看起来有点怪异是吧？别担心，跟着这则攻略学习，你就会发现它其实很简单。

4.2.1　实战演练

正则表达式是由字面文本和具有特殊意义的符号组成的。我们可以根据具体需求，使用它们构造出适合的正则表达式来匹配文本。因为正则表达式是一种匹配文本的通用语言，因此在这则攻略中我们不再介绍其他工具，留待本章其他攻略中再叙。

来看几个文本匹配的例子。

- 要匹配给定文本中的所有单词，可以使用下面的正则表达式：

```
( ?[a-zA-Z]+ ?)
```

  “?”用于匹配单词前后可能出现的空格。`[a-zA-Z]+`代表一个或多个字母（a~z和A~Z）。

- 要匹配一个IP地址，可以使用下面的正则表达式：

```
[0-9]{1,3}\.[0-9]{1,3}\.[0-9]{1,3}\.[0-9]{1,3}
```

  或者

```
[[:digit:]]{1,3}\.[[:digit:]]{1,3}\.[[:digit:]]{1,3}\.[[:digit:]]{1,3}
```

  我们知道IP地址通常的书写形式是192.168.0.2，它是由点号分割的4个整数（每一个整数的取值范围从0~255）。

  `[0-9]`或`[:digit:]`匹配数字0~9。`{1,3}`匹配1到3个数字，`\.`匹配"."。

这个正则表达式可以匹配所处理文本中的IP地址，但它并不检查地址的合法性。例如，形如123.300.1.1的IP地址可以被正则表达式匹配，但这却是一个非法的IP地址。不过在解析文本流时，通常目标仅仅是找出IP地址而已。

4.2.2　工作原理

先来看一看正则表达式的基本组成部分，如表4-1所示。

表 4-1

正则表达式	描 述	示 例
^	行起始标记	^tux 匹配以tux起始的行
$	行尾标记	tux$ 匹配以tux结尾的行
.	匹配任意一个字符	Hack.匹配Hackl和Hacki，但是不能匹配Hackl2和Hackil，它只能匹配单个字符
[]	匹配包含在 [字符] 之中的任意一个字符	coo[kl] 匹配cook或cool
[^]	匹配除 [^字符] 之外的任意一个字符	9[^01] 匹配92、93，但是不匹配91或90
[-]	匹配 [] 中指定范围内的任意一个字符	[1-5] 匹配从1 ~ 5的任意一个数字
?	匹配之前的项1次或0次	colou?r 匹配color或colour，但是不能匹配colouur
+	匹配之前的项1次或多次	Rollno-9+ 匹配Rollno-99、Rollno-9，但是不能匹配Rollno-
*	匹配之前的项0次或多次	co*l 匹配cl、col、coool等
()	创建一个用于匹配的子串	ma(tri)?x 匹配max或maxtrix
{n}	匹配之前的项n次	[0-9]{3} 匹配任意一个三位数，[0-9]{3}可以扩展为[0-9][0-9][0-9]
{n,}	之前的项至少需要匹配n次	[0-9]{2,} 匹配任意一个两位或更多位的数字
{n,m}	指定之前的项所必需匹配的最小次数和最大次数	[0-9]{2,5} 匹配从两位数到五位数之间的任意一个数字
|	交替——匹配 | 两边的任意一项	Oct (1st | 2nd) 匹配Oct 1st或Oct 2nd
\	转义符可以将上面介绍的特殊字符进行转义	a\.b匹配a.b，但不能匹配ajb。通过在 . 之间加上前缀 \，从而忽略了 . 的特殊意义

更多细节请参考：http://www.linuxforu.com/2011/04/sed-explained-part-1/。

4.2.3 补充内容

下面就看一看如何在正则表达式中赋予某些字符特殊含义。

1. 处理特殊字符

正则表达式用$、^、.、*、+、{以及}等作为特殊字符。但是如果我们希望将这些字符作为非特殊字符（表示普通字面含义的字符），应该怎么做呢？来看一个正则表达式的例子：a.txt。

它会匹配字符a，然后是任意字符，接着是字符串txt。但是我们希望'.'能够匹配字面意义上的'.'，而非任意字符。所以我们在这个字符之前加上了一个反斜杠\（这叫做“将该字符进行转义”）。这表明正则表达式希望匹配的是字面字符，而不是它所代表的特殊含义。因此，最终的正则表达式就变成了a\.txt。

2. 可视化正则表达式

正则表达式有时很难理解，但是人们更易于理解带有图示的事物，因此就出现了一些将正则表达式进行可视化的工具。你可以通过http://www.regexper.com找到同类工具中的一个。你可以在这个工具中输入正则表达式，然后它会创建出一个漂亮的图示来帮助你理解。图4-1就是上一节那个正则表达式的可视化截图。

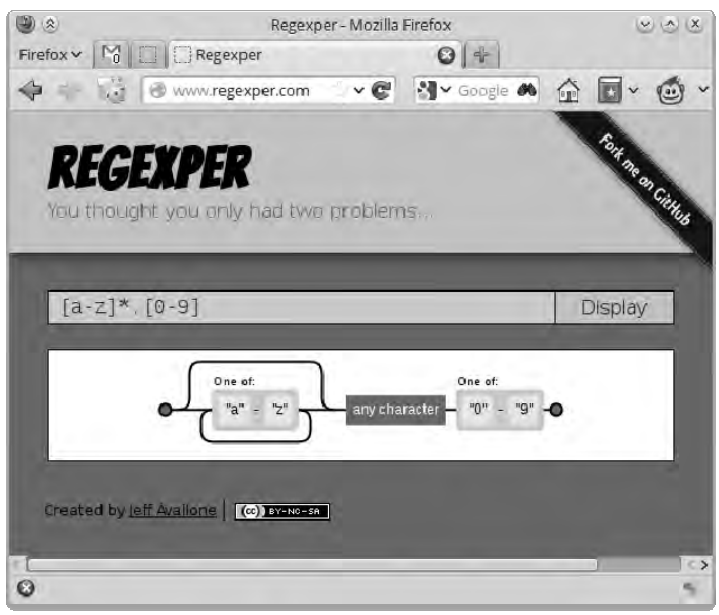

图　4-1

4.3　用 grep 在文件中搜索文本

在文件中进行搜索是文本处理中一项重要工作。我们也许需要在某些多达上千行的文件中查找所需要的数据。这则攻略将教你如何从大量数据中定位符合规格的数据。

4.3.1　实战演练

grep命令作为Unix中用于文本搜索的神奇工具，能够接受正则表达式，生成各种格式的输出。除此之外，它还有大量有趣的选项。让我们看看具体的用法。

(1) 搜索包含特定模式的文本行：

```
$ grep pattern filename
this is the line containing pattern
```

或者

```
$ grep "pattern" filename
this is the line containing pattern
```

(2) 也可以像下面这样从stdin中读取：

```
$ echo -e "this is a word\nnext line" | grep word
this is a word
```

(3) 单个grep命令也可以对多个文件进行搜索：

```
$ grep "match_text" file1 file2 file3 ...
```

(4) 用--color选项可以在输出行中着重标记出匹配到的单词：

```
$ grep word filename --color=auto
this is the line containing word
```

(5) grep命令只解释match_text中的某些特殊字符。如果要使用正则表达式，需要添加-E选项——这意味着使用扩展（extended）正则表达式。或者也可以使用默认允许正则表达式的grep命令——egrep。例如：

```
$ grep -E "[a-z]+" filename
```

或者

```
$ egrep "[a-z]+" filename
```

(6) 只输出文件中匹配到的文本部分，可以使用选项 -o：

```
$ echo this is a line. | egrep -o "[a-z]+\."
line.
```

(7) 要打印除包含match_pattern行之外的所有行，可使用：

```
$ grep -v match_pattern file
```

选项-v可以将匹配结果进行反转（invert）。

(8) 统计文件或文本中包含匹配字符串的行数：

```
$ grep -c "text" filename
10
```

需要注意的是-c只是统计匹配行的数量，并不是匹配的次数。例如：

```
$ echo -e "1 2 3 4\nhello\n5 6" | egrep  -c "[0-9]"
2
```

尽管有6个匹配项，但命令只打印出2，这是因为只有两个匹配行。在单行中出现的多次匹配只被统计为一次。

(9) 要文件中统计匹配项的数量，可以使用下面的技巧：

```
$ echo -e "1 2 3 4\nhello\n5 6" | egrep -o "[0-9]" | wc -l
6
```

(10) 打印出包含匹配字符串的行号：

```
$ cat sample1.txt
gnu is not unix
linux is fun
bash is art
$ cat sample2.txt
planetlinux

$ grep linux -n sample1.txt
2:linux is fun
```

或者

```
$ cat sample1.txt | grep linux -n
```

如果涉及多个文件，它也会随着输出结果打印出文件名：

```
$ grep linux -n sample1.txt sample2.txt
sample1.txt:2:linux is fun
sample2.txt:2:planetlinux
```

(11) 打印模式匹配所位于的字符或字节偏移：

```
$ echo gnu is not unix | grep -b -o "not"
7:not
```

一行中字符串的字符偏移是从该行的第一个字符开始计算，起始值是0。在上面的例子中，"not"的偏移值是7（也就是说，not是从该行的第7个字符开始的，即“gnu is not unix”这一行）。

选项 -b总是和 -o配合使用。

(12) 搜索多个文件并找出匹配文本位于哪一个文件中：

```
$ grep -l linux sample1.txt sample2.txt
sample1.txt
sample2.txt
```

和-l相反的选项是-L，它会返回一个不匹配的文件列表。

4.3.2 补充内容

我们已经看过了grep命令的基本用法。不过grep的本事可不止如此，它还有更多的特性。接着看看grep的其他选项。

1. 递归搜索文件

如果需要在多级目录中对文本进行递归搜索，可以使用：

```
$ grep "text" . -R -n
```

命令中的“.”指定了当前目录。

grep的选项-R和-r功能一样。

例如：

```
$ cd src_dir
$ grep "test_function()" . -R -n
./miscutils/test.c:16:test_function();
```

test_function()位于miscutils/test.c的第16行。

这是开发人员使用最多的命令之一。它用于查找某些文本位于哪些源码文件中。

2. 忽略样式中的大小写

选项 -i可以使匹配样式不考虑字符的大小写，例如：

```
$ echo hello world | grep -i "HELLO"
hello
```

3. 用grep匹配多个样式

在进行匹配的时候通常只指定一个样式。然而，我们可以用选项 -e来指定多个匹配样式：

```
$ grep -e "pattern1" -e "pattern"
```

例如：

```
$ echo this is a line of text | grep -e "this" -e "line" -o
this
line
```

还有另一种方法也可以指定多个样式。我们可以提供一个样式文件用于读取样式。在样式文件中逐行写下需要匹配的样式，然后用选项 -f执行grep：

```
$ grep -f pattern_filesource_filename
```

例如：

```
$ cat pat_file
hello
cool

$ echo hello this is cool | grep -f pat_file
hello this is cool
```

4. 在grep搜索中指定或排除文件

grep可以在搜索过程中指定（include）或排除（exclude）某些文件。我们通过通配符来指定所include文件或exclude文件。

目录中递归搜索所有的 .c和 .cpp文件：

```
$ grep "main()" . -r  --include *.{c,cpp}
```

注意，some{string1,string2,string3}会扩展成somestring1 somestring2 somestring3。

在搜索中排除所有的README文件：

```
$ grep "main()" . -r --exclude "README"
```

如果需要排除目录，可以使用 --exclude-dir选项。

如果需要从文件中读取所需排除的文件列表，使用--exclude-from FILE。

5. 使用0值字节作为后缀的grep与xargs

xargs命令通常用于将文件名列表作为命令行参数提供给其他命令。当文件名用作命令行参数时，建议用0值字节作为文件名终止符，而非空格。因为一些文件名中会包含空格字符，一旦它被误解为终结符，那么单个文件名就会被认为是两个文件名（例如，New file.txt被解析成New和file.txt两个文件名）。这个问题可以利用0值字节后缀来避免。我们使用xargs以便从诸如grep、find中接收stdin文本。这些命令可以将带有0值字节后缀的文本输出到stdout。为了指明输入的文件名是以0值字节（\0）作为终止符，需要在xargs中使用-0。

创建测试文件：

```
$ echo "test" > file1
$ echo "cool" > file2
$ echo "test" > file3
```

在下面的命令序列中，grep使用-Z选项输出以0值字节作为终结符的文件名（\0）。xargs -0读取输入并用0值字节终结符分隔文件名：

```
$ grep "test" file* -lZ | xargs -0 rm
```

-Z通常和 -l结合使用。

6. grep的静默输出

有时候，我们并不打算查看匹配的字符串，而只是想知道是否能够成功匹配。这可以通过设置grep的静默选项（-q）来实现。在静默模式中，grep命令不会输出任何内容。它仅是运行命令，然后根据命令执行成功与否返回退出状态。

如果命令运行成功会返回0，如果失败则返回非0值。

让我们来看一个脚本，这个脚本利用grep的静默模式来测试文本匹配是否存在于某个文件中。

```
#!/bin/bash
# 文件名: silent_grep.sh
# 用途: 测试文件是否包含特定的文本内容

if [ $# -ne 2 ]; then
  echo "Usage: $0 match_text filename"
  exit 1
fi

match_text=$1
filename=$2
grep -q "$match_text" $filename

if [ $? -eq 0 ]; then
  echo "The text exists in the file"
else
  echo "Text does not exist in the file"
fi
```

这个silent_grep.sh脚本使用一个用于匹配的单词（Student）和一个文件名（student_data.txt）作为命令参数：

```
$ ./silent_grep.sh Student student_data.txt
The text exists in the file
```

7. 打印出匹配文本之前或之后的行

基于上下文的打印是grep的特色之一。假设已经找到了给定文本的匹配行，通常情况下grep只会打印出这一行。但我们也许需要匹配行之前或之后的*n*行，也可能两者皆要。这可以在grep中用前后行控制选项来实现。来看看具体的做法。

要打印匹配某个结果之后的3行，使用 -A选项：

```
$ seq 10 | grep 5 -A 3
5
6
7
8
```

要打印匹配某个结果之前的3行，使用 -B选项：

```
$ seq 10 | grep 5 -B 3
2
3
4
5
```

要打印匹配某个结果之前以及之后的3行，使用-C选项：

```
$ seq 10 | grep 5 -C 3
2
3
4
5
6
7
8
```

如果有多个匹配，那么使用--作为各部分之间的定界符：

```
$ echo -e "a\nb\nc\na\nb\nc" | grep a -A 1
a
b
--
a
b
```

4.4　用 cut 按列切分文件

我们可能需要按列，而不是按行来切分文件。假设我们有一个文本文件，其中按行包含了学生的报表信息，例如Roll、Name、Mark、Percentage。我们需要将学生的姓名或者是第*n*列提取到另一个文件，也可能需要其中两列甚至更多。这则攻略将为你演示如何完成这项任务。

4.4.1　实战演练

cut是一个帮我们将文本按列进行切分的小巧工具。它也可以指定分隔每列的定界符。在cut的术语中，每列被称为一个**字段**。

(1) 要提取特定的字段或列，可以使用下面的语法：

```
cut -f FIELD_LIST filename
```

FIELD_LIST是需要显示的列。它由列号组成，彼此之间用逗号分隔。例如：

```
$ cut -f 2,3 filename
```

这条命令将显示第2列和第3列。

(2) cut也能够从stdin中读取输入文本。

制表符是字段或列的默认定界符。对于没有定界符的行，会将该行照原样打印出来。如果不想打印出这种不包含定界符的行，则可以使用cut的 -s选项。一个cut命令的例子如下：

```
$ cat student_data.txt
No  Name  Mark  Percent
1  Sarath  45  90
2  Alex  49  98
3  Anu  45  90

$ cut -f1 student_data.txt
No
1
2
3
```

(3) 提取多个字段：

```
$ cut -f2,4 student_data.txt
Name     Percent
Sarath   90
Alex     98
Anu     90
```

(4) 要打印多列，需要提供一个由逗号分隔的列号列表作为-f选项的参数。

(5) 我们也可以用 --complement选项对提取的字段进行补集运算。假设有多个字段，你希望打印出除第3列之外的所有列，则可以使用：

```
$ cut -f3 --complement student_data.txt
No  Name    Percent
1   Sarath  90
2   Alex    98
3   Anu     90
```

(6) 要指定字段的定界符，使用 -d选项：

```
$ cat delimited_data.txt
No;Name;Mark;Percent
1;Sarath;45;90
2;Alex;49;98
3;Anu;45;90

$ cut -f2 -d";" delimited_data.txt
Name
Sarath
Alex
Anu
```

4.4.2　补充内容

cut命令有一些选项可以将一串指定的字符作为列来显示。让我们来看看这些选项。

指定字段的字符或字节范围

假设我们不依赖定界符，但需要通过将字段定义为一个字符范围（行首记为0）来进行字段提取。这种需求也可以用cut来实现。

表4-2中列出了对应的记法。

表　4-2

记　法	范　围
N-	从第*N*个字节，字符或字段到行尾
N-M	从第*N*个字节，字符或字段到第*M*个（包括第*M*个在内）字节、字符或字段
-M	第1个字节，字符或字段到第*M*个（包括第*M*个在内）字节、字符或字段

用上面介绍的记法，结合下列选项将字段指定为某个范围内的字节或字符：

- -b 表示字节；
- -c 表示字符；
- -f 用于定义字段。

例如：

```
$ cat range_fields.txt
abcdefghijklmnopqrstuvwxyz
abcdefghijklmnopqrstuvwxyz
abcdefghijklmnopqrstuvwxyz
abcdefghijklmnopqrstuvwxy
```

你可以打印第1个到第5个字符：

```
$ cut -c1-5 range_fields.txt
abcde
abcde
abcde
abcde
```

打印前2个字符：

```
$ cut range_fields.txt -c -2
ab
ab
ab
ab
```

若要用字节作为计数单位，可以将 -c替换成 -b。

在使用 -c、-f和 -b时，我们可以指定输出定界符：

```
--output-delimiter "delimiter string"
```

当用-b或-c提取多个字段时，必须使用 --output-delimiter，否则，你就没法区分不同的字段了。例如：

```
$ cut range_fields.txt -c1-3,6-9 --output-delimiter ","
abc,fghi
abc,fghi
abc,fghi
abc,fghi
```

4.5 使用 sed 进行文本替换

sed是**流编辑器**（stream editor）的缩写。它是文本处理中不可或缺的工具，能够配合正则表达式使用，功能不同凡响。sed命令众所周知的一个用法是进行文本替换。这则攻略包括了sed命令大部分的常用技术。

4.5.1 实战演练

(1) sed可以替换给定文本中的字符串。

```
$ sed 's/pattern/replace_string/' file
```

或者

```
$ cat file | sed 's/pattern/replace_string/'
```

该命令从stdin中读取输入。

如果你用的是vi编辑器，你会发现它用于替换文本的命令和sed的非常相似。

(2) 在默认情况下，sed只会打印替换后的文本。如果需要在替换的同时保存更改，可以使用-i选项，可以将替换结果应用于原文件。很多用户在进行替换之后，会借助重定向来保存文件：

```
$ sed 's/text/replace/' file >newfile
$ mv newfile file
```

其实只需要一行命令就可以搞定，例如：

```
$ sed -i 's/text/replace/' file
```

(3) 之前看到的sed命令会将每一行中第一处符合模式的内容替换掉。但是如果要替换所有内容，我们需要在命令尾部加上参数g，其方法如下：

```
$ sed 's/pattern/replace_string/g' file
```

后缀/g意味着sed会替换每一处匹配。但是有时候我们只需要从第*n*处匹配开始替换。对此，可以使用/Ng选项。

请看下面的命令：

```
$ echo thisthisthisthis | sed 's/this/THIS/2g'
thisTHISTHISTHIS

$ echo thisthisthisthis | sed 's/this/THIS/3g'
thisthisTHISTHIS

$ echo thisthisthisthis | sed 's/this/THIS/4g'
thisthisthisTHIS
```

字符/在sed中被作为定界符使用。我们可以像下面一样使用任意的定界符：

```
sed 's:text:replace:g'
sed 's|text|replace|g'
```

当定界符出现在样式内部时，我们必须用前缀\对它进行转义：

```
sed 's|te\|xt|replace|g'
```

\|是一个出现在样式内部并经过转义的定界符。

4.5.2　补充内容

sed命令包含大量可用于文本处理的选项。将这些选项以合理的次序组合，可以只用一行命

令就解决很多复杂的问题。让我们看看这些选项。

1. 移除空白行

用sed移除空白行不过是小菜一碟。空白行可以用正则表达式 ^$ 进行匹配：

```
$ sed '/^$/d' file
```

/pattern/d会移除匹配样式的行。

在空白行中，行尾标记紧随着行首标记。

2. 直接在文件中进行替换

如果将文件名传递给sed，它会将文件内容输出到stdout。如果我们想修改文件内容，可以使用-i选项：

```
$ sed 's/PATTERN/replacement/' -i filename
```

例如，使用指定的数字替换文件中所有3位数的数字：

```
$ cat sed_data.txt
11 abc 111 this 9 file contains 111 11 88 numbers 0000

$ sed -i 's/\b[0-9]\{3\}\b/NUMBER/g' sed_data.txt
$ cat sed_data.txt
11 abc NUMBER this 9 file contains NUMBER 11 88 numbers 0000
```

上面的单行命令替换了所有的3位数字。正则表达式\b[0-9]\{3\}\b用于匹配3位数字。[0-9]表示数位取值范围，也就是说从0~9。{3}表示匹配之前的字符3次。\{3\}中的\用于转义{和}。\b表示单词边界。

一种有益的做法是先使用不带-i选项的sed命令，以确保正则表达式没有问题，一旦结果符合要求，再加入-i选项将更改写入文件。另外，你也可以使用下列形式的sed：

```
sed -i .bak 's/abc/def/' file
```

这时的sed不仅执行文件内容替换，还会创建一个名为file.bak的文件，其中包含着原始文件内容的副本。

3. 已匹配字符串标记（&）

在sed中，我们可以用 &标记匹配样式的字符串，这样就能够在替换字符串时使用已匹配的内容。

例如：

```
$ echo this is an example | sed 's/\w\+/[&]/g'
[this] [is] [an] [example]
```

正则表达式 \w\+ 匹配每一个单词，然后我们用[&]替换它。& 对应于之前所匹配到的单词。

4. 子串匹配标记（\1）

& 代表匹配给定样式的字符串。但我们也可以匹配给定样式的其中一部分。来看看具体的做法。

```
$ echo this is digit 7 in a number | sed 's/digit \([0-9]\)/\1/'
this is 7 in a number
```

这条命令将digit 7替换为7。样式中匹配到的子串是7。\(pattern\)用于匹配子串。模式被包括在使用斜线转义过的()中。对于匹配到的第一个子串，其对应的标记是 \1，匹配到的第二个子串是 \2，往后依次类推。下面的示例中包含了多个匹配：

```
$ echo seven EIGHT | sed 's/\([a-z]\+\) \([A-Z]\+\)/\2 \1/'
EIGHT seven
```

([a-z]\+\)匹配第一个单词，([A-Z]\+\)匹配第二个单词。\1和\2用来引用它们。这种引用被称为**向后引用**（back reference）。在替换部分，它们的次序被更改为\2 \1，因此结果就呈现出逆序的形式。

5. 组合多个表达式

可以利用管道组合多个sed命令：

```
sed 'expression' | sed 'expression'
```

它等价于

```
$ sed 'expression; expression'
```

或者

```
$ sed -e 'expression' -e expression'
```

例如：

```
$ echo abc | sed 's/a/A/' | sed 's/c/C/'
AbC
$ echo abc | sed 's/a/A/;s/c/C/'
AbC
$ echo abc | sed -e 's/a/A/' -e 's/c/C/'
AbC
```

6. 引用

sed表达式通常用单引号来引用。不过也可以使用双引号。双引号会通过对表达式求值来对其进行扩展。当我们想在sed表达式中使用一些变量时，双引号就能派上用场了。

例如：

```
$ text=hello
$ echo hello world | sed "s/$text/HELLO/"
HELLO world
```

$text的求值结果是hello。

4.6 使用 awk 进行高级文本处理

awk是一款设计用于数据流的工具。它颇有玩头的原因就在于可以对列和行进行操作。awk有很多内建的功能，比如数组、函数等，这是它和C语言的相同之处。灵活性是awk最大的优势。

4.6.1 预备知识

awk脚本的结构基本如下所示：

```
awk ' BEGIN{  print "start" } pattern { commands } END{ print "end" } file
```

awk命令也可以从stdin中读取。

awk脚本通常由3部分组成。BEGIN，END和带模式匹配选项的常见语句块。这3个部分都是可选项，在脚本中可省略任意部分。

4.6.2 实战演练

以下awk脚本被包含在单引号或双引号之间：

```
awk 'BEGIN { statements } { statements } END { end statements }'
```

也可以使用：

```
awk "BEGIN { statements } { statements } END { end statements }"
```

例如：

```
$ awk 'BEGIN { i=0 } { i++ } END{ print i}' filename
```

或者

```
$ awk "BEGIN { i=0 } { i++ } END{ print i }" filename
```

4.6.3　工作原理

awk命令的工作方式如下所注。

(1) 执行BEGIN { commands } 语句块中的语句。

(2) 从文件或stdin中读取一行，然后执行pattern { commands }。重复这个过程，直到文件全部被读取完毕。

(3) 当读至输入流末尾时，执行END { commands } 语句块。

BEGIN语句块在awk开始从输入流中读取行之前被执行。这是一个可选的语句块，诸如变量初始化、打印输出表格的表头等语句通常都可以写入BEGIN语句块中。

END语句块和BEGIN语句块类似。END语句块在awk从输入流中读取完所有的行之后即被执行。像打印所有行的分析结果这类汇总信息，都是在END语句块中实现的常见任务（例如，在比较过所有的行之后，打印出最大数）。它也是一个可选的语句块。

最重要的部分就是pattern语句块中的通用命令。这个语句块同样是可选的。如果不提供该语句块，则默认执行{ print }，即打印所读取到的每一行。awk对于每一行，都会执行这个语句块。这就像一个用来读取行的while循环，在循环体中提供了相应的语句。

每读取一行，awk就会检查该行和提供的样式是否匹配。样式本身可以是正则表达式、条件语句以及行匹配范围等。如果当前行匹配该样式，则执行{ }中的语句。

样式是可选的。如果没有提供样式，那么awk就认为所有的行都是匹配的，并执行{ }中的语句。

让我们看看下面的例子：

```
$ echo -e "line1\nline2" | awk 'BEGIN{ print "Start" } { print } END{ print "End" } '
Start
line1
line2
End
```

当使用不带参数的print时，它会打印出当前行。关于print，需要记住两件重要的事情：当print的参数是以逗号进行分隔时，参数打印时则以空格作为定界符。在awk的print语句中，双引号是被当做拼接操作符（concatenation operator）使用的。

例如：

```
$ echo | awk '{ var1="v1"; var2="v2"; var3="v3"; \
print var1,var2,var3 ; }'
```

该语句将按照下面的格式打印变量值：

```
v1 v2 v3
```

echo命令向标准输出写入一行，因此awk的 { } 语句块中的语句只被执行一次。如果awk的标准输入包含多行，那么 { } 语句块中的命令就会被执行多次。

拼接的使用方法如下：

```
$ echo | awk '{ var1="v1"; var2="v2"; var3="v3"; \
print var1 "-" var2 "-" var3 ; }'
```

输出为：

```
v1-v2-v3
```

{ }类似于一个循环体，会对文件中的每一行进行迭代。

我们通常将变量初始化语句（如var=0）以及打印文件头部的语句放入BEGIN语句块中。在END{}语句块中，往往会放入打印结果等语句。

4.6.4 补充内容

awk命令具有丰富的特性。要想洞悉awk编程的精妙之处，首先应该熟悉awk重要的选项和功能。让我们来看看awk的一些重要功能。

1. 特殊变量

以下是可以用于awk的一些特殊变量。

- NR：表示记录数量，在执行过程中对应于当前行号。
- NF：表示字段数量，在执行过程中对应于当前行的字段数。
- $0：这个变量包含执行过程中当前行的文本内容。
- $1：这个变量包含第一个字段的文本内容。
- $2：这个变量包含第二个字段的文本内容。

例如：

```
$ echo -e "line1 f2 f3\nline2 f4 f5\nline3 f6 f7" | \
```

```
awk '{
print "Line no:"NR",No of fields:"NF, "$0="$0, "$1="$1,"$2="$2,"$3="$3
}'
Line no:1,No of fields:3 $0=line1 f2 f3 $1=line1 $2=f2 $3=f3
Line no:2,No of fields:3 $0=line2 f4 f5 $1=line2 $2=f4 $3=f5
Line no:3,No of fields:3 $0=line3 f6 f7 $1=line3 $2=f6 $3=f7
```

我们可以用print $NF打印一行中最后一个字段，用 $(NF-1)打印倒数第二个字段，其他字段依次类推即可。

awk的printf()函数的语法和C语言中的同名函数一样。我们也可以用这个函数来代替print。

再来看awk的一些基本用法。打印每一行的第2和第3个字段：

```
$awk '{ print $3,$2 }'  file
```

要统计文件中的行数，使用下面的命令：

```
$ awk 'END{ print NR }' file
```

这里只使用了END语句块。每读入一行，awk会将NR更新为对应的行号。当到达最后一行时，NR中的值就是最后一行的行号，于是，位于END语句块中的NR就包含了文件的行数。

你可以将每一行中第一个字段的值按照下面的方法进行累加：

```
$ seq 5 | awk 'BEGIN{ sum=0; print "Summation:" }
{ print $1"+"; sum+=$1 } END { print "=="; print sum }'
Summation:
1+
2+
3+
4+
5+
==
15
```

2. 将外部变量值传递给awk

借助选项 -v，我们可以将外部值（并非来自stdin）传递给awk：

```
$ VAR=10000
$ echo | awk -v VARIABLE=$VAR '{ print VARIABLE }'
10000
```

还有另一种灵活的方法可以将多个外部变量传递给awk，例如：

```
$ var1="Variable1" ; var2="Variable2"
$ echo | awk '{ print v1,v2 }' v1=$var1 v2=$var2
```

```
Variable1 Variable2
```

当输入来自于文件而非标准输入时，使用下列命令：

```
$ awk '{ print v1,v2 }' v1=$var1 v2=$var2 filename
```

在上面的方法中，变量之间用空格分隔，以键-值对的形式（v1=$var1 v2=$var2）作为awk的命名行参数紧随在BEGIN、{}和END语句块之后。

3. 用getline读取行

awk通常默认读取一个文件的所有行。如果只想读取某一行，可以使用getline函数。有时候，我们需要从BEGIN语句块中读取第一行。

语法：getline var。变量var就包含了特定行的内容。如果调用不带参数的getline，我们可以用 $0、$1和$2访问文本行的内容。

例如：

```
$ seq 5 | awk 'BEGIN { getline; print "Read ahead first line", $0 } { print $0 }'
Read ahead first line 1
2
3
4
5
```

4. 使用过滤模式对awk处理的行进行过滤

我们可以为需要处理的行指定一些条件，例如：

```
$ awk 'NR < 5' # 行号小于5的行
$ awk 'NR==1,NR==4' # 行号在1到5之间的行
$ awk '/linux/' # 包含样式linux的行（可以用正则表达式来指定模式）
$ awk '!/linux/' # 不包含包含模式为linux的行
```

5. 设置字段定界符

默认的字段定界符是空格。我们也可以用 -F "delimiter"明确指定一个定界符：

```
$ awk -F: '{ print $NF }' /etc/passwd
```

或者

```
awk 'BEGIN { FS=":" } { print $NF }' /etc/passwd
```

在BEGIN语句块中则可以用OFS="delimiter"设置输出字段的定界符。

6. 从awk中读取命令输出

在下面的代码中，echo会生成一个空白行。变量cmdout包含命令grep root /etc/passwd的输出，该命令会打印出包含root的行。

将命令的输出结果读入变量output的语法如下：

```
"command" | getline output ;
```

例如：

```
$ echo | awk '{ "grep root /etc/passwd" | getline cmdout ; print cmdout }'
root:x:0:0:root:/root:/bin/bash
```

通过使用getline，我们将外部shell命令的输出读入变量cmdout。

awk支持以文本作为索引的关联数组。

7. 在awk中使用循环

在awk中可以使用for循环，其格式如下：

```
for(i=0;i<10;i++) { print $i ; }
```

或者

```
for(i in array) { print array[i]; }
```

8. awk内建的字符串控制函数

awk有很多内建的字符串控制函数，让我们认识一下其中部分函数。

- length(string)：返回字符串的长度。
- index(string, search_string)：返回search_string在字符串中出现的位置。
- split(string, array, delimiter)：用定界符生成一个字符串列表，并将该列表存入数组。
- substr(string, start-position, end-position)：在字符串中用字符起止偏移量生成子串，并返回该子串。
- sub(regex, replacement_str, string)：将正则表达式匹配到的第一处内容替换成replacment_str。
- gsub(regex, replacment_str, string)：和sub()类似。不过该函数会替换正则表达式匹配到的所有内容。
- match(regex, string)：检查正则表达式是否能够匹配字符串。如果能够匹配，返回非0值；否则，返回0。match()有两个相关的特殊变量，分别是RSTART和RLENGTH。变